

Resumen

En la presente memoria se describe el diseño e implementación de un sistema que extrae información de las canciones y las etiqueta automáticamente a partir de su audio. Este trabajo fue desarrollado para la empresa Plusyc Live con el fin de optimizar el armado de catálogos musicales destinados a la ambientación de distintos espacios comerciales.

Para la elaboración de este trabajo fueron fundamentales los conocimientos adquiridos durante la carrera sobre tratamiento de datos estadísticos, modelos de árboles de clasificación y regresión, perceptrones multicapa, aprendizaje por transferencia, y puesta en producción de una REST API.

Índice general

Resumen	I
1. Introducción general	1
1.1. Extracción de información musical	1
1.2. Contexto de aplicación	1
1.3. Objetivos y alcance	2
1.4. Estado del arte	2
1.4.1. Objetivos específicos de señales y extracción a bajo nivel	2
1.4.2. Modelos preentrenados y soluciones comerciales	2
1.4.3. Estado del arte	3
2. Introducción específica	5
2.1. Estilo y convenciones	5
2.1.1. Modelos preentrenados y soluciones comerciales	5
2.1.2. Uso de mayúscula inicial para los título de secciones	5
2.1.3. Síntesis comparativa	5
2.1.4. Este es el título de una subsección	5
2.1.5. Estructura del documento	6
2.1.6. Figuras	6
2.1.7. Tablas	7
2. Introducción específica	7
2.1. Fuentes de datos de canciones	7
2.2. Representaciones numéricas de la música	7
3. Diseño e implementación	9
3.1. Información semántica del audio	9
3.2. Modelos de inteligencia artificial utilizados	10
3.3. Despliegue e integración	11
4. Ensayos y resultados	11
4.1. Pruebas funcionales del hardware	13
4.2. Análisis del software	13
5. Conclusiones	13
5.1. Conclusiones generales	15
5.2. Próximos pasos	15
Bibliografía	17
5.1. Conclusiones	17
5.1. Conclusiones generales	17
5.2. Próximos pasos	17
Bibliografía	19

Índice de figuras

1.1. Interfaz de consulta en Tunebat	4
2.1. Representaciones usuales del qudie eligió para el diseño del logo. .	8
2.2. Probabilidades de depóñon semanal del procesador ¹	10
2.3. ¿Por qué de pronto aparece esta figura?	7
2.4. Tres gráficos simples.	7

Índice de tablas

2.1. Atributos representativos	9
2.1. caption corto	8

Capítulo 1

Introducción general

En este capítulo se introduce la definición de la extracción de información musical, se expone la problemática que motivó la búsqueda de una solución automatizada para la asignación de características musicales a partir del audio de canciones, y se detalla el alcance de la solución propuesta. Finalmente, se realiza una revisión general de las soluciones existentes.

1.1. Extracción de información musical

La extracción de información musical, comúnmente conocida como MIR (por sus siglas en inglés *Music Information Retrieval*), procesa, analiza y organiza datos musicales [1]. Los sistemas MIR abarcan el procesamiento digital de señales y el aprendizaje automático, y permiten automatizar tareas como el etiquetado de canciones, la clasificación de géneros o el reconocimiento de estados de ánimo a partir del audio digital [2].

1.2. Contexto de aplicación

1.2. Contexto de aplicación

El trabajo se realiza para dar respuesta a una necesidad tecnológica de Plusyc Live SAS, una empresa dedicada a la creación de experiencias musicales personalizadas para locales comerciales. La plataforma de la compañía crea listas de reproducción basadas en las características musicales de un catálogo de canciones. Anteriormente, la asignación de estas características dependía del consumo de interfaces de programación de aplicaciones (API) de terceros. Esta metodología generaba restricciones de disponibilidad, incrementos en los costos operativos y limitaba la autonomía de la empresa. Con la implementación de este trabajo, la empresa cuenta con un sistema de inteligencia artificial que caracteriza automáticamente canciones a partir de su archivo de audio. Esto reduce la dependencia de servicios externos y mejora la escalabilidad y autonomía de la aplicación, para fortalecer la experiencia musical personalizada que la empresa ofrece a los comercios.

1.3. Objetivos y alcance

El trabajo incluye la asignación de las características musicales definidas en la tabla 1.1. Las definiciones de las características agrupadas como básicas y perceptibles tienen como origen la documentación de Spotify [3].

1.3. Objetivos y alcance

Esta sección define las metas. Se presenta el objetivo general y los objetivos específicos, los pasos metodológicos necesarios para su cumplimiento y el conjunto de características musicales consideradas.

TABLA 1.1. Definición, ejemplos y tipo de problema de aprendizaje supervisado por característica.

1.3.1. Objetivo general

Característica	Definición	Ejemplos	Tipo de problema
Desarrollar un sistema basado en inteligencia artificial para predecir las características musicales de las canciones del catálogo de Plusyc Live a partir de su archivo de audio y reducir la dependencia de servicios de terceros.			

Característica	Definición	Ejemplos	Tipo de problema
Key	Tonalidad estimada de la pista mapeada a números enteros (Pitch Class).	0 (Do), 1 (Do#), 2 (Re)	Clasificación

1.3.2. Objetivos específicos

Para alcanzar el objetivo general, se definen los siguientes pasos metodológicos:

Característica	Definición	Ejemplos	Tipo de problema
Mode	Modalidad (mayor o menor) del contenido melódico.	1 (Mayor), 0 (Menor)	Clasificación
Tempo	Tempo del aprendizaje por supervisión.	120 BPM, 85 BPM	Regresión
Loudness	Volumen global promedio en decibeles (dB).	-5.2 dB, -12.4 dB	Regresión
Perceptibles	Ejecutar el análisis exploratorio de datos (EDA) y el preprocesamiento de las variables.		

Característica	Definición	Ejemplos	Tipo de problema
Acousticness	Confianza de que la pista es acústica (0.0 a 1.0).	0.95, 0.10	Regresión

Característica	Definición	Ejemplos	Tipo de problema
Danceability	Capacidad de ser bailable según tiempo y ritmo (0.0 a 1.0).	0.85, 0.20	Regresión

Característica	Definición	Ejemplos	Tipo de problema
Energy	Medida de intensidad y actividad (0.0 a 1.0).	0.90	Regresión

Característica	Definición	Ejemplos	Tipo de problema
Instrumentalness	Probabilidad de ausencia de contenido vocal (0.0 a 1.0).	0.90 (sin voz), 0.05 (cantada)	Regresión

Característica	Definición	Ejemplos	Tipo de problema
Liveness	Confianza de grabación con público en vivo (0.0 a 1.0).	0.85 (concierto), 0.10 (estudio)	Regresión

Característica	Definición	Ejemplos	Tipo de problema
Speechiness	Presencia de voz en la pista (0.0 a 1.0).	0.5 (rap), 0.05 (música)	Regresión

Característica	Definición	Ejemplos	Tipo de problema
Valence	Positividad musical transmitida (0.0 a 1.0).	0.90, 0.10	Regresión

1.3.3. Alcance

El alcance de este trabajo comprende la predicción computacional de trece características musicales, que se agrupan en tres categorías principales:

Característica	Definición	Ejemplos	Tipo de problema
Primary Mood	Estados de ánimo predominantes (primary moods), estados de ánimo secundarios (secondary moods) y géneros sugeridos (suggested genres).	Empowering, Euphoric, Energetic, Anxious	Clasificación

Característica	Definición	Ejemplos	Tipo de problema
Suggested Genres	Género musical sugerido.	Chill House, EDM	Clasificación

Para cada una de las características mencionadas se aplican los pasos mencionados en los objetivos específicos. El detalle técnico, las definiciones formales y el modelado de cada característica como problema de clasificación o regresión se abordan en el transcurso de la presente memoria.

1.4. Estado del arte

El presente trabajo incluye los siguientes pasos para todas las características musicales:

- Análisis y elección de un conjunto de datos musical para modelos de aprendizaje supervisado y aprendizaje profundo.
- Representaciones musicales de las canciones.
- EDA (Análisis Exploratorio de Datos) y preprocesamiento.

- Selección de variables de entrada relevantes para el modelado.

1.4.1. Procesamiento digital de señales y extracción a bajo nivel

Existen bibliotecas de software para extraer descriptores numéricos de bajo nivel, como Librosa [3] y Essentia [4].

- Evaluación de los modelos.

Las bibliotecas de procesamiento digital de señales proveen funciones para representar la señal digital en arreglos numéricos, como espectrogramas y cromagramas. Este tipo de transformaciones matemáticas son útiles para reducir la dimensionalidad de los archivos de audio y generar variables predictivas para modelos de aprendizaje automático.

- Asignación del subconjunto de otras características que no requieren de inteligencia artificial para su solución.

1.4.2. Modelos preentrenados y soluciones comerciales

Para la predicción de características de alto nivel existen modelos de código abierto basados en aprendizaje profundo. Dos ejemplos son la arquitectura musicnn [5] y los modelos entrenados sobre el conjunto de datos AudioSet [6]. Estos sistemas clasifican etiquetas musicales generales. Su limitación principal radica en el uso de taxonomías fijas orientadas a los datos con los que fueron entrenados originalmente.

1.4. Estado del arte

La biblioteca Essentia también incorpora modelos preentrenados para inferir atributos semánticos, y por lo tanto se incluye en esta categoría. Las herramientas computacionales para el análisis de audio, como bibliotecas de procesamiento digital de señales que extraen representaciones numéricas a partir de archivos de audio, la modalidad de software como servicio (SaaS) y entregan predicciones mediante su interfaz de programación de aplicaciones (API). La gran desventaja es que introducen costos operativos recurrentes y generan dependencia tecnológica hacia el proveedor.

1.4.1. Procesamiento digital de señales y extracción a bajo nivel

También existen plataformas web que permiten consultar esta información de manera individual. Un ejemplo es Tunebat [9], que permite visualizar un conjunto de características [4], pero restringe la consulta a una canción a la vez. Se presenta un ejemplo en la figura 1.1.

Estas bibliotecas ayudan a representar la señal digital en arreglos numéricos, como espectrogramas.

1.4.3. Síntesis comparativa

1.4.2. Modelos preentrenados y soluciones comerciales

Las tecnologías existentes ofrecen herramientas útiles para el objetivo del trabajo. Para la predicción de características de alto nivel existen modelos de código abierto basados en aprendizaje profundo. Dos ejemplos son la arquitectura musicnn [6] y los modelos entrenados sobre el conjunto de datos AudioSet [7]. Estos sistemas clasifican etiquetas musicales generales. Su limitación principal radica en el uso de taxonomías fijas orientadas a los datos con los que fueron entrenados. Esencia también incorpora modelos preentrenados para inferir atributos semánticos, y por lo tanto entra en esta categoría.

Sin embargo, persisten limitaciones operativas para su aplicación directa en el entorno de la empresa. Los servicios de terceros generan costos recurrentes, limitan la cantidad de consultas y crean dependencia tecnológica. Las plataformas web

der uso manual no son viables para procesar catálogos con miles de canciones. Además, los modelos no coinciden con las características y las clases específicas que usa Plusyc Live. Introducen costos operativos recurrentes y generan dependencia tecnológica hacia el proveedor. También existen plataformas web que permiten consultar esta información de manera individual. Un ejemplo es Tunebat [9], que permite visualizar un conjunto de características, pero solo permite consultar una canción a la vez. Se presenta un ejemplo en la Figura 1.1. Por estos motivos, resulta necesario desarrollar una solución propia. El propósito de este trabajo es aprovechar las técnicas actuales de inteligencia artificial para crear un sistema independiente. Esto permite analizar directamente los archivos de audio y etiquetarlos según las necesidades de la empresa, lo cual elimina de forma definitiva la dependencia de proveedores externos.



FIGURA 1.1. Ejemplo de visualización de características musicales en Tunebat [9].

FIGURA 1.1. Ejemplo de visualización de características musicales en Tunebat ¹.

1.5. Estructura del documento

La presente memoria se estructura en los siguientes capítulos:

En el Capítulo 2 se introducen las herramientas de terceros y las tecnologías necesarias para el desarrollo del sistema. Se describe la fuente de datos principal, las técnicas para extraer representaciones numéricas del audio, los modelos de aprendizaje automático seleccionados y las tecnologías para el despliegue.

En el Capítulo 3 se detalla el desarrollo del trabajo. Se documenta la evaluación y selección de los conjuntos de datos. Se analizan las distribuciones de las variables objetivo y las estrategias de muestreo. Asimismo, se describen las técnicas de selección y reducción de variables de entrada para el uso de una arquitectura

¹Imagen tomada de <https://tunebat.com/Info/Weird-Fishes-Arpeggi-Radiohead/4wajj1o7jWIg62YqpkHC75>

mixta. Luego, se explica el proceso de modelado y la búsqueda de hiperparámetros. Finalmente, se presentan los resultados generales de la iteración productiva y la arquitectura para el despliegue del sistema.

Capítulo 2

En el Capítulo 4 se presentan los resultados obtenidos. Se evalúa el desempeño de los distintos modelos entrenados y se justifica la selección final de los algoritmos para su paso a producción.

Introducción específica

Finalmente, en el Capítulo 5 se exponen las conclusiones generales del proyecto, el cumplimiento de los objetivos propuestos y las posibles líneas de trabajo futuro para mejorar el sistema implementado.

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

2.1. Estilo y convenciones

2.1.1. Uso de mayúscula inicial para los título de secciones

Si en el texto se hace alusión a diferentes partes del trabajo referirse a ellas como capítulo, sección o subsección según corresponda. Por ejemplo: “En el capítulo 1 se explica tal cosa”, o “En la sección 2.1 se presenta lo que sea”, o “En la subsección 2.1.2 se discute otra cosa”.

Cuando se quiere poner una lista tabulada, se hace así:

- Este es el primer elemento de la lista.
- Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

Si se desea poner una lista numerada el formato es este:

1. Este es el primer elemento de la lista.
2. Este es el segundo elemento de la lista.

Notar el uso de las mayúsculas y el punto al final de cada elemento.

2.1.2. Este es el título de una subsección

Se recomienda no utilizar **texto en negritas** en ningún párrafo, ni tampoco texto subrayado. En cambio sí se debe utilizar *texto en itálicas* para palabras en un idioma extranjero, al menos la primera vez que aparecen en el texto. En el caso de palabras que estamos inventando se deben utilizar “comillas”, así como también para citas textuales. Por ejemplo, un *digital filter* es una especie de “selector” que permite separar ciertos componentes armónicos en particular.

La escritura debe ser impersonal. Por ejemplo, no utilizar “el diseño del firmware lo hice de acuerdo con tal principio”, sino “el firmware fue diseñado utilizando tal principio”.

El trabajo es algo que al momento de escribir la memoria se supone que ya está concluido, entonces todo lo que se refiera a hacer el trabajo se narra en tiempo pasado, porque es algo que ya ocurrió. Por ejemplo, "se diseñó el firmware empleando la técnica de test driven development".

En cambio, la memoria es algo que está vivo cada vez que el lector la lee. Por eso transcurre siempre en tiempo presente, como por ejemplo:

"En el presente capítulo se da una visión global sobre las distintas pruebas realizadas y los resultados obtenidos. Se explica el modo en que fueron llevados a cabo los test unitarios y las pruebas del sistema".

Se recomienda no utilizar una sección de glosario sino colocar la descripción de las abreviaturas como parte del mismo cuerpo del texto. Por ejemplo, RTOS (*Real Time Operating System*, Sistema Operativo de Tiempo Real) o en caso de considerarlo apropiado mediante notas a pie de página.

Si se desea indicar alguna página web utilizar el siguiente formato de referencias bibliográficas, dónde las referencias se detallan en la sección de bibliografía de la memoria, utilizando el formato establecido por IEEE en [10]. Por ejemplo, "el presente trabajo se basa en la plataforma EDU-CIAA-NXP [11], la cual...".

2.1.3. Figuras

Al insertar figuras en la memoria se deben considerar determinadas pautas. Para empezar, usar siempre tipografía claramente legible. Luego, tener claro que **es incorrecto** escribir por ejemplo esto: "El diseño elegido es un cuadrado, como se ve en la siguiente figura:"



La forma correcta de utilizar una figura es con referencias cruzadas, por ejemplo: "Se eligió utilizar un cuadrado azul para el logo, como puede observarse en la figura 2.1".



FIGURA 2.1. Ilustración del cuadrado azul que se eligió para el diseño del logo.

El texto de las figuras debe estar siempre en español, excepto que se decida reproducir una figura original tomada de alguna referencia. En ese caso la referencia de la cual se tomó la figura debe ser indicada en el epígrafe de la figura e incluida como una nota al pie, como se ilustra en la figura 2.2.

Capítulo 2



FIGURA 2.2. Imagen tomada de la página oficial del procesador¹.

Introducción específica

La figura y el epígrafe deben conformar una unidad cuyo significado principal pueda ser comprendido por el lector sin necesidad de leer el cuerpo central de la memoria. Para eso es necesario que el epígrafe sea todo lo detallado que corresponda y si en la figura se utilizan abreviaturas entonces aclarar su significado en el epígrafe o en la misma figura.

Este capítulo introduce las herramientas de terceros y las tecnologías necesarias para el desarrollo del sistema. Se describe la fuente de datos principal, las técnicas para extraer representaciones numéricas del audio, los modelos predictivos y las tecnologías utilizadas para el despliegue.

2.1. Fuentes de datos de canciones

Para el entrenamiento de los modelos predictivos se utilizó la colección privada de canciones de la empresa. Esta fuente de datos cuenta con más de 60 000 archivos de audio de canciones completas.

Nunca colocar una figura en el documento antes de hacer la primera referencia a ella. Se seleccionó este conjunto de datos por la disponibilidad en el acceso a la información y por su representatividad en ambientes comerciales reales. Por el contrario, otros conjuntos de datos públicos musicales, como GTZAN [10] y los subconjuntos estándar de FMA [11], ofrecen fragmentos limitados a 10 o 30 segundos de audio. El uso de pistas incompletas restringe la disponibilidad de la información musical. Realizar predicciones sobre el audio total resulta más preciso, ya que evita la pérdida de los eventos musicales que ocurren antes o después de una sola ventana. Además, estas alternativas carecen parcialmente de las variables objetivas requeridas en el alcance del trabajo.

El acceso a los archivos de audio de canciones completas garantiza la preservación de la estructura musical, evita la pérdida de información y flexibiliza la extracción de representaciones matemáticas mediante el uso de bibliotecas y modelos preentrenados.

El análisis comparativo de las fuentes de datos, las representaciones estadísticas de las canciones y los criterios de selección de variables predictivas se detallan en el Capítulo 3.

El código para generar las imágenes se encuentra disponible para su reutilización en el archivo `Chapter2.tex`.

2.2. Representaciones numéricas de la música

Una canción se traduce a un formato numérico para su procesamiento computacional. El procesamiento digital de señales (DSP) transforma la onda sonora en arreglos matemáticos de una o dos dimensiones. Entre las representaciones bidimensionales más destacadas se encuentran el espectrograma, el cromagrama y el espacio armónico o *tonnetz*. El espectrograma refleja la variación de las frecuencias a lo largo del tiempo. Por su parte, el cromagrama captura la energía asociada a las doce clases de notas musicales. Finalmente, el *tonnetz* modela las relaciones

tonales y armónicas de la pista. A modo de ejemplo, en la figura 2.1 se ilustran estas tres transformaciones aplicadas a un fragmento de la canción “Weird Fishes/Arpeggi” de la banda Radiohead.




FIGURA 2.1. Representación visual de un espectrograma, un cromagrama y un tonnetz.

Para generar la ecuación 2.1 se utilizó el siguiente código:

```
\begin{equation}
\label{eq:metric}
ds^2 = c^2 dt^2 \left( \frac{d\sigma^2}{1 - k\sigma^2} + \sigma^2 [d\theta^2 + \sin^2 \theta d\phi^2] \right) +
\sigma^2 \left[ d\theta^2 + \sin^2 \theta d\phi^2 \right]
```

Además de las representaciones bidimensionales, las bibliotecas de procesamiento de señales facilitan la extracción de atributos numéricos unidimensionales. En la tabla 2.1 se presenta un listado que introduce algunas de las características de bajo nivel más representativas en el análisis musical.

En la elaboración del trabajo se usaron Librossa y Essentia en este proceso.

Estas transformaciones matemáticas reducen la dimensionalidad del archivo de audio. Sin embargo, carecen de significado semántico. Su función principal, en el

TABLA 2.1. Listado introductorio de los principales atributos de procesamiento de señales extraídos del audio.

Atributo	Descripción principal
MFCC	Coefficientes cepstrales que modelan la percepción auditiva humana.
Centroide espectral	Indica el centro de masa del espectro acústico. Se asocia al brillo del sonido.
Ancho de banda	Mide la dispersión de las frecuencias alrededor del centroide espectral.
Tasa de cruces por cero	Cuantifica la cantidad de cambios de signo en la señal temporal.
Rolloff espectral	Estima la frecuencia por debajo de la cual se concentra la mayor parte de la energía.

contexto de este trabajo, es la de generar las variables predictivas necesarias para entrenar modelos de aprendizaje automático.

El listado completo de las variables de entrada, el análisis de su relevancia y su impacto en el rendimiento de los algoritmos se detalla en el Capítulo 3.

Se puede agregar código o pseudocódigo dentro de un entorno `lstlisting` con el siguiente código:

2.3. Información semántica del audio

Las representaciones de bajo nivel descritas en la sección anterior no siempre son suficientes para capturar conceptos musicales complejos. Es posible mejorar la cobertura de la información musical con el aprendizaje por transferencia. Esta técnica consiste en utilizar modelos previamente entrenados con grandes volúmenes de datos para extraer características semánticas de alto nivel.

Para este fin existen bibliotecas especializadas, como PANNs Inference. Esta herramienta provee acceso a redes neuronales optimizadas para el análisis de eventos sonoros. Dentro de sus opciones, destaca la arquitectura denominada CNN14 [12]. Se trata de una red neuronal convolucional, capaz de abstraer patrones del audio y generar *embeddings* numéricos basados en las clases del conjunto de datos AudioSet.

Un ejemplo de las probabilidades de detección obtenidas para distintas clases de eventos sonoros a lo largo del tiempo se visualizan en la figura 2.2, donde se muestran ventanas consecutivas de 10 segundos de la canción de Radiohead.

El uso de esta arquitectura permite transformar la onda sonora para extraer *embeddings* y obtener probabilidades asociadas a etiquetas predefinidas, como la presencia de aplausos, instrumentos musicales específicos o habla. Estos datos semánticos enriquecen el conjunto de variables de entrada para la inferencia de algunas de las características musicales que se definieron en el alcance del trabajo.

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
Las líneas de código irían aquí...
\end{lstlisting}

A modo de ejemplo, se muestra el fragmento de código 3.1.

1 int32_t sensorValue[MAX_SENSOR_NUMBER];
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ALARM_DURATION 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
8 state_t gestureState[MAX_ALARM_NUMBER]; //ON or OFF
9 AudioSet.
10 void vControl() {
11     // Ejemplo de las probabilidades de detección obtenidas para distintas clases
12     // de eventos sonoros a lo largo del tiempo se visualizan en la figura 2.2, donde se
13     // muestran ventanas consecutivas de 10 segundos de la canción de Radiohead.
14     period = 500 ms;
15
16     El uso de esta arquitectura permite transformar la onda sonora para extraer em-
17     beddings y obtener probabilidades asociadas a etiquetas predefinidas, como la
18     presencia de aplausos, instrumentos musicales específicos o habla. Estos datos
19     semánticos enriquecen el conjunto de variables de entrada para la inferencia de
20     algunas de las características musicales que se definieron en el alcance del trabajo.
21
22     updateAlarms();
23
24     controlActuators();
25
26     vTaskDelayUntil(&ticks, period);
27 }
```

28 }




FIGURA 2.2. Mapa de calor de las características de alto nivel extraídas mediante la red CNN14. Las áreas más claras indican una mayor probabilidad de activación para cada clase.

2.4. Modelos de inteligencia artificial utilizados

Una vez obtenidos los descriptores numéricos y semánticos, es necesario aplicar algoritmos de predicción. Para este fin, se utilizaron dos enfoques principales:

- Algoritmos LightGBM: Se integró la arquitectura LightGBM, basada en el ensamble de árboles de decisión. Esta herramienta destaca por su alta velocidad computacional y eficiencia en tareas generales de predicción.
- Redes MLP: Los perceptrones multicapa son redes neuronales artificiales con capacidad para modelar relaciones complejas. Permiten, entre otras aplicaciones, predecir múltiples variables continuas de forma simultánea.

2.5. Despliegue e integración

La integración del sistema predictivo requirió del despliegue de una interfaz de programación de aplicaciones. Para su construcción se utilizó FastAPI como marco de trabajo. Esta herramienta facilita el desarrollo de servicios web de alto rendimiento basados en Python.

El alojamiento remoto del producto se apoyó en los servicios de infraestructura de Oracle Cloud Infrastructure (OCI). Se provisionó una instancia de cómputo virtual en la nube para desplegar la aplicación y ejecutar los modelos predictivos. El uso de esta tecnología garantiza la disponibilidad continua del sistema.

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos. Se puede agregar código o pseudocódigo dentro de un entorno `lstlisting` con el siguiente código:

```
Algunas preguntas que pueden servir para completar este capítulo
\begin{lstlisting}[caption="Un epígrafe descriptivo"]
    las líneas de código irían aquí
\end{lstlisting}
```

■ ¿Cuál es el grado de cumplimiento de los requerimientos?
■ ¿Cuán fielmente se puede seguir la planificación original (cronograma incluido)?

A modo de ejemplo, se muestra el fragmento de código 3.1:

```
1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ACTUATOR_NUMBER 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
8 state_t actuatorState[MAX_ACTUATOR_NUMBER]; //ON or OFF
9
10 void vControl() {
11     // ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?
12     initGlobalVariables();
13
14     period = 500 ms;
15
16     vTaskDelay(1);
17
18     ticks = xTaskGetTickCount();
19
20     updateSensors();
21
22     updateAlarms();
23
24     controlActuators();
25
26     vTaskDelayUntil(&ticks, period);
27 }
```

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

```
17
18     ticks = xTaskGetTickCount();
19
20     updateSensors();
21
22     updateAlarms();
23
24     controlActuators();
25
26     vTaskDelayUntil(&ticks, period);
27 }
```

28 }

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Bibliografía

Ensayos y resultados

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

- [4] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20, 2015. URL: <https://librosa.org/>.

4.1. Pruebas funcionales del hardware

- [5] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.
- [6] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [7] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [8] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [9] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- [10] IEEE. *IEEE Citation Reference*. 1.^a ed. IEEE Publications, 2016. URL: <http://www.ieee.org/documents/ieeecitationref.pdf> (visitado 26-09-2016).
- [11] Proyecto CIAA. *Computadora Industrial Abierta Argentina*. Visitado el 2016-06-25. 2014. URL: <http://proyecto-ciaa.com.ar/devwiki/doku.php?id=start>.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20. 2015. URL: <https://librosa.org/>.
- [4] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- [5] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [6] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [7] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [8] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [9] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- [10] George Tzanetakis y Perry Cook. «Musical genre classification of audio signals». En: *IEEE Transactions on Speech and Audio Processing* (2002).
- [11] Michaël Defferrard et al. «FMA: A Dataset for Music Analysis». En: *18th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.
- [12] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).