

Índice general

Resumen	I
1. Introducción general	1
1.1. Extracción de información musical	1
1.2. Contexto de aplicación	1
1.3. Objetivos y alcance	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.3.3. Alcance	2
1.4. Estado del arte	3
1.4.1. Procesamiento digital de señales y extracción a bajo nivel	3
1.4.2. Modelos preentrenados y soluciones comerciales	3
1.4.3. Síntesis comparativa	3
1.5. Estructura del documento	4
2. Introducción específica	5
2.1. Fuentes de datos de canciones	5
2.2. Representaciones numéricas de la música	5
2.3. Representación semántica de la música	7
2.4. Modelos de inteligencia artificial utilizados	8
2.5. Despliegue e integración artificial utilizados	18
2.5. Despliegue e integración	11
3. Diseño e implementación	11
3.1. Conjuntos de datos	13
3.1.1. Análisis de conjuntos de datos públicos	11
GTZAN	11
4. Ensayos y resultados	12
4.1. Pruebas funcionales del hardware	12
Million Song Dataset (MSD)	12
AudioSet	13
5. Conclusiones	13
5.1. Conclusiones generales	13
5.2. Próximos pasos	15
3.2. Ejecución de tareas sobre el conjunto de datos	15
3.3. Selección de variables de entrada	15
Bibliografía	19
3.4. Modelado y optimización	15
3.5. Iteración productiva	15
3.6. Arquitectura de despliegue e integración	15
4. Ensayos y resultados	17
4.1. Pruebas funcionales del hardware	17
5. Conclusiones	19
5.1. Conclusiones generales	19
5.2. Próximos pasos	19

Índice de figuras

1.1. Interfaz de consulta en Tunebat	4
2.1. Representaciones visuales del audio	6
2.2. Probabilidades de detección semántica	18

Índice de tablas

2.1. Atributos representativos	7
--	---

Capítulo 1

Introducción general

En este capítulo se introduce la definición de la extracción de información musical, se expone la problemática que motivó la búsqueda de una solución automatizada para la asignación de características musicales a partir del audio de canciones, y se detalla el alcance de la solución propuesta. Finalmente, se realiza una revisión general de las soluciones existentes.

1.1. Extracción de información musical

La extracción de información musical, comúnmente conocida como MIR (por su sigla en inglés, *Music Information Retrieval*), procesa, analiza y organiza datos musicales [1].

Los sistemas MIR abarcan el procesamiento digital de señales (DSP) y el aprendizaje automático, y permiten automatizar tareas como el etiquetado de canciones, la clasificación de géneros o el reconocimiento de estados de ánimo a partir del audio digital [2].

1.2. Contexto de aplicación

El trabajo se realiza para dar respuesta a una necesidad tecnológica de Plusyc Live SAS [3], una empresa dedicada a la creación de experiencias musicales personalizadas para locales comerciales. La plataforma de la compañía crea listas de reproducción basadas en las características musicales de un catálogo de canciones.

Anteriormente, la asignación de estas características dependía del consumo de interfaces de programación de aplicaciones (API) de terceros. Esta metodología generaba restricciones de disponibilidad, incrementos en los costos operativos y limitaba la autonomía de la empresa.

Con la implementación de este trabajo, la empresa cuenta con un sistema de inteligencia artificial que caracteriza automáticamente canciones a partir de su archivo de audio. Esto reduce la dependencia de servicios externos y mejora la escalabilidad y autonomía de la aplicación; de esta manera se fortalece la experiencia musical personalizada que la empresa ofrece a los comercios.

1.3. Objetivos y alcance

Esta sección define las metas. Se presenta el objetivo general y los objetivos específicos, y el conjunto de características musicales consideradas.

1.3.1. Objetivo general

1.3.1. Objetivo general

Desarrollar un sistema basado en inteligencia artificial para predecir las características musicales de las canciones del catálogo de Plusyc Live a partir de su archivo de audio y reducir la dependencia de servicios de terceros a partir de su archivo de audio y reducir la dependencia de servicios de terceros.

1.3.2. Objetivos específicos

1.3.2. Objetivos específicos

Para alcanzar el objetivo general, se definen los siguientes objetivos específicos:

Para alcanzar el objetivo general, se definen los siguientes pasos metodológicos:

- Seleccionar y analizar un conjunto de datos musicales pertinente para el entrenamiento de modelos de aprendizaje supervisado.
- Extraer representaciones numéricas y descriptores semánticos a partir de las señales de audio originales.
- Ejecutar el análisis exploratorio de datos (EDA) y el preprocesamiento de las variables.
- Entrenar modelos de aprendizaje supervisado para la predicción de las características objetivo.
- Evaluar el rendimiento de los modelos y seleccionar los de mejor desempeño.
- Desplegar los modelos en un entorno productivo para su integración operativa.

1.3.3. Alcance

1.3.3. Alcance

El alcance de este trabajo comprende la predicción computacional de trece características musicales, que se agrupan en tres categorías principales:

- Básicas: tonalidad (key), modo (mode), tempo y volumen (loudness).
- Perceptibles: nivel acústico (acousticness), bailabilidad (danceability), energía (energy), instrumentalidad (instrumentalness), presencia de público (liveness), presencia de voz (speechiness) y positividad (valence).
- Clasificables por ánimo y género: estados de ánimo predominantes (primary moods), estados de ánimo secundarios (secondary moods) y géneros sugeridos (suggested genres).

Para cada una de las características mencionadas se busca cumplir con los objetivos específicos definidos. Para cada característica mencionada se aplican los pasos mencionados en los objetivos específicos.

El detalle técnico, las definiciones formales y el modelado de cada característica como problema de clasificación o regresión se abordan en el transcurso de la presente memoria.

1.4. Estado del arte

En el campo de la extracción de información musical existen diversas herramientas computacionales para el análisis de audio. Por un lado, se encuentran las bibliotecas de procesamiento digital de señales, que permiten extraer representaciones numéricas a partir de archivos de audio. Además, existen modelos preentrenados capaces de obtener información semántica y servicios comerciales orientados a inferir etiquetas de alto nivel.

1.4.1. Procesamiento digital de señales y extracción a bajo nivel

Existen bibliotecas de software para extraer descriptores numéricos de bajo nivel, como Librosa [3] y Essentia [5].

Las bibliotecas de procesamiento digital de señales proveen funciones para representar la señal digital en arreglos numéricos, como espectrogramas y cromagramas. Este tipo de transformaciones matemáticas son útiles para reducir la dimensionalidad de los archivos de audio y generar variables predictivas para modelos de aprendizaje automático.

1.4.2. Modelos preentrenados y soluciones comerciales

Para la predicción de características semánticas existen modelos de código abierto basados en aprendizaje profundo. Dos ejemplos son la arquitectura musicnn [6] y los modelos entrenados sobre el conjunto de datos AudioSet [7]. Estos sistemas clasifican etiquetas musicales generales. Su limitación principal radica en el uso de taxonomías fijas orientadas a los datos con los que fueron entrenados originalmente. La biblioteca Essentia también incorpora modelos preentrenados para inferir atributos semánticos, y por lo tanto se incluye en esta categoría.

La biblioteca Essentia también incorpora modelos preentrenados para inferir atributos semánticos. Por su parte, soluciones comerciales como Spotify [8] y Gracenote [9] operan en la modalidad de software como servicio (SaaS) y entregan predicciones mediante su interfaz de programación de aplicaciones (API). La gran desventaja es que introducen costos operativos recurrentes y generan dependencia tecnológica hacia el proveedor.

También existen plataformas web que permiten consultar esta información de manera individual. Un ejemplo es Tunebat [10], que permite visualizar un conjunto de características, pero restringe la consulta a una canción a la vez. En la figura 1.1 se presenta un ejemplo de la plataforma web Tunebat.

1.4.3. Síntesis comparativa

Las tecnologías existentes ofrecen herramientas útiles para el objetivo del trabajo.

Las bibliotecas de procesamiento digital de señales permiten extraer representaciones numéricas de las ondas sonoras, y los modelos preentrenados ofrecen representaciones semánticas. Por otro lado, las soluciones comerciales proveen servicios de etiquetado para canciones.

Sin embargo, persisten limitaciones operativas para su aplicación directa en el entorno de la empresa. Los servicios de terceros generan costos recurrentes, limitan la cantidad de consultas y crean dependencia tecnológica. Las plataformas web de uso manual no son viables para procesar catálogos con miles de canciones. La cantidad de consultas y crean dependencia tecnológica. Las plataformas web

Además, los modelos no coinciden con las características y las clases específicas que usa Plusyc Live. Por estos motivos, resulta necesario desarrollar una solución propia. El propósito de este trabajo es, aprovechar las técnicas actuales de inteligencia artificial para crear un sistema independiente. Esto permite analizar directamente los archivos de audio, etiquetarlos según las necesidades de la empresa y así reducir la dependencia de proveedores externos. Esto permite analizar directamente los archivos de audio, etiquetarlos según las necesidades de la empresa, lo cual elimina de forma definitiva la dependencia de proveedores externos.



FIGURA 1.1. Ejemplo de visualización de características musicales en Tunebat¹.

1.5. Estructura del documento

La presente memoria se estructura en los siguientes capítulos:

En el Capítulo 2 se introducen las herramientas de terceros y las tecnologías necesarias para el desarrollo del sistema. Se describe la fuente de datos principal, las técnicas para extraer representaciones numéricas del audio, los modelos de aprendizaje automático seleccionados y las tecnologías para el despliegue.

En el Capítulo 3 se detalla el desarrollo del trabajo. Se documenta la evaluación y selección de los conjuntos de datos. Se analizan las distribuciones de las variables objetivo y las estrategias de muestreo. Asimismo, se describen las técnicas de selección y reducción de variables de entrada para el uso de una arquitectura

¹Imagen tomada de <https://tunebat.com/Info/Weird-Fishes-Arpeggi-Radiohead/4wajj1o7jWlg62YqpkHC7S>

¹Imagen tomada de <https://tunebat.com/Info/Weird-Fishes-Arpeggi-Radiohead/4wajj1o7jWlg62YqpkHC7S>

mixta. Luego, se explica el proceso de modelado y la búsqueda de hiperparámetros. Finalmente, se presentan los resultados generales de la iteración productiva y la arquitectura para el despliegue del sistema.

Capítulo 2

En el Capítulo 4 se presentan los resultados obtenidos. Se evalúa el desempeño de los distintos modelos entrenados y se justifica la selección final de los algoritmos para su paso a producción.

Introducción específica

Finalmente, en el Capítulo 5 se exponen las conclusiones generales del proyecto, el cumplimiento de los objetivos propuestos y las posibles líneas de trabajo futuro para mejorar el sistema implementado.

Este capítulo introduce las herramientas de terceros y las tecnologías necesarias para el desarrollo del sistema. Se describe la fuente de datos principal, las técnicas para extraer representaciones numéricas del audio, los modelos predictivos y las tecnologías utilizadas para el despliegue.

2.1. Fuentes de datos de canciones

Para el entrenamiento de los modelos predictivos se utilizó la colección privada de canciones de la empresa. Esta fuente de datos cuenta con más de 60 000 archivos de audio de canciones completas.

Se seleccionó este conjunto de datos por la disponibilidad en el acceso a la información y por su representatividad en ambientes comerciales reales. Por el contrario, otros conjuntos de datos públicos musicales, como GTZAN [11] y los subconjuntos estándar de FMA [12], ofrecen fragmentos limitados a 10 o 30 segundos de audio. El uso de pistas incompletas restringe la disponibilidad de la información musical. Realizar predicciones sobre el audio total resulta más preciso, ya que evita la pérdida de los eventos musicales que ocurren antes o después de una sola ventana. Además, estas alternativas carecen parcialmente de las variables objetivo requeridas en el alcance del trabajo.

El acceso a los archivos de audio de canciones completas garantiza la preservación de la estructura musical, evita la pérdida de información y flexibiliza la extracción de representaciones matemáticas mediante el uso de bibliotecas y modelos preentrenados.

El análisis comparativo de las fuentes de datos, las representaciones estadísticas de las canciones y los criterios de selección de variables predictivas se detallan en la sección 3.1 del siguiente capítulo.

2.2. Representaciones numéricas de la música

Una canción se traduce a un formato numérico para su procesamiento computacional. El procesamiento digital de señales (DSP) transforma la onda sonora en arreglos matemáticos de una o dos dimensiones. Entre las representaciones bidimensionales más destacadas se encuentran el espectrograma, el cromagrama y el espacio armónico o tonnetz. El espectrograma refleja la variación de las frecuencias a lo largo del tiempo. Por su parte, el cromagrama captura la energía asociada a las doce clases de notas musicales. Finalmente, el tonnetz modela las relaciones

tonales y armónicas de la pista. A modo de ejemplo, en la figura 2.1 se ilustran estas tres transformaciones aplicadas a un fragmento de la canción “Weird Fishes/ Arpeggi” de la banda Radiohead. En estos gráficos, el eje horizontal representa el tiempo, mientras que la intensidad del color indica la magnitud de la energía para las distintas frecuencias, notas musicales o relaciones tonales correspondientes a cada eje vertical.




FIGURA 2.1. Representación visual de un espectrograma, un cromagrama y un tonnetz.

Además de las representaciones bidimensionales, las bibliotecas de procesamiento de señales facilitan la extracción de atributos numéricos unidimensionales. En la tabla 2.1 se presenta un listado que introduce algunas de las características de bajo nivel más representativas en el análisis musical. En la elaboración del trabajo se usaron Librosa y Essentia en este proceso.

Estas transformaciones matemáticas reducen la dimensionalidad del archivo de audio. Sin embargo, carecen de significado semántico. Su función principal, en el

contexto de este trabajo, es la de generar las variables predictivas necesarias para entrenar modelos de aprendizaje automático.

El listado completo de las variables de entrada, el análisis de su relevancia y su impacto en el rendimiento de los algoritmos se detalla en la sección 3.3.

TABLA 2.1. Listado introductorio de los principales atributos de procesamiento de señales extraídos del audio.

Atributo	Descripción principal
MFCC	Coefficientes cepstrales que modelan la percepción auditiva humana.
Centroíde espectral	Indica el centro de masa del espectro acústico. Se asocia al brillo del sonido.
Ancho de banda	Mide la dispersión de las frecuencias alrededor del centroíde espectral.
Tasa de cruces por cero	Cuantifica la cantidad de cambios de signo en la señal temporal.
Rolloff espectral	Estima la frecuencia por debajo de la que se concentra la mayor parte de la energía.

Este capítulo introduce las herramientas de terceros y las tecnologías necesarias para el desarrollo del sistema. Se describe la fuente de datos principal, las técnicas para extraer representaciones numéricas del audio, los modelos predictivos y las tecnologías utilizadas para el despliegue.

Para el entrenamiento de los modelos predictivos se utilizó la colección privada de canciones de la empresa. Esta fuente de datos cuenta con más de 60 000 archivos de audio de canciones completas.

2.3. Información semántica del audio

La selección entre los distintos tipos de datos depende de la disponibilidad en el acceso a la información y por su representatividad en ambientes comerciales reales. Por el contrario, las representaciones de bajo nivel descritas en la sección 2.2 no siempre son suficientes para capturar conceptos musicales complejos. Es posible mejorar la cobertura de la información musical con el aprendizaje por transferencia. Esta técnica consiste en utilizar modelos previamente entrenados con grandes volúmenes de datos para extraer características semánticas de alto nivel, antes o después de una sola ventana. Además, estas alternativas carecen parcialmente de las variables. Para este fin existen bibliotecas especializadas, como PANNs Inference. Esta herramienta provee acceso a redes neuronales optimizadas para el análisis de eventos sonoros. Dentro de sus opciones, destaca la arquitectura denominada CNN14 [10]. Se trata de una red neuronal convolucional, capaz de abstraer patrones del audio y generar embeddings numéricos basados en las clases del conjunto de datos AudioSet.

Un ejemplo de las probabilidades de detección obtenidas para distintas clases de eventos sonoros a lo largo del tiempo se visualiza en la figura 2.2, donde se muestran ventanas consecutivas de 10 segundos de la canción de Radiohead. En este mapa de calor, las áreas más claras indican una mayor probabilidad de activación para cada clase.

2.2. Representaciones numéricas de la música

El uso de esta arquitectura permite transformar la onda sonora para extraer embeddings y obtener probabilidades asociadas a etiquetas predefinidas, como la presencia de aplausos, instrumentos musicales específicos o habla. Estos datos semánticos enriquecen el conjunto de variables de entrada para la inferencia de algunas de las características musicales que se definieron en el alcance del trabajo: espacio armónico o *tonnetz*. El espectrograma refleja la variación de las frecuencias a lo largo del tiempo. Por su parte, el cromagrama captura la energía asociada a las doce clases de notas musicales. Finalmente, el *tonnetz* modela las relaciones

tonales y armónicas de la presencia de clases del AudioSet. En la figura 2.1 se ilustran estas tres transformaciones aplicadas a un fragmento de la canción "Weird Fishes/Arpeggi" de la banda Radiohead.




FIGURA 2.2. Mapa de calor de las características semánticas extraídas mediante la red CNN14.

2.4. Modelos de inteligencia artificial utilizados

Una vez obtenidos los descriptores numéricos y semánticos, es necesario aplicar algoritmos de predicción. Para este fin, se utilizaron dos enfoques principales:

- Algoritmos LightGBM: se integró la arquitectura LightGBM, basada en el ensamble de árboles de decisión. Esta herramienta destaca por su alta velocidad computacional y eficiencia en tareas generales de predicción.
- Redes MLP: los perceptrones multicapa son redes neuronales artificiales con capacidad para modelar relaciones complejas. Permiten, entre otras aplicaciones, predecir múltiples variables continuas de forma simultánea.

Además de las representaciones bidimensionales, las hipotesis de procesamiento de señales facilitan la extracción de atributos numéricos unidimensionales. En la tabla 2.1 se presenta un listado que introduce algunas de las características de bajo nivel más representativas en el análisis musical.

2.5. Despliegue e integración

En la elaboración del trabajo se usaron Librossa y Essentia en este proceso.

La integración del sistema predictivo requirió del despliegue de una interfaz de programación de aplicaciones. Para su construcción se utilizó FastAPI [14] como núcleo. Sin embargo, carecen de significado semántico. Su función principal, en el

marco de trabajo. Esta herramienta facilita el desarrollo de servicios web de alto rendimiento basados en Python [15].

El alojamiento remoto del producto se apoyó en los servicios de infraestructura de OCI (por su sigla en inglés, Oracle Cloud Infrastructure) [16]. Se provisionó una instancia de cómputo Virtual en la nube para desplegar la aplicación y ejecutar los modelos predictivos. El uso de esta tecnología garantiza la disponibilidad continua del sistema.

Atributo	Descripción principal
Centroide espectral	Indica el centro de masa del espectro acústico. Se asocia al brillo del sonido.
Ancho de banda	Mide la dispersión de las frecuencias alrededor del centroide espectral.
Tasa de cruces por cero	Cuantifica la cantidad de cambios de signo en la señal temporal.
Roloff espectral	Estima la frecuencia por debajo de la cual se concentra la mayor parte de la energía.

contexto de este trabajo, es la de generar las variables predictivas necesarias para entrenar modelos de aprendizaje automático.

El listado completo de las variables de entrada, el análisis de su relevancia y su impacto en el rendimiento de los algoritmos se detalla en el Capítulo 3.

2.3. Información semántica del audio

Las representaciones de bajo nivel descritas en la sección anterior no siempre son suficientes para capturar conceptos musicales complejos. Es posible mejorar la cobertura de la información musical con el aprendizaje por transferencia. Esta técnica consiste en utilizar modelos previamente entrenados con grandes volúmenes de datos para extraer características semánticas de alto nivel.

Para este fin existen bibliotecas especializadas, como PANNs Inference. Esta herramienta provee acceso a redes neuronales optimizadas para el análisis de eventos sonoros. Dentro de sus opciones, destaca la arquitectura denominada CNN14 [12]. Se trata de una red neuronal convolucional, capaz de abstraer patrones del audio y generar *embeddings* numéricos basados en las clases del conjunto de datos AudioSet.

Un ejemplo de las probabilidades de detección obtenidas para distintas clases de eventos sonoros a lo largo del tiempo se visualizan en la figura 2.2, donde se muestran ventanas consecutivas de 10 segundos de la canción de Radiohead.

El uso de esta arquitectura permite transformar la onda sonora para extraer *embeddings* y obtener probabilidades asociadas a etiquetas predefinidas, como la presencia de aplausos, instrumentos musicales específicos o habla. Estos datos semánticos enriquecen el conjunto de variables de entrada para la inferencia de algunas de las características musicales que se definieron en el alcance del trabajo.




FIGURA 2.2. Mapa de calor de las características de alto nivel extraídas mediante la red CNN14. Las áreas más claras indican una mayor probabilidad de activación para cada clase.

2.4. Modelos de inteligencia artificial utilizados

Una vez obtenidos los descriptores numéricos y semánticos, es necesario aplicar algoritmos de predicción. Para este fin, se utilizaron dos enfoques principales:

- **Algoritmos LightGBM:** Se integró la arquitectura LightGBM, basada en el ensamble de árboles de decisión. Esta herramienta destaca por su alta velocidad computacional y eficiencia en tareas generales de predicción.
- **Redes MLP:** Los perceptrones multicapa son redes neuronales artificiales con capacidad para modelar relaciones complejas. Permiten, entre otras aplicaciones, predecir múltiples variables continuas de forma simultánea.

2.5. Despliegue e integración

La integración del sistema predictivo requirió del despliegue de una interfaz de programación de aplicaciones. Para su construcción se utilizó FastAPI como marco de trabajo. Esta herramienta facilita el desarrollo de servicios web de alto rendimiento basados en Python.

El alojamiento remoto del producto se apoyó en los servicios de infraestructura de Google Cloud Infrastructure (GCP). Se provisionó una instancia de cómputo virtual en la nube para desplegar la aplicación y ejecutar los modelos predictivos. El uso de esta tecnología garantiza la disponibilidad continua del sistema.

Este capítulo detalla el diseño y la implementación del sistema predictivo. Se analizan los conjuntos de datos utilizados, la extracción de atributos del audio y el tratamiento de datos según las distribuciones de las variables objetivo. Asimismo, se describen las técnicas de reducción y selección de variables, el proceso de optimización de los modelos y los resultados de la iteración productiva. Finalmente, se presenta la arquitectura desarrollada para el despliegue y la integración del sistema en un entorno operativo.

3.1. Conjuntos de datos

3.1.1. Análisis de conjuntos de datos públicos

La definición de la estrategia para la extracción de atributos se fundamenta en una revisión de conjuntos de datos públicos estandarizados en el ámbito MIR. El objetivo fue entender cómo repositorios de referencia, como FMA y Million Song Dataset, representan y estructuran los datos musicales, para decidir su viabilidad en el contexto de aplicación de este trabajo.

GTZAN

Este conjunto de datos se considera el equivalente al MNIST [17] para el análisis de audio [18], dada su adopción histórica como estándar de evaluación en tareas de clasificación de géneros musicales.

- Variables predictivas principales: tempo, representaciones chroma, amplitud media cuadrática (RMS), descriptores espectrales y coeficientes MFCC.
- Estructura: 1 000 archivos de audio en crudo limitados a 30 segundos, acompañados de metadatos tabulares e imágenes de espectrogramas de Mel en su versión distribuida mediante Kaggle [19]. Todas estas representaciones fueron extraídas utilizando la biblioteca Librosa. Las tablas contienen los atributos calculados sobre la pista completa y también sobre divisiones de 3 segundos para incrementar el volumen de datos de entrenamiento. En ambos escenarios se aplica una reducción de dimensionalidad temporal: las variables se calculan inicialmente sobre micro-ventanas de milisegundos y luego se colapsan a valores estáticos mediante estadísticos de agregación, como la media y la varianza.
- Variables objetivo principales en Plusyc: se podría relacionar con *suggested genres*.

- Desventajas: provee segmentos cortos de audio, lo que limita la representatividad de la información musical a nivel de canción; y solo abarca 10 géneros musicales, mientras que Plusyc trabaja con más de 500.

FMA estándar

Se analiza la versión estándar de FMA, diseñada para superar las limitaciones de tamaño y acceso a las colecciones completa y mediana.

- Variables predictivas principales: representaciones chroma, Transformada de Q Constante (CQT), tonnetz, MFCC, RMS, descriptores espectrales y tasa de cruces por cero (ZCR).
- Estructura: ofrece recortes de audio de 30 segundos para sus subconjuntos estándar, acompañados de matrices de atributos precomputados distribuidos en formato tabular (CSV). Los atributos fueron extraídos utilizando Librosa y posteriormente colapsados mediante estadísticos de agregación, como la media, desviación estándar, asimetría y curtosis, para obtener valores estáticos por pista.
- Metadatos contextuales: información tabular adicional que incluye álbum, artista, popularidad, fechas de lanzamiento y ubicación geográfica.
- Variables objetivo principales: géneros musicales estructurados en una taxonomía jerárquica de clases y para un subconjunto de aproximadamente 13 000 pistas, proporciona atributos como *danceability*, *energy*, *valence*, *speechiness* y *liveness*.
- Desventajas: el análisis está restringido a segmentos de 30 segundos en la versión estándar. Las versiones media y completa exceden las capacidades de procesamiento de la infraestructura actual de la empresa. Además, la incertidumbre sobre las versiones exactas de Librosa utilizadas originalmente dificulta la replicabilidad técnica sobre canciones nuevas. Finalmente, la información etiquetada de 13 000 pistas es mucho menor que la de más de 60 000 de Plusyc.

Million Song Dataset (MSD)

Desarrollado por la Universidad de Columbia y The Echo Nest [20], este conjunto escaló la investigación de información musical a nivel industrial.

- Variables predictivas principales: representaciones de tono (chroma y pitch) y descriptores de timbre, ambos calculados a nivel de segmento.
- Estructura: colección de metadatos y descriptores precomputados empaquetados en archivos HDF5.
- Método de extracción: a diferencia de la segmentación por ventanas fijas, el MSD utiliza una división adaptativa basada en eventos. Esto fragmenta la canción en segmentos de duración variable. Para cada uno de estos segmentos, se calculan coeficientes de tono y timbre, y se genera una matriz de atributos alineada con la estructura temporal de la pista.
- Variables objetivo principales: proporciona atributos musicales fundamentales como *tempo*, *loudness*, *key* y *mode*.

- Desventajas: los descriptores se generaron con algoritmos propietarios de The Echo Nest, lo que complica procesar la segmentación por eventos en canciones nuevas de forma idéntica para realizar el proceso de inferencia.

Capítulo 3

AudioSet

Este conjunto masivo establece un estándar para la clasificación de eventos sonoros generales

Diseño e implementación

- Estructura: conjunto de identificadores de videos de YouTube y marcas de tiempo que referencian segmentos de 10 segundos, anotados bajo una ontología de 527 clases.

Todas las variables predictivas principales: el corpus original no extrae descriptores tradicionales. Su distribución oficial provee embeddings precomputados mediante el modelo VGGish [21], que sirven como entrada rápida para entrenar clasificadores de terceros sin necesidad de descargar el audio original.

3.1. Análisis del software

Variables objetivo principales: etiquetas multiclase que identifican la presencia de instrumentos musicales, como tipos de voces (habla, canto) y ambientes acústicos. La idea es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

- Desventajas: el enfoque en sonidos generales limita su precisión para los atributos musicales. Se puede agregar pseudocódigo dentro de un entorno `lstlisting` con el siguiente código:

Todos estos conjuntos de datos presentan varias limitaciones frente a la solución propuesta: algunos restringen el análisis a segmentos cortos de audio, mientras que otros requieren tamaños de almacenamiento excesivamente pesados o estructuras de datos difíciles de replicar durante el proceso de inferencia y dependientes de las versiones de las bibliotecas de extracción. A modo de ejemplo, se muestra el fragmento de código 3.1:

```
1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 3
3 #define MAX_ACTUATOR_NUMBER 6
4 uint32_t sensorValue[MAX_SENSOR_NUMBER];
5 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
6 uint32_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
7 uint32_t actuatorState[MAX_ACTUATOR_NUMBER]; //ON or OFF
8
9 Cabe mencionar que, a pesar de que en algunas de las fuentes de datos públicas se incluye información del contexto como la región del artista, el año de lanzamiento, el álbum o las letras, en esta solución se trabaja exclusivamente con información musical que se extrae del audio.
```

initGlobalVariables();

```
14 period = 500 ms;
```

3.1.2. Reducción de dimensionalidad mediante estadísticas

```
16 while(1) {
```

En el ámbito del procesamiento de señales, la información de un archivo de audio se representa como una serie de tiempo multivariada: una secuencia de puntos de datos [22], en este caso, descriptores numéricos y semánticos, indexados y ordenados cronológicamente.

```
22 updateAlarms();
```

La estrategia adoptada se inspiró en los conjuntos de datos de referencia, donde la señal se divide en ventanas temporales y la información de cada ventana se colapsa en valores estáticos. Esto permite reducir estas secuencias a un vector por cada canción, buscando optimizar el uso de la memoria y los tiempos de

```
26 vTaskDelayUntil(&ticks, period);
```

28 procesamiento. Esta transformación de la señal de secuencias de números a un vector de estadísticos ocurre de la siguiente manera:

FIGURA 3.1. Pseudocódigo del lazo principal de control.

- Segmentación temporal: se estableció una ventana de análisis de 10 segundos continuos. Esta decisión se fundamenta en la arquitectura de la red neuronal CNN14, entrenada sobre el conjunto de datos AudioSet, cuyos segmentos originales son de 10 segundos.
- Extracción de variables predictivas: para cada segmento de 10 segundos de la canción, el algoritmo usa Librosa y Essentia para extraer el conjunto de variables predictivas principales que proveen las fuentes de datos públicos. También se extrae información global de la canción y algunas de las variables predictivas escalares se calculan de forma global y también de forma segmentada y agregada.
- Extracción de embeddings y probabilidades: para esos segmentos de 10 segundos, el algoritmo también extrae un vector de embeddings y las probabilidades de activación para 173 clases de eventos musicales provistas por PANNs inference.
- Agrupación estadística: dado que una canción estándar produce una cantidad variable de segmentos de 10 segundos, se aplicó una técnica de colapso estadístico a lo largo del eje temporal, diferenciando el tratamiento según el tipo de variable:
 - Para las variables predictivas (DSP), se calcularon siete estadísticos por pista: media, desviación estándar, asimetría, curtosis, y los percentiles 10 (cerca del mínimo), 50 (mediana) y 90 (cerca del máximo para evitar ruido).
 - Para los embeddings y las probabilidades semánticas de las 173 clases seleccionadas de PANNs, se calcularon cuatro medidas: media, valor máximo, desviación estándar y el percentil 90.

Este enfoque matemático permite comprimir el volumen masivo de información de una serie de tiempo en un único vector unidimensional por canción.

Algunos experimentos preliminares sirvieron para validar que esta representación permitía capturar la información esencial de la canción de manera eficiente y compacta. El algoritmo de extracción, es el resultado de múltiples pruebas con distintas configuraciones de variables, estadísticos y métodos de segmentación. Algunos de los experimentos que no resultaron exitosos comprenden: pruebas con solo variables predictivas sin embeddings, demuestran que no es posible capturar eventos como el público en vivo o el habla en los primeros intentos de inferencia de *liveness* y *speechiness*. Las pruebas con embeddings pero sin variables predictivas en general no proporcionan la información de *key*, *tempo*, *loudness*, *mood* o *genres*. Pruebas con distintas ventanas resultaron ser ineficientes en el proceso de extracción de más de 60 000 canciones. Pruebas aplicando todos los estadísticos resultaron en un espacio de variables que consume mucho espacio de almacenamiento y con alta correlación.

3.1.3. Conformación del espacio de variables masivo

3.2. Ejecución de tareas sobre el conjunto de datos

Capítulo 4

3.3. Selección de variables de entrada

3.4. Modelado y optimización

Ensayos y resultados

3.5. Iteración productiva

3.6. Arquitectura de despliegue e integración

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

A modo de ejemplo, se muestra el fragmento de código 3.1:

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

```

1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ACTUATOR_NUMBER 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
8 state_t actuatorState[MAX_ACTUATOR_NUMBER]; //ON or OFF
9
10 void vControl() {
11
12     initGlobalVariables();
13
14     period = 500 ms;
15
16     while(1) {
17
18         ticks = xTaskGetTickCount();
19
20         updateSensors();
21
22         updateAlarms();
23
24         controlActuators();
25
26         vTaskDelayUntil(&ticks, period);
27     }
28 }
```

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

Conclusiones

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20, 2013. URL: <https://librosa.org/>.
- [4] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- [7] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [8] Gracenote Inc. *Gracenote Music Data: Some Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [9] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- [10] George Tzafarakis y Perry Cook. «Musical genre classification of audio signals». En: *IEEE Transactions on Speech and Audio Processing* (2002).
- [11] Michael Defferrard et al. «FMA: A Dataset for Music Analysis». En: *16th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.
- [12] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Plusyc Live SAS. *Perfil oficial en Instagram*. 2026. URL: <https://www.instagram.com/plusyc/>.
- [4] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20. 2015. URL: <https://librosa.org/>.
- [5] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- [6] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [7] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [8] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [9] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [10] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- [11] George Tzanetakis y Perry Cook. «Musical genre classification of audio signals». En: *IEEE Transactions on Speech and Audio Processing* (2002).
- [12] Michaël Defferrard et al. «FMA: A Dataset for Music Analysis». En: *18th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.
- [13] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).
- [14] Sebastián Ramírez. *FastAPI*. 2018. URL: <https://github.com/fastapi/fastapi>.
- [15] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://www.python.org>.
- [16] Oracle Corporation. *Oracle Cloud Infrastructure*. 2026. URL: <https://www.oracle.com/cloud/>.
- [17] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* (1998).

- [18] Bob L. Sturm. «The state of the art ten years after a state of the art: Future research in music information retrieval». En: *Journal of New Music Research* (2014).
- [19] Andrada Olteanu. *GTZAN Dataset - Music Genre Classification*. 2020. URL: <https://www.kaggle.com/datasets/andradaolteanu/gtzan-dataset-music-genre-classification>.
- [20] Thierry Bertin-Mahieux et al. «The million song dataset». En: 2011.
- [21] Shawn Hershey et al. «CNN architectures for large-scale audio classification». En: IEEE. 2017.
- [22] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. 2015.