

Índice general

Resumen	I
1. Introducción general	1
1.1. Extracción de información musical	1
1.2. Contexto de aplicación	1
1.3. Objetivos y alcance	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.3.3. Alcance	2
1.4. Estado del arte	3
1.4.1. Procesamiento digital de señales y extracción a bajo nivel	3
1.4.2. Modelos preentrenados y soluciones comerciales	3
1.4.3. Síntesis comparativa	4
2. Introducción específica	5
2.1. Fuentes de datos de canciones	5
2.2. Representaciones numéricas de la música	5
2.3. Información semántica del audio	7
2.4. Modelos de inteligencia artificial utilizados	8
2.5. Despliegue e integración	8
3. Diseño e implementación	11
3.1. Conjuntos de datos y extracción de atributos.	11
3.1.1. Análisis comparativo de conjuntos de datos públicos.	11
GTZAN	11
FMA estándar	12
Million Song Dataset (MSD)	13
AudioSet	13
3.1.2. Reducción de dimensionalidad mediante estadísticas	13
3.1.3. Definición del espacio de variables.	16
3.2. Ejecución de tareas sobre el conjunto de datos	17
3.2.1. Distribuciones y tratamiento de las variables objetivo.	17
Características básicas.	17
3.2.2. Selección de variables de entrada	19
3.3. Modelado y optimización.	20
3.4. Arquitecturas de Deep Learning: Emotionalness, Instrumentalness, y Valence.	21
Speechiness	22
4. Ensayos y resultados	23
4.1. Pruebas funcionales del hardware	23
Top-5 primary mood	23
Top-5 secondary mood	23
5. Conclusiones	23
5.1. Conclusiones generales.	23
3.2.2. Selección de variables de entrada	25
5.2. Próximos pasos	21

Bibliografía	25
3.3. Modelado y optimización	25
3.4. Arquitectura de despliegue e integración	25
4. Ensayos y resultados	27
4.1. Pruebas funcionales del hardware	27
5. Conclusiones	29
5.1. Conclusiones generales	29
5.2. Próximos pasos	29
Bibliografía	31

Índice de figuras

1.1. Interfaz de consulta en Tunebat	4
2.1. Representaciones visuales del audio	6
2.2. Probabilidades de detección semántica	8
3.1. Algoritmo de extracción de atributos	14
3.2. Proceso de reducción de dimensionalidad	15
3.3. Distribución de loudness	19
3.4. Distribución de key y mode	19
3.5. Distribución de tempo	20
3.6. Múltiples relaciones lineales de tempo real y estimado	21
3.7. Distribuciones de características perceptibles	21
3.8. Distribución de speechiness	22
3.9. Distribución de liveness	23
3.10. Distribución de primary mood	23
3.11. Distribución de secondary mood	24
3.12. Distribución de suggested genres	24

Índice de tablas

2.1. Atributos representativos	7
3.1. Desglose del espacio de variables	16
3.2. Características objetivas	18

Capítulo 3

Diseño e implementación

Este capítulo detalla el diseño y la implementación del sistema predictivo. Se analizan los conjuntos de datos utilizados, la extracción de atributos del audio y el tratamiento de datos según las distribuciones de las variables objetivo. Asimismo, se describen las técnicas de reducción y selección de variables, el proceso de optimización de los modelos y los resultados de la iteración productiva. Finalmente, se presenta la arquitectura desarrollada para el despliegue y la integración del sistema en un entorno operativo.

3.1. Conjuntos de datos y extracción de atributos

3.1.1. Análisis comparativo de conjuntos de datos públicos

La definición de la estrategia para la extracción de atributos se fundamenta en una revisión de conjuntos de datos públicos estandarizados en el ámbito MIR. El objetivo de este análisis previo fue entender cómo repositorios de referencia, como FMA y Million Song Dataset [27], representan y estructuran los datos musicales, como método para establecer los criterios de diseño del conjunto de datos propio.

En un comienzo se contempló el uso de algunos de estos conjuntos de datos, pero se encontró que presentan varias limitaciones frente a la solución propuesta: algunos restringen el análisis a segmentos cortos de audio, mientras que otros requieren tamaños de almacenamiento excesivamente pesados o estructuras de datos difíciles de replicar durante el proceso de inferencia y dependientes de las versiones de las bibliotecas de extracción.

Por otro lado, el análisis resultó positivo; estas restricciones motivaron que el proceso de extracción se ejecute directamente sobre el catálogo privado para eliminar las limitaciones, y su análisis permitió conocer las variables numéricas en la música, cómo se segmentan las canciones, cómo se reduce la dimensionalidad y hacer los primeros experimentos predictivos de las variables objetivo requeridas.

GTZAN

Este conjunto de datos se considera el equivalente al MNIST [28] para el análisis de audio [29], dada su adopción histórica como estándar de evaluación en tareas de clasificación de géneros musicales. Con el análisis de este conjunto de datos se pudo identificar los siguientes puntos:

- Variables predictivas principales: tempo, representaciones chroma, amplitud media cuadrática (RMS), descriptores espectrales y coeficientes MFCC.

- Variables predictivas principales: tiempo, representaciones chroma [48], amplitud media cuadrática (RMS) [47], descriptores espectrales [30] y coeficientes MFCC distribuida mediante Kaggle [30]. Todas estas representaciones fueron extraídas con la biblioteca Librosa. Las tablas contienen los atributos calculados sobre la pista completa y también sobre divisiones de 3 segundos para incrementar el volumen de datos de entrenamiento. En ambos escenarios se aplica una reducción de dimensionalidad temporal: las variables se calculan inicialmente sobre micro-ventanas de milisegundos y luego se colapsan a valores estáticos mediante estadísticos de agregación, como la media y la varianza.
 - Desventajas: provee segmentos cortos de audio, lo que limita la representatividad de la información musical a nivel de canción; y solo abarca 10 géneros musicales, mientras que Plusyc trabaja con más de 500.
- FMA estándar**
- Se analiza la versión estándar de FMA, diseñada para superar las limitaciones de tamaño y acceso a las colecciones completa y mediana. Se encuentra:
- FMA estándar**
- Variables predictivas principales: representaciones chroma, Transformada de Q Constante (CQT) [46], tonnetz, MFCC, RMS, descriptores espectrales y tasa de cruces pondero (ZCR). Los atributos fueron extraídos con Librosa y posteriormente colapsados mediante estadísticos de agregación, como la media, desviación estándar, asimetría y curtosis, para obtener valores estáticos por pista.
 - Estructura: ofrece recortes de audio de 30 segundos para sus subconjuntos estándar, acompañados de matrices de atributos precomputados distribuidos en formato tabular (CSV). Los atributos fueron extraídos con Librosa y posteriormente colapsados mediante estadísticos de agregación, como la media, desviación estándar, asimetría y curtosis, para obtener valores estáticos por pista.
 - Variables objetivo principales: géneros musicales estructurados en una taxonomía jerárquica de clases y para un subconjunto de aproximadamente 13 000 pistas, proporciona atributos como *danceability*, *energy*, *valence*, *speechiness* y *liveness*.
 - Metadatos contextuales: información tabular adicional que incluye álbum, artista, popularidad, fechas de lanzamiento y ubicación geográfica.
 - Desventajas: el análisis está restringido a segmentos de 30 segundos en la versión estándar. Las versiones media y completa exceden las capacidades de procesamiento de la infraestructura actual de la empresa. Además, la incertidumbre sobre las versiones exactas de Librosa utilizadas originalmente dificulta la replicabilidad técnica sobre canciones nuevas. Finalmente, la información etiquetada de 13 000 pistas es mucho menor que la de más de 60 000 de Plusyc.
- Million Song Dataset (MSD)**
- Desarrollado por la Universidad de Columbia y The Echo Nest, este conjunto escaló la investigación de información musical a nivel industrial. Se describen sus componentes principales:

Million Song Dataset (MSD) Principales: representaciones de tono (chroma y pitch) y descriptores de timbre, ambos calculados a nivel de segmento. Desarrollado por la Universidad de Columbia y The Echo Nest, este conjunto escalo la investigación de información musical a nivel industrial. Se describen sus componentes principales:

- Variables predictivas principales: representaciones de tono (chroma y pitch) [18,16] y descriptores de timbre [30], ambos calculados a nivel de segmento. El MSD utiliza una división adaptativa basada en eventos. Esto fragmenta la canción en segmentos de duración variable. Para cada uno de estos segmentos, se calculan coeficientes de tono y timbre, y se genera una matriz de atributos alineada con la estructura temporal de la pista.
- Método de extracción: a diferencia de la segmentación por ventanas fijas, el MSD utiliza una división adaptativa basada en eventos. Esto fragmenta la canción en segmentos de duración variable. Para cada uno de estos segmentos, se calculan coeficientes de tono y timbre, y se genera una matriz de atributos alineada con la estructura temporal de la pista.
- Variables objetivo principales: proporciona atributos musicales fundamentales como *tempo*, *loudness*, *key* y *mode*.
- Desventajas: los descriptores se generaron con algoritmos propietarios de The Echo Nest, lo que complica procesar la segmentación por eventos en canciones nuevas de forma idéntica para realizar el proceso de inferencia.
- Variables objetivo principales: proporciona atributos musicales fundamentales como *tempo*, *loudness*, *key* y *mode*.

AudioSet

Desventajas: los descriptores se generaron con algoritmos propietarios de The Echo Nest, lo que complica procesar la segmentación por eventos en canciones nuevas de forma idéntica para realizar el proceso de inferencia.

- Estructura: conjunto de identificadores de videos de YouTube y marcas de tiempo que referencian segmentos de 10 segundos, anotados bajo una ontología de 527 clases.

AudioSet Este conjunto masivo establece un estándar para la clasificación de eventos sonoros generales.

Variables predictivas principales: el corpus original no extrae descriptores tradicionales. Su distribución oficial provee embeddings precomputados mediante el modelo VGGish [31], que sirven como entrada rápida para entrenar clasificadores de terceros sin necesidad de descargar el audio original.

- Estructura: conjunto de identificadores de videos de YouTube y marcas de tiempo que referencian segmentos de 10 segundos, anotados bajo una ontología de 527 clases.
- Variables predictivas principales: el corpus original no extrae descriptores tradicionales. Su distribución oficial provee embeddings precomputados mediante el modelo VGGish [32], que sirven como entrada rápida para entrenar clasificadores de terceros sin necesidad de descargar el audio original.
- Variables objetivo principales: etiquetas multiclase que identifican la presencia de instrumentos musicales, como tipos de voces (habla, canto) y ambientes acústicos.
- Desventajas: el enfoque en sonidos generales limita su precisión para los atributos musicales.
- Variables objetivo principales: etiquetas multiclase que identifican la presencia de instrumentos musicales, como tipos de voces (habla, canto) y ambientes acústicos.

Cabe mencionar que a pesar de que en algunas de las fuentes de datos públicas se incluye información del contexto como la región del artista, el año de lanzamiento, el álbum o las letras, en esta solución se trabaja exclusivamente con información musical que se extrae del audio.

Desventajas: el enfoque en sonidos generales limita su precisión para los atributos musicales.

Cabe mencionar que a pesar de que en algunas de las fuentes de datos públicas se incluye información del contexto como la región del artista, el año de lanzamiento, el álbum o las letras, en esta solución se trabaja exclusivamente con información musical que se extrae del audio.

3.1.2. Reducción de dimensionalidad mediante estadísticas

La estrategia adoptada se inspiró en los conjuntos de datos de referencia, donde En el ámbito del procesamiento de señales, la información de un archivo de audio se representa como una serie de tiempo multivariada: una secuencia de puntos de datos [16], en este caso, descriptores numéricos y semánticos, indexados y ordenados cronológicamente.

de datos [16], en este caso, descriptores numéricos y semánticos, indexados y ordenados cronológicamente. En este algoritmo se muestra en la figura 3.1, donde se observa como la extracción ocurre en ramas paralelas para la transformación de la señal a un vector de estadísticos.

La estrategia adoptada se inspiró en los conjuntos de datos de referencia, donde la señal se divide en ventanas temporales y la información de cada ventana se colapsa en valores estáticos. Esto permite reducir estas secuencias a un vector por cada canción, para optimizar el uso de la memoria y los tiempos de procesamiento. El diagrama de flujo de este algoritmo se muestra en la figura 3.1, donde se observa como la extracción ocurre en ramas paralelas para la transformación de la señal a un vector de estadísticos.




FIGURA 3.1. Algoritmo de extracción de atributos.

En la rama de la izquierda se observa la extracción de variables (DSP) y a la derecha la extracción de embeddings y probabilidades semánticas con PANNs inference:

- Para la extracción de variables (DSP) se extraen de las bibliotecas Librosa y Essentia sobre la señal continua, el algoritmo extrae las series temporales de la rama de la izquierda se observa la extracción de variables (DSP) y a la derecha la extracción de embeddings y probabilidades semánticas con PANNs inference: la señal [16, 17]. También se extrae información global de la canción, descriptores escalares para la pista entera que complementan la información segmentada.
- Para la extracción de variables (DSP) se utilizan las bibliotecas Librosa y Essentia sobre la señal continua, el algoritmo extrae las series temporales de las características principales, por ventanas de 64 ms de longitud y solapamiento de 16 ms, que proporciona una alta resolución temporal original de la arquitectura de la red neuronal CNN14, entrenada sobre el conjunto de

la señal [16, 37]. También se extrae información global de la canción descriptores escalares para la pista entera que complementan la información segmentada de eventos musicales provistas por PANNs inference por cada ventana.

- Para la extracción de embeddings y probabilidades se estableció una ventana de análisis de 10 segundos continuos. Esta decisión se fundamenta en la arquitectura de la red neuronal GNN14, entrenada sobre el conjunto de datos AudioSet, cuyos segmentos originales son de 10 segundos. El algoritmo extrae un vector de embeddings y las probabilidades de activación para 173 clases de eventos musicales provistas por PANNs inference por cada ventana.
- Agrupación estadística: dado que una canción estándar produce una cantidad variable de segmentos, se aplicó una técnica de colapso estadístico a lo largo del eje temporal, según el tipo de variable:
 - Para los embeddings y las probabilidades semánticas de las 173 clases seleccionadas de PANNs, se calcularon cuatro medidas: media, valor máximo, desviación estándar y el percentil 90.
 - Para las variables (DSP), se calcularon siete estadísticos por pista: media, desviación estándar, asimetría, curtosis, y los percentiles 10 (cerca del mínimo), 50 (mediana) y 90 (cerca del máximo para evitar ruido).

Este enfoque matemático permite comprimir el volumen masivo de información de una serie de tiempo en un vector unidimensional por canción. Una representación empírica de este proceso se ilustra en la figura 3.2, donde se observa visualmente cómo las matrices dinámicas de la pista se colapsan en vectores tras el cálculo estadístico. La visualización muestra solo algunos ejemplos, la media en algunos DSP y el percentil 90 en algunas clases del AudioSet.

Este enfoque matemático permite comprimir el volumen masivo de información de una serie de tiempo en un vector unidimensional por canción. Una representación empírica de este proceso se ilustra en la figura 3.2, donde se observa visualmente cómo las matrices dinámicas de la pista se colapsan en vectores tras el cálculo estadístico. La visualización muestra solo algunos ejemplos, la media en algunos DSP y el percentil 90 en algunas clases del AudioSet.




FIGURA 3.2. Visualización de la reducción de dimensionalidad: las secuencias temporales (izquierda) se transforman en vectores (derecha) mediante la aplicación de medidas de agregación.

Algunos experimentos preliminares sirvieron para validar que esta representación permitía capturar la información esencial de la canción de manera eficiente y compacta. El algoritmo de extracción, es el resultado de pruebas con distintas configuraciones de arquitectura, extracción y reducción de dimensionalidad:

las secuencias temporales (izquierda) se transforman en vectores (derecha) mediante la aplicación de medidas de agregación.

Algunos experimentos preliminares sirvieron para validar que esta representación permitía capturar la información esencial de la canción de manera eficiente y compacta. El procesamiento computacional sobre el catálogo de canciones requirió más de una semana de ejecución para procesar y extraer la información de más de 60 000 canciones completas. El alto costo computacional se justificó por la necesidad de garantizar la disponibilidad de información para los experimentos de modelos predictivos de múltiples características musicales.

3.1.3. Definición del espacio de variables

El procesamiento computacional sobre el catálogo de canciones requirió más de una semana de ejecución para procesar y extraer la información de más de 60 000 canciones completas. El alto costo computacional se justificó por la necesidad de garantizar la disponibilidad de información para los experimentos de modelos predictivos de múltiples características musicales.

La aplicación del algoritmo final generó un conjunto de datos masivo compuesto por 9590 variables, resumido en la tabla 3.1.

Categoría de extracción	Atributos base	Cant.	Estadísticos aplicados	Cant.	Total
Representaciones DSP (Librosa)	MFCF (20), Deltas (40), Centroide, Ancho de banda, Rolloff, Contraste (7), Flatness, Flux, Chroma (12), Tonnetz (6), RMS, ZCR.	92	Media, Desv. Estándar, Asimetría, Curtosis, Percentiles (10, 50, 90).	7	644
Atributos globales y ritmo	LJFS [33], Entropía espectral [17], Tempo, Complejidad dinámica [17], Tasa y estadísticos de onset (4) [16], Pitch, Fracción de voz [34], Claridad tonal (2), Factor de cresta [30], Desviación de la- tidos [16].	15	Cálculo único por pista completa.	7	15
Estimación tonal (Perfiles)	Vectores de correlación Krumhansl (Mayor/Menor) y Temperley (Mayor/Menor) [16], Factor de cresta [30], Desviación de la- tidos [16].	48	Cálculo único por pista completa (4 perfiles × 12 semitonos).	1	48
Embeddings semánticos (PANNs)	Vector latente de la capa pre- via a la clasificación de la red CNN14.	2048	Media, Máximo, Desv. Estándar, Percentil 90.	4	8192
Estimación tonal (Perfiles)	Vectores de correlación Krumhansl (Mayor/Menor) y Temperley (Mayor/Menor) [16].	48	Cálculo único por pista completa (4 perfiles × 12 semitonos).	1	48
Probabilidades (PANNs)	Clases filtradas (Voz, Instru- mentos, Géneros, Público en vivo, Distorsión).	173	Media, Máximo, Desv. Estándar, Percentil 90.	4	692

Total de variables por canción: 9591

Embeddings semánticos (PANNs) Vector latente de la capa pre- via a la clasificación de la red CNN14. 2048 Media, Máximo, Desv. Estándar, Percentil 90. 4 8192

3.2. Ejecución de tareas sobre el conjunto de datos

Esta sección presenta las variables objetivo y sus distribuciones, el tratamiento aplicado a los datos y las técnicas de selección y reducción de variables predictivas.

Las variables objetivo se dividen en tres grupos básicos: percentiles y géneros/estados de ánimo sugeridos. Y se definen en la tabla 3.2.

Total de variables por canción: 9590

3.2. Ejecución de tareas sobre el conjunto de datos

Esta sección presenta las variables objetivo y sus distribuciones, el tratamiento aplicado a los datos y las técnicas de selección y reducción de variables predictivas.

TABLA 3.2. Definición, ejemplos y tipo de problema de aprendizaje supervisado por característica.

Las variables objetivo se dividen en tres grupos: básicas, perceptibles y géneros/estados de ánimo sugeridos. Y se definen en la tabla 3.2.

Característica	Definición	Ejemplos	Tipo de problema
Básicas			
3.2.1. Distribución y tratamiento de las variables objetivo			
Loudness	Volumen global promedio en decibelios, más negativa más silenciosa (dB)	5.2 dB, -12.4 dB	Regresión
Key	Tonalidad estimada de la pista, mapeada a números enteros (Pitch Class)	0 (Do), 1 (Do#), 2 (Re)	Clasificación
Mode	Modalidad (mayor o menor) del contenido melódico	1 (Mayor), 0 (Menor)	Clasificación
Tempo	Segmentos con amplitud inferior a -60 dB. Esta operación eliminó la gran mayoría de los nulos. Después de la reducción, El restante se concentró exclusivamente en un 6% del descriptor <i>spectral_entropy_global</i> . Matemáticamente, el cálculo de la entropía espectral requiere normalizar la magnitud del espectro para interpretarlo como una distribución de probabilidad. En ventanas de análisis correspondientes a silencios absolutos, la energía espectral es nula [17].	120 BPM, 85 BPM	Regresión
Acousticness	Confianza de que la pista es acústica (0.0 a 1.0).	0.99, 0.01	Regresión
Danceability	Capacidad de ser bailable según etiquetado manual. Al analizar las variables objetivo, se identificó un cambio en una fecha específica en la fuente de los datos: hasta mediados de diciembre de 2024, los valores provenían de la integración con una API externa. Los registros generados durante 2025, ingresados manualmente por el equipo de curadores, introdujeron error, caracterizado por la presencia de valores por fuera del rango en variables discretas, valores extremos en cero y uno en variables continuas. Para proteger el entrenamiento de los modelos, el conjunto de datos de análisis fue truncado para conservar únicamente los registros fiables hasta diciembre de 2024. Resulta en el uso de un 92.5% aproximado de las canciones del catálogo de Plusyc y aplica para todas las variables, excepto para géneros y estados de ánimo donde la información no dependía de la API.	0.85, 0.20	Regresión
Energy	Intensidad percibida	0.99, 0.01	Regresión
Instrumentalness	Probabilidad de ausencia de contenido vocal (0.0 a 1.0).	0.90 (sin voz), 0.05 (cantada)	Regresión
Liveness	Confianza de grabación con público en vivo (0.0 a 1.0).	0.85 (concierto), 0.10 (estudio)	Regresión
Speechiness	Presencia de palabras habladas (0.0 a 1.0).	0.85 (conversación), 0.5 (rap), 0.05 (música)	Regresión
Valence	Positividad musical transmitida (0.0 a 1.0).	0.90, 0.15	Regresión
A continuación se presentan las distribuciones de las variables objetivo después del filtrado y el preprocesamiento adicional aplicado.			
Primary Mood	Estado de ánimo o emoción predominante.	Energizing, Lively, Empowering	Clasificación
Loudness	Estado de ánimo o emoción predominante.	Energizing, Lively, Empowering	Clasificación
La figura 3.3 muestra la distribución de frecuencia de los valores del <i>loudness</i> . Se observa que presenta un sesgo negativo, con una concentración principal cerca de los -7 dB. Esto se explica dada la guerra del <i>loudness</i> [25], donde muchos artistas y productores buscan que sus canciones suenen con alto volumen, y plataformas como Spotify normalizan el <i>loudness</i> para evitar cambios abruptos en el volumen entre las canciones.			
Suggested Genres	Género musical	Pop, Indie, EDM	Clasificación

Desafíos:

3.2.1. Distribuciones de las variables objetivo

Tabla 3.2. Definición, ejemplos y tipo de problema de aprendizaje supervisado por característica.


Características básicas

Característica	Definición	Ejemplos	Tipo de problema
Loudness	Volumen global promedio en decibelios, más negativa, más silenciosa (dB)	-5.2 dB, -12.4 dB	Regresión
Key	Tonalidad estimada de la pista mapeada a números enteros (<i>Pitch Class</i>)	0 (Do), 1 (Do#), 2 (Re)	Clasificación
Mode	Modalidad (mayor o menor) del contenido melódico.	1 (Mayor), 0 (Menor)	Clasificación
Tempo	Tempo global estimado en pulsaciones por minuto (BPM).	120 BPM, 85 BPM	Regresión
Perceptibles			
Acousticness	Confianza de que la pista es acústica (0,0 a 1,0).	0,95, 0,10	Regresión
Danceability	Capacidad de ser bailable según tempo y ritmo (0,0 a 1,0).	0,85, 0,20	Regresión
Energy	Medida de intensidad y actividad (0,0 a 1,0).	0,90	Regresión
Instrumentalness	Probabilidad de ausencia de contenido vocal (0,0 a 1,0).	0,90 (sin voz), 0,05 (cantada)	Regresión
Liveness	Confianza de grabación con público en vivo (0,0 a 1,0).	0,85 (concierto), 0,10 (estudio)	Regresión
Speechiness	Presencia de palabras habladas (0,0 a 1,0).	0,85 (conversación), 0,5 (rap), 0,05 (música)	Regresión
Valence	Positividad musical transmitida (0,0 a 1,0).	0,90, 0,15	Regresión

ánimo y género sugeridos

Primary Mood	Estado de ánimo o emoción predominante.	<i>Energizing, Lively, Empowering</i>	Clasificación
Secondary Mood	Estados de ánimo complementarios.	<i>Euphoric Energy, Energetic, Anxious</i>	Clasificación
Suggested Genres	Género musical.	<i>Chill House, EDM</i>	Clasificación

La figura 3.3 muestra el valor del *loudness* en el eje x y la frecuencia en las canciones del catálogo en el eje y. Se observa que presenta un sesgo negativo, con una concentración principal cerca de los -7 dB. Esto es predecible dada la guerra del *loudness* [32], donde muchos artistas y productores quieren que sus canciones suenen fuertes, y plataformas como Spotify normalizan el *loudness* para evitar cambios abruptos de volumen entre las canciones.



Desafíos y tratamiento

- Desafío 1: **Energy**
- Desafío n: **Instrumentalness**

3.2.2. Selección de variables de entrada

Liveness Confianza de grabación con público en vivo (0,0 a 1,0). 0,85 (concierto), 0,10 (estudio) Regresión

Speechiness Presencia de palabras habladas (0,0 a 1,0). 0,85 (conversación), 0,5 (rap), 0,05 (música) Regresión


Valence Positividad musical transmitida (0,0 a 1,0). 0,90, 0,15 Regresión

3.3. Modelado y optimización

3.4. Arquitectura de despliegue e integración

Capítulo 4

Ensayos y resultados



Todos los capítulos de esta sección se refieren al contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

- Existencia de asimetría negativa (sesgo a la izquierda) y presencia de valores extremos negativos (hasta -60 dB). Esto potencialmente podría generar un error matemático que desvíe la atención del algoritmo durante el entrenamiento [23].

4.1. Preprocesamiento funcional del hardware

Tratamiento:

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y cómo se aplicó una transformación.

- Se aplicó una transformación logarítmica desplazada (*Shifted Log-Transformation*). Primero, se realizó una traslación de la escala ($y + 60,1$) para garantizar que todos los registros fueran estrictamente mayores a cero.
- Posteriormente, se aplicó la función matemática $\log(1 + x)$ ('np.log1p'). Este preprocesamiento comprime la cola izquierda de la distribución, mitiga el sesgo original y estabiliza la varianza para mejorar el rendimiento del modelo de regresión [23].

Key y Mode

La figura 3.4 muestra la distribución conjunta de las frecuencias de los valores discretos de las 24 tonalidades de la música occidental. Se observa preferencia por tonalidades como Do mayor, Re mayor y Sol mayor; y menor frecuencia de canciones en Re sostenido mayor y menor.




FIGURA 3.4. Distribución conjunta de *key* y *mode* en el catálogo de Plusyc.

Desafíos:

- Existe un desbalance marcado en las tonalidades, propiciando que los modelos de clasificación colapsen hacia las clases mayoritarias [23].
- Los algoritmos de aprendizaje automático requieren que las variables categóricas (como las notas musicales) estén representadas en un formato numérico procesable.

Tratamiento:

- Para adaptar las etiquetas alfanuméricas de las tonalidades al entrenamiento, se aplicó codificación de etiquetas (*Label Encoding*).
- Para mitigar el desbalance sin eliminar información musical intrínseca, el problema se abordó directamente en la fase de modelado mediante la ponderación de clases (`class_weights='balanced'`).

Se decide abordar el problema de clasificación conjunto de *key* y *mode* como una variable categórica con 24 clases (12 tonalidades $\times$ 2 modos). El motivo de la decisión se basa en que el caso de equivocación de *mode* es más problemático que el de *key* y *mode*, ya que afecta la familia armónica. La predicción de un top-k de *key* y *mode* conjuntos, generalmente muestran relaciones armónicas de la canción, esto sentido en el contexto de la ambientación.

Tempo

La figura 3.5 muestra la distribución de frecuencia de los valores del *tempo*. Se observa una concentración principal en el rango de los 90 a 130 BPM, con un pico destacado alrededor de los 120 BPM, predominante en la música popular contemporánea [16].




FIGURA 3.5. Distribución de *tempo* en el catálogo de Plusyc.

Se encuentra que *tempo* es un caso especial ya que presenta errores de octava métrica:

Desafíos:

- Se identificaron inconsistencias en las etiquetas, donde el valor objetivo registrado representaba exactamente la mitad, el doble o proporciones fraccionarias (ej. 1.5x) del tempo real. Este es un problema documentado en la recuperación de información musical conocido como «error de octava» (*octave error*) [16].

- El problema anterior también puede explicar la presencia de valores atípicos en los extremos de la distribución.

La presencia de errores de octava complica el uso de algoritmos de regresión lineal ya que se observan múltiples relaciones lineales entre variables rítmicas predictivas y el *tempo global* (ej. predecir 60 BPM para una pista etiquetada en 120 BPM). Un ejemplo de esta relación se muestra en la figura 3.6, donde el *tempo real* etiquetado muestra múltiples relaciones lineales con la variable predictiva *tempo* estimada desde Essentia.



Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

Se contempla la evaluación de los algoritmos DSP de estimación de *tempo* integrados en las bibliotecas de DSP, esta comparación se muestra en la sección de validación. Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?

Acousticness, Danceability, Energy, Instrumentalness y Valence

- ¿Cuán fielmente se pudo seguir la planificación original (cronograma in-

La figura 3.7 muestra las distribuciones de frecuencia de los valores de estas características. Aunque todas comparten un rango de $[0, 1]$, presentan comportamientos distintos: *danceability* muestra una distribución aproximadamente normal; *energy* presenta sesgo negativo; *valence* tiende a la uniformidad; mientras que *acousticness* y, de forma extrema, *instrumentalness*, exhiben un sesgo positivo con una concentración masiva de valores cercanos a cero.

¿Se manifestó alguno de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente? ¿Cuáles fueron las causas y los efectos?

- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

(A) Acousticness

(B) Danceability

(C) Energy

Acá se indica cómo se podría continuar el trabajo más adelante.



(D) Instrumentalness



(E) Valence

FIGURA 3.7. Distribuciones de características perceptibles en el catálogo de Plusyc.

El modelado conjunto de estas cinco características se aborda convencionalmente mediante redes neuronales, como el Perceptrón Multicapa (MLP), dada su capacidad para aprender de forma simultánea las complejas correlaciones y dependencias no lineales entre ellas [23]. Bajo esta premisa, el preprocesamiento requiere atenciones específicas:

Desafíos:

- La heterogeneidad en las formas de las distribuciones y sus varianzas. En arquitecturas sensibles a la escala, como los MLP, las variables con mayor varianza empírica pueden dominar el cálculo de los gradientes, ralentizando o sesgando la convergencia de los pesos [23].
- Las MLP son sensibles a los valores nulos y el descriptor *spectral_entropy_global* (presente en un 6 % de la muestra).

Tratamiento:

- A diferencia del *loudness*, las variables objetivo ya se encuentran acotadas matemáticamente en el intervalo $[0, 1]$. Por tanto, no requirieron transformaciones, ya que este rango es compatible con las funciones de activación continuas (como la sigmoide) en la capa de salida una red neuronal.
- Se garantizó la integridad de la matriz de características imputando de forma segura con el valor cero los nulos residuales, y así reflejar la falta de información acústica.
- Finalmente, se aplica estandarización estadística (*StandardScaler*) a todo el conjunto de entrada para garantizar una media de cero y varianza unitaria ($\mu = 0, \sigma^2 = 1$). Este paso es necesario para homogeneizar el espacio de variables predictivas para el entrenamiento del modelo neuronal [23].

Speechiness

La figura 3.8 muestra las distribuciones de frecuencia del *speechiness*.




FIGURA 3.8. Distribución de *speechiness* en el catálogo de Plusyc.

Desafíos: Tratamiento:

Liveness

La figura 3.9 muestra las distribuciones de frecuencia del *liveness*.

Bibliografía

Distribución de Liveness



- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Gordon G. Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [4] Franck V Garlin y Keri Owen. «Setting the tone with the tune: A meta-analytic review of the effects of background music in retail settings». En: *Journal of Business Research* (2006).

FIGURA 3.9. Distribución de *liveness* en el catálogo de Plusyc.

Desafíos: Tratamiento:

Estados de ánimo y géneros sugeridos: este grupo incluye la variable *primary mood* y algunas variables también discretas y de alta cardinalidad: *secondary mood*, *suggested genres*.

- [5] Holger Roschik, Sandra Maria Correia Loureiro y Jan Breitsohl. «Calibrating 30 years of experimental research: a meta-analysis of the atmospheric effects of music, scent, and color». En: *Journal of Retailing* (2017).
- [6] Plusyc LIVE SAS. Perfil oficial en Instagram. 2026. URL: <https://www.instagram.com/plusyc/>.
- [7] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20, 2015. URL: <https://librosa.org/>.

La figura 3.10 muestra los *primary mood* de Plusyc y sus frecuencias.

- [8] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- [9] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [10] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [11] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/web-api/reference/get-audio-features>.

FIGURA 3.10. Distribución de *primary mood* en el catálogo de Plusyc.

- [12] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.

Desafíos: Tratamiento:

- [13] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.

Top-5 *secondary mood*

- [14] George Tzanetakis y Perry Cook. «Musical genre classification of audio signals». En: *Proceedings of the 2002 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2002.

- [15] Michaël Defferrard et al. «FMA: A Dataset for Music Analysis». En: *18th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.

- [16] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Springer, 2015.

La figura 3.12 muestra las distribuciones de frecuencia de los *suggested genres*.

- [17] Alexander Lerch. *An introduction to audio content analysis: Applications in signal processing and music informatics*. John Wiley & Sons, 2012.
- [18] Emilia Gómez. «Tonal description of polyphonic audio for music content processing». En: *INFORMS Journal on Computing* (2006).
- [19] Christopher Harte, Mark Sandler y Martin Gasser. «Detecting harmonic change in musical audio». En: *Proceedings of the 1st ACM workshop on Audio and music computing multimedia*. 2006.
- [20] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).
- [21] Karen Simonyan y Andrew Zisserman. «Very deep convolutional networks for large-scale image recognition». En: *International Conference on Learning Representations*. 2015.
- [22] Guolin Ke et al. «Lightgbm: A highly efficient gradient boosting decision tree». En: *Advances in neural information processing systems*. Vol. 30. 2017.
- [23] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep learning*. MIT press, 2016.
- [24] Sebastián Ramírez. *FastAPI*. 2018. URL: <https://github.com/fastapi/fastapi>.
- [25] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://www.python.org>.
- [26] Oracle Corporation. *Oracle Cloud Infrastructure*. 2026. URL: <https://www.oracle.com/cloud/>.
- [27] Thierry Bertin-Mahieux et al. «The million song dataset». En: *Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR 2011)*. 2011.
- [28] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* (1998).
- [29] Bob L. Sturm. «The state of the art ten years after a state of the art: Future research in music information retrieval». En: *Journal of New Music Research* (2014).
- [30] Andrada Olteanu. *GTZAN Dataset - Music Genre Classification*. 2020. URL: <https://www.kaggle.com/datasets/andradolteanu/gtzan-dataset-music-genre-classification>.
- [31] Shawn Hershey et al. «CNN architectures for large-scale audio classification». En: *IEEE*. 2017.
- [32] Earl Vickers. «The loudness war: Background, speculation and recommendations». En: *Audio Engineering Society*. 2010.




FIGURA 3.12. Distribución de *suggested genres* en el catálogo de Plusyc.

Desafíos: Tratamiento:

3.2.2. Selección de variables de entrada

3.3. Modelado y optimización

3.4. Arquitectura de despliegue e integración

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [4] Franck V Garlin y Keri Owen. «Setting the tone with the tune: A meta-analytic review of the effects of background music in retail settings». En: *Journal of Business Research* (2006).
- [5] Holger Roschk, Sandra Maria Correia Loureiro y Jan Breitsohl. «Calibrating 30 years of experimental research: a meta-analysis of the atmospheric effects of music, scent, and color». En: *Journal of Retailing* (2017).
- [6] Plusyc Live SAS. *Perfil oficial en Instagram*. 2026. URL: <https://www.instagram.com/plusyc/>.
- [7] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20. 2015. URL: <https://librosa.org/>.
- [8] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- [9] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [10] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [11] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [12] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [13] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- [14] George Tzanetakis y Perry Cook. «Musical genre classification of audio signals». En: *IEEE Transactions on Speech and Audio Processing* (2002).
- [15] Michaël Defferrard et al. «FMA: A Dataset for Music Analysis». En: *18th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.
- [16] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Springer, 2015.

- [17] Alexander Lerch. *An introduction to audio content analysis: Applications in signal processing and music informatics*. John Wiley & Sons, 2012.
- [18] Emilia Gómez. «Tonal description of polyphonic audio for music content processing». En: *INFORMS Journal on Computing* (2006).
- [19] Christopher Harte, Mark Sandler y Martin Gasser. «Detecting harmonic change in musical audio». En: *Proceedings of the 1st ACM workshop on Audio and music computing multimedia*. 2006.
- [20] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).
- [21] Karen Simonyan y Andrew Zisserman. «Very deep convolutional networks for large-scale image recognition». En: *International Conference on Learning Representations*. 2015.
- [22] Guolin Ke et al. «Lightgbm: A highly efficient gradient boosting decision tree». En: *Advances in neural information processing systems*. Vol. 30. 2017.
- [23] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep learning*. MIT press, 2016.
- [24] Sebastián Ramírez. *FastAPI*. 2018. URL: <https://github.com/fastapi/fastapi>.
- [25] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://www.python.org>.
- [26] Oracle Corporation. *Oracle Cloud Infrastructure*. 2026. URL: <https://www.oracle.com/cloud/>.
- [27] Thierry Bertin-Mahieux et al. «The million song dataset». En: *Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR 2011)*. 2011.
- [28] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* (1998).
- [29] Bob L. Sturm. «The state of the art ten years after a state of the art: Future research in music information retrieval». En: *Journal of New Music Research* (2014).
- [30] Geoffroy Peeters. *A large set of audio features for sound description (similarity and classification) in the CUIDADO project*. Inf. téc. IRCAM (Institut de Recherche et Coordination Acoustique/Musique), 2004.
- [31] Andrada Olteanu. *GTZAN Dataset - Music Genre Classification*. 2020. URL: <https://www.kaggle.com/datasets/andradolteanu/gtzan-dataset-music-genre-classification>.
- [32] Shawn Hershey et al. «CNN architectures for large-scale audio classification». En: *IEEE*. 2017.
- [33] ITU-R. «Algorithms to measure audio programme loudness and true-peak audio level». En: *Recommendation ITU-R BS.1770-4* (2015).
- [34] Alain De Cheveigné e Hideki Kawahara. «YIN, a fundamental frequency estimator for speech and music». En: *The Journal of the Acoustical Society of America* (2002).
- [35] Earl Vickers. «The loudness war: Background, speculation and recommendations». En: *Audio Engineering Society*. 2010.