

Asignación de características musicales para ambientación comercial

Ing. Carlos Alberto Rivas Araque

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Martín Moreyra (GatekeeperX)

Jurados:

Natanael Emir Ferrán (FIUBA) (Esp. Ing.)
Pablo Carlos Zizzutti (FIUBA) (Mg. Lic.)
Ana Laura Diedrichs (FIUBA) (Esp. Ing.)

Ciudad de Buenos Aires, junio de 2026

3.2.2.	Selección de variables de entrada	26
3.3.	Modelado y optimización	27
	Modelado mediante perceptrón multicapa (MLP)	27
	Modelado mediante Gradient Boosting (LightGBM)	28
	Optimización de hiperparámetros y regularización	29
3.4.	Arquitectura de despliegue e integración	30
3.4.1.	Diseño del servicio predictivo	30
3.4.2.	Flujo de integración	31
4.	Ensayos y resultados	33
4.1.	Resultados por modelo	33
4.1.1.	Acousticness, danceability, energy, instrumentalness y valence	33
4.1.2.	Loudness	35
4.1.3.	Key y mode	37
4.1.4.	Tempo	38
4.1.5.	Speechiness y liveness	40
4.1.6.	Suggested genres	42
4.1.7.	Primary y secondary moods	44
4.2.	Ejemplo de inferencia	46
5.	Conclusiones	49
5.1.	Conclusiones generales	49
5.2.	Próximos pasos	50
A	Apéndice A: Respuesta JSON de inferencia	51
B	Bibliografía	53

4.19. Curvas ROC y valores AUC para primary mood.	44
4.20. Matriz de confusión normalizada de secondary mood.	45
4.21. Visualización de los resultados de inferencia en una interfaz web (parte 1).	46
4.22. Visualización de los resultados de inferencia en una interfaz web (parte 2).	47
4.23. Visualización de los resultados de inferencia en una interfaz web (parte 3).	48

Índice de tablas

2.1. Atributos representativos	7
3.1. Desglose del espacio de variables	16
3.2. Distribución porcentual de speechiness antes y después del pre- procesamiento.	22
3.3. Distribución porcentual de liveness antes y después del preproce- samiento.	23
3.4. Resumen de parámetros usados en la selección de variables.	26
3.5. Resumen de hiperparámetros óptimos por objetivo.	30
4.1. Comparativa de métricas de dos experimentos de la red neuronal MLP.	34
4.2. Métricas de Essentia y del modelo de key y mode.	38
4.3. Resultados de la estimación de tempo de Essentia.	40
4.4. Métricas en el modelado de speechiness y liveness.	40

La distribución muestra la presencia de un sesgo positivo extremo, ya que el catálogo musical carece de pistas de palabra hablada pura y concentra los valores muy cerca de cero. Los valores cerca del uno indican contenido exclusivamente hablado como podcast o streaming conversacional, ausentes en el catálogo de Plusyc.

El mejor resultado experimental en términos de las métricas de evaluación se obtuvo al aplicar técnicas de submuestreo. Se discretizó el dominio de la variable en rangos estratégicos y se aplicó un submuestreo con tope por rangos para limitar la cantidad de registros en la moda, reducir el sesgo y conservar la totalidad de registros de la cola. Los rangos se presentan en la tabla 3.2.

TABLA 3.2. Distribución porcentual de speechiness antes y después del preprocesamiento.

Intervalo	Descripción del rango	% Original	% Final
[0, 00, 0, 05]	Menor presencia de canto	56,0 %	42,1 %
(0, 05, 0, 33]	Canto	41,9 %	42,1 %
(0, 33, 1, 00]	Rap	2,1 %	15,7 %
Total		100 %	100 %

Cabe mencionar que se aplicó muestreo estratificado a nivel de los rangos durante la división de conjuntos de entrenamiento y pruebas. Finalmente, se mitigó el ruido en las etiquetas al eliminar un porcentaje menor de registros contradictorios: se compararon los valores de la variable objetivo con la evidencia acústica vocal en las probabilidades de clases como *speech* y *rapping* extraídas de PANNs para descartar las pistas que presentaban discrepancias entre su etiqueta manual y su contenido semántico real.

Liveness

El *liveness* representa la confianza de que la pista fue grabada con público en vivo [0, 1], (ej. 0,85 para un concierto, 0,10 para un estudio) [11]. La figura 3.8 muestra la distribución de frecuencia del *liveness*.




FIGURA 3.8. Distribución de *liveness* en el catálogo de Plusyc.

Esta distribución, como en el caso anterior, también muestra la presencia de un sesgo positivo extremo, ya que concentra la inmensa mayoría de los registros por debajo de 0,2. Adicionalmente, se identificó un problema de ruido sistemático

TABLA 3.5. Resumen de hiperparámetros óptimos por objetivo.

Objetivo	Prof. máx.	Hojas	Tasa de apren.	Muestras/Hoja	L1 (α)	L2 (λ)
<i>Key/Mode</i>	5	140	0,0259	34	3,1690	6,9757
<i>Loudness</i>	10	21	0,0868	25	0,0104	0,0390
<i>Liveness</i>	4	15	0,0194	17	0,0107	0,3887
<i>Speechiness</i>	8	34	0,0102	32	0,4942	0,2947
<i>Primary Mood</i>	10	32	0,0208	79	0,1084	5,0239
<i>Secondary Mood</i>	11	35	0,0125	69	0,1443	2,6547
<i>Genres</i>	6	28	0,0606	21	0,9334	4,8052

3.4. Arquitectura de despliegue e integración

El sistema de inferencia fue diseñado para operar como un servicio integrable con la infraestructura existente de Plusyc. El despliegue se realizó en una instancia de cómputo sobre OCI.

3.4.1. Diseño del servicio predictivo

El núcleo de procesamiento se expuso a través de una API RESTful desarrollada con FastAPI. Esta interfaz expone el ciclo de inferencia: carga del audio, extracción de variables predictivas de entrada a los modelos MLP y LightGBM, que retornan los valores de las predicciones de las características musicales. Para garantizar la reproducibilidad y estabilidad del entorno, la aplicación fue contenedorizada utilizando Docker, como se observa en la figura 3.15.




FIGURA 3.15. Diagrama de bloques de la aplicación predictiva.


Dada la alta exigencia computacional y de memoria del modelo preentrenado PANNs inference, se aplicaron configuraciones a nivel de contenedor para asegurar la viabilidad en producción:

- Se limitó a una instancia. Esto previene la duplicación masiva de los modelos y pesos preentrenados en la memoria RAM, para optimizar el consumo de los recursos de la máquina virtual y evitar nuevos costos [49].

4.2. Ejemplo de inferencia

Para demostrar el funcionamiento integral del sistema, se ejecutó una inferencia cuya entrada es la canción de Radiohead ilustrada en los primeros capítulos y que no está en el catálogo de Plusyc. El archivo de audio se procesó a través de la API. En el anexo A se presenta la respuesta en formato JSON:

Las figuras 4.21, 4.22 y 4.23 exponen una representación visual de estos resultados en una interfaz de usuario. En la primera parte, la figura 4.21a ilustra la pantalla de selección de la canción procesada, seguida por el resumen general en la figura 4.21b, donde aparecen las estimaciones de *key*, *mode*, *tempo* y *loudness*, e incuye el top-3 de *key* y *mode* en la parte inferior.




(B) Resumen general de resultados, características básicas.

Las figuras 4.21 y 4.22 exponen una representación visual de estos resultados en una interfaz de usuario. Visualización de los resultados de inferencia en una interfaz web (parte 1).


Si se comparan los resultados de la inferencia con los resultados de Tunebat de la figura 1.1, se puede observar alta similitud en los datos.

Si se comparan estos resultados con los valores de Tunebat de la figura 1.1, se puede observar una alta similitud en los datos. El único valor que está desfasado en este caso es el *tempo*, para el que no se usó un modelo de inferencia desarrollado como parte de este trabajo sino que curiosamente se usó el algoritmo de extracción de Essentia. Además, el desfase ocurre en una proporción $y \approx 0,67x$ en relación al valor real, posibilidad que se sugirió en la sección 4.1.4.

A continuación, la segunda parte muestra los resultados de la estimación de las características perceptibles en la figura 4.22a, también coherentes con los valores de Tunebat y en la figura 4.22b, los resultados de las predicciones para el top-5 de *primary mood* a la izquierda y *secondary mood* a la derecha.



Resumen (A) Características perceptibles.



(B) Predicción de top-5 primary y secondary moods.

FIGURA 4.22. Visualización de los resultados de inferencia en una interfaz web (parte 2).

Características perceptibles

FIGURA 4.21. Visualización de los resultados de inferencia en una interfaz web (parte 1).

Finalmente, la figura 4.23 presenta dos resultados de las predicciones para el topé 5 de suggested genres, que también muestran coherencia con lo esperado para la obra analizada. el algoritmo de extracción de Essentia. Además, el desfase ocurre en proporción $y \approx 0,67x$ en relación al valor real, posibilidad que se sugirió en la sección 4.1.2.

Los estados de ánimo y géneros también muestran resultados coherentes con los esperados.




FIGURA 4.23. Visualización de los resultados de inferencia en una interfaz web (parte 3).




FIGURA 4.22. Visualización de los resultados de inferencia en una interfaz web (parte 2).

Apéndice A

Bibliografía

Apéndice A: Respuesta JSON de inferencia

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [4] JSON de respuesta de la API tras el ciclo de inferencia.
- [5] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [6] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [7] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [8] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [9] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [10] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [11] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [12] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [13] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [14] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [15] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [16] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [17] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).

- [18] Emilia Gómez. «Tonal description of polyphonic audio for music content processing». En: *INFORMS Journal on Computing* (2006).
- [19] Christopher Harte, Mark Sandler y Martin Gasser. «Detecting harmonic change in musical audio». En: *Proceedings of the 1st ACM workshop on Audio and music computing multimedia*. 2006.
- [20] Qiuqiang Kong et al. «PANNS: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).
- [21] Karen Simonyan y Andrew Zisserman. «Very deep convolutional networks for large-scale image recognition». En: *International Conference on Learning Representations*. 2015.
- [22] Guolin Ke et al. «Lightgbm: A highly efficient gradient boosting decision tree». En: *Advances in neural information processing systems*. Vol. 30. 2017.
- [23] Takuya Akiba et al. «Optuna: A next-generation hyperparameter optimization framework». En: *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*. 2019.
- [24] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep learning*. MIT press, 2016.
- [25] Sebastián Ramírez. *FastAPI*. 2018. URL: <https://github.com/fastapi/fastapi>.
- [26] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://www.python.org/>.
- [27] Dirk Merkel. «Docker: lightweight linux containers for consistent development and deployment». En: *Linux journal* (2014).
- [28] Oracle Corporation. *Oracle Cloud Infrastructure*. 2026. URL: <https://www.oracle.com/cloud/>.
- [29] Thierry Bertin-Mahieux et al. «The million song dataset». En: *Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR 2011)*. 2011.
- [30] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* (1998).
- [31] Bob L. Sturm. «The state of the art ten years after a state of the art: Future research in music information retrieval». En: *Journal of New Music Research* (2014).
- [32] Geoffroy Peeters. *A large set of audio features for sound description (similarity and classification) in the CUIDADO project*. Inf. téc. IRCAM (Institut de Recherche et Coordination Acoustique/Musique), 2004.
- [33] Andrada Olteanu. *GTZAN Dataset - Music Genre Classification*. 2020. URL: <https://www.kaggle.com/datasets/andradaolteanu/gtzan-dataset-music-genre-classification>.
- [34] Shawn Hershey et al. «CNN architectures for large-scale audio classification». En: *IEEE*. 2017.
- [35] ITU-R. «Algorithms to measure audio programme loudness and true-peak audio level». En: *Recommendation ITU-R BS.1770-4* (2015).
- [36] Alain De Cheveigné e Hideki Kawahara. «YIN, a fundamental frequency estimator for speech and music». En: *The Journal of the Acoustical Society of America* (2002).
- [37] Earl Vickers. «The loudness war: Background, speculation and recommendations». En: *Audio Engineering Society*. 2010.

- [38] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Science & Business Media, 2009.
- [39] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [40] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* (2011).
- [41] Max Kuhn y Kjell Johnson. *Applied Predictive Modeling*. Springer, 2013.
- [42] R. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [43] Gordon G. Bruner II. «Music, mood, and marketing». En: *Journal of Marketing* (1990).
- [44] le Guyon y André Elisseeff. «An introduction to variable and feature selection». En: *Machine Learning Research* (2003).
- [4] Frank W. Garlin y Kerl Owen. «Setting the tone with the tune: A meta-analytic review of the effects of background music in retail settings». En: *Journal of Business Research* (2006).
- [45] Holger Roschk, Sandra Maria Correia Loureiro y Jan Breitsohl. «Calibrating 30 years of experimental research: a meta-analysis of the atmospheric effects of music, scent, and color». En: *Journal of Retailing* (2017).
- [47] Plusyo Live SAS. Sitio web oficial. 2026. URL: <https://www.plusydc.com>.
- [6] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20. URL: <https://proceedings.scipy.org>.
- [48] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://www.essentialia.org/>.
- [50] *Learning for Humans*. O'Reilly Media, 2020.
- [9] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [10] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [11] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [12] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [13] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- [14] George Tzanetakis y Perry Cook. «Musical genre classification of audio signals». En: *IEEE Transactions on Speech and Audio Processing* (2002).
- [15] Michaël Defferrard et al. «FMA: A Dataset for Music Analysis». En: *18th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.
- [16] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Springer, 2015.
- [17] Alexander Lerch. *An introduction to audio content analysis: Applications in signal processing and music informatics*. John Wiley & Sons, 2012.

- [18] Emilia Gómez. «Tonal description of polyphonic audio for music content processing». En: *INFORMS Journal on Computing* (2006).
- [19] Christopher Harte, Mark Sandler y Martin Gasser. «Detecting harmonic change in musical audio». En: *Proceedings of the 1st ACM workshop on Audio and music computing multimedia*. 2006.
- [20] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).
- [21] Karen Simonyan y Andrew Zisserman. «Very deep convolutional networks for large-scale image recognition». En: *International Conference on Learning Representations*. 2015.
- [22] Guolin Ke et al. «Lightgbm: A highly efficient gradient boosting decision tree». En: *Advances in neural information processing systems*. Vol. 30. 2017.
- [23] Takuya Akiba et al. «Optuna: A next-generation hyperparameter optimization framework». En: *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*. 2019.
- [24] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep learning*. MIT press, 2016.
- [25] Sebastián Ramírez. *FastAPI*. 2018. URL: <https://github.com/fastapi/fastapi>.
- [26] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://www.python.org/>.
- [27] Dirk Merkel. «Docker: lightweight linux containers for consistent development and deployment». En: *Linux journal* (2014).
- [28] Oracle Corporation. *Oracle Cloud Infrastructure*. 2026. URL: <https://www.oracle.com/cloud/>.
- [29] Thierry Bertin-Mahieux et al. «The million song dataset». En: *Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR 2011)*. 2011.
- [30] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* (1998).
- [31] Bob L. Sturm. «The state of the art ten years after a state of the art: Future research in music information retrieval». En: *Journal of New Music Research* (2014).
- [32] Geoffroy Peeters. *A large set of audio features for sound description (similarity and classification) in the CUIDADO project*. Inf. téc. IRCAM (Institut de Recherche et Coordination Acoustique/Musique), 2004.
- [33] Andrada Olteanu. *GTZAN Dataset - Music Genre Classification*. 2020. URL: <https://www.kaggle.com/datasets/andradolteanu/gtzan-dataset-music-genre-classification>.
- [34] Shawn Hershey et al. «CNN architectures for large-scale audio classification». En: *IEEE*. 2017.
- [35] ITU-R. «Algorithms to measure audio programme loudness and true-peak audio level». En: *Recommendation ITU-R BS.1770-4* (2015).
- [36] Alain De Cheveigné e Hideki Kawahara. «YIN, a fundamental frequency estimator for speech and music». En: *The Journal of the Acoustical Society of America* (2002).
- [37] Earl Vickers. «The loudness war: Background, speculation and recommendations». En: *Audio Engineering Society*. 2010.

- [38] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Science & Business Media, 2009.
- [39] Christopher M Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [40] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* (2011).
- [41] Max Kuhn y Kjell Johnson. *Applied Predictive Modeling*. Springer, 2013.
- [42] Ron Kohavi. «A study of cross-validation and bootstrap for accuracy estimation and model selection». En: *Proceedings of the 14th International Joint Conference on Artificial Intelligence - Volume 2*. Morgan Kaufmann Publishers Inc. 1995.
- [43] Leo Breiman et al. *Classification and Regression Trees*. CRC press, 1984.
- [44] Isabelle Guyon y André Elisseeff. «An introduction to variable and feature selection». En: *Journal of Machine Learning Research* (2003).
- [45] Ilya Loshchilov y Frank Hutter. «Decoupled Weight Decay Regularization». En: *International Conference on Learning Representations*. 2019.
- [46] Peter J Huber. «Robust estimation of a location parameter». En: *The Annals of Mathematical Statistics* (1964).
- [47] Sergey Ioffe y Christian Szegedy. «Batch normalization: Accelerating deep network training by reducing internal covariate shift». En: *International Conference on Machine Learning*. PMLR. 2015.
- [48] Nitish Srivastava et al. «Dropout: a simple way to prevent neural networks from overfitting». En: *The Journal of Machine Learning Research* (2014).
- [49] Mark Treveil et al. *Introducing MLOps: How to scale machine learning in the enterprise*. O'Reilly Media, 2020.
- [50] Micha Gorelick y Ian Ozsvald. *High Performance Python: Practical Performant Programming for Humans*. O'Reilly Media, 2020.