

Asignación de características musicales para ambientación comercial

Ing. Carlos Alberto Rivas Araque

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Martín Moreyra (GatekeeperX)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Buenos Aires, junio de 2026

Resumen

En la presente memoria se describe el diseño e implementación de un sistema que extrae información de las canciones y las etiqueta automáticamente a partir de su audio. Este trabajo fue desarrollado para la empresa Plusyc Live con el fin de optimizar el armado de catálogos musicales destinados a la ambientación de distintos espacios comerciales.

Para la elaboración de este trabajo fueron fundamentales los conocimientos adquiridos durante la carrera sobre tratamiento de datos estadísticos, modelos de árboles de clasificación y regresión, perceptrones multicapa, aprendizaje por transferencia, y puesta en producción.

Índice general

Resumen	I
1. Introducción general	1
1.1. Extracción de información musical	1
1.2. Contexto de aplicación	1
1.3. Objetivos y alcance	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.3.3. Alcance	2
1.4. Estado del arte	3
1.4.1. Procesamiento digital de señales y extracción a bajo nivel . .	3
1.4.2. Modelos preentrenados y soluciones comerciales	3
1.4.3. Síntesis comparativa	4
2. Introducción específica	5
2.1. Fuentes de datos de canciones	5
2.2. Representaciones numéricas de la música	5
2.3. Información semántica del audio	7
2.4. Modelos de inteligencia artificial utilizados	8
2.5. Despliegue e integración	9
3. Diseño e implementación	11
3.1. Conjuntos de datos y extracción de atributos	11
3.1.1. Análisis comparativo de conjuntos de datos públicos	11
GTZAN	11
FMA estándar	12
Million Song Dataset (MSD)	13
AudioSet	13
3.1.2. Reducción de dimensionalidad mediante estadísticas	13
3.1.3. Definición del espacio de variables	16
3.2. Ejecución de tareas sobre el conjunto de datos	17
3.2.1. Distribución y tratamiento de las variables objetivo	17
Loudness	17
Key y Mode	18
Tempo	19
Acousticness, Danceability, Energy, Instrumentalness y Va- lence	20
Speechiness	21
Liveness	22
Top-5 primary mood	23
Top-5 secondary mood	24
Suggested genres	25

3.2.2.	Selección de variables de entrada	26
3.3.	Modelado y optimización	27
	Modelado mediante perceptrón multicapa (MLP)	27
	Modelado mediante Gradient Boosting (LightGBM)	28
	Optimización de hiperparámetros y regularización	28
3.4.	Arquitectura de despliegue e integración	29
3.4.1.	Diseño del servicio predictivo	29
3.4.2.	Flujo de integración	29
4.	Ensayos y resultados	31
4.1.	Resultados predictivos	31
4.1.1.	Acousticness, Danceability, Energy, Instrumentalness y Valence	31
4.1.2.	Loudness	33
4.1.3.	Key y Mode	35
4.1.4.	Suggested Genres	37
4.1.5.	Tempo	37
4.1.6.	Speechiness y Liveness	39
4.1.7.	Suggested Genre	40
4.2.	Validación productiva	44
5.	Conclusiones	45
5.1.	Conclusiones generales	45
5.2.	Próximos pasos	45
	Bibliografía	47

Índice de figuras

1.1. Interfaz de consulta en Tunebat	4
2.1. Representaciones visuales del audio	6
2.2. Probabilidades de detección semántica	8
3.1. Algoritmo de extracción de atributos	14
3.2. Proceso de reducción de dimensionalidad	15
3.3. Distribución de loudness	18
3.4. Distribución de key y mode	18
3.5. Distribución de tempo	19
3.6. Distribuciones de características perceptibles	20
3.7. Distribución de speechiness	21
3.8. Distribución de liveness	22
3.9. Distribución de primary mood	23
3.10. Distribución de frecuencias secondary mood	24
3.11. Distribución de frecuencias de suggested genres	25
3.12. Diagrama de despliegue e integración.	30
4.1. Curvas de aprendizaje del modelo MLP	31
4.2. Dispersión de valores reales vs. estimados para las cinco variables perceptibles con el modelo definitivo.	32
4.3. Top-15 variables predictivas del modelo MLP.	33
4.4. Curvas de aprendizaje del modelo LightGBM para <i>Loudness</i>	33
4.5. Dispersión de valores actuales vs. estimados para <i>Loudness</i>	34
4.6. Top-15 variables predictivas del modelo LightGBM para <i>Loudness</i>	34
4.7. Matriz de confusión para la clasificación de 24 clases de <i>Key</i> y <i>Mode</i>	36
4.8. Top-15 variables predictivas del modelo LightGBM para <i>Key</i> y <i>Mode</i>	37
4.9. Dispersión de valores reales vs. estimados para <i>Tempo</i> utilizando regresión con LightGBM. Se evidencia la incapacidad del modelo para generalizar fuera de la moda.	38
4.10. Múltiples relaciones lineales y de proporción entre el tempo real (etiqueta) y el extraído por DSP.	38
4.11. Superposición de distribuciones: Tempo real vs. estimación directa de Essentia (<i>tempo_bpm</i>).	39
4.12. Comparativa de dispersión entre los modelos preliminares (izquierda) y definitivos (derecha) para <i>Speechiness</i> y <i>Liveness</i> . Se observa la transición del colapso hacia la media a una capacidad real de discriminación de valores altos.	41
4.13. Top-15 variables predictivas para el modelo definitivo de <i>Speechiness</i>	42
4.14. Top-15 variables predictivas para el modelo definitivo de <i>Liveness</i>	42
4.15. Matriz de confusión normalizada para la clasificación de 197 géneros musicales.	43

4.16. Top-15 variables predictivas del modelo LightGBM para la sugere- ncia de género (<i>Suggested Genre</i>).	44
--	----

Índice de tablas

2.1. Atributos representativos	7
3.1. Desglose del espacio de variables	16
3.2. Distribución porcentual de speechiness antes y después del pre- procesamiento	22
3.3. Distribución porcentual de liveness antes y después del preproce- samiento	23
3.4. Resumen de parámetros usados en la selección de variables.	26
3.5. Resumen de hiperparámetros óptimos por objetivo.	29
4.1. Comparativa de métricas de los dos experimentos de la red neuro- nal MLP.	32
4.2. Comparativa de métricas globales entre el extractor de Essentia y las predicciones <i>Top-1</i> y <i>Top-3</i> del modelo LightGBM.	35
4.3. Estadísticas de la estimación directa de Essentia según la relación proporcional con el tempo real.	39
4.4. Comparativa de métricas entre el modelo preliminar DSP y los mo- delos definitivos con PANNs para <i>Speechiness</i> y <i>Liveness</i>	40

Capítulo 1

Introducción general

En este capítulo se introduce la definición de la extracción de información musical, se expone la problemática que motivó la búsqueda de una solución automatizada para la asignación de características musicales a partir del audio de canciones, y se detalla el alcance de la solución propuesta. Finalmente, se realiza una revisión general de las soluciones existentes.

1.1. Extracción de información musical

La extracción de información musical, comúnmente conocida como MIR (por su sigla en inglés, *Music Information Retrieval*), procesa, analiza y organiza datos musicales [1].

Los sistemas MIR abarcan el procesamiento digital de señales (DSP) y el aprendizaje automático, y permiten automatizar tareas como el etiquetado de canciones, la clasificación de géneros o el reconocimiento de estados de ánimo a partir del audio digital [2].

La aplicación de estas tecnologías en el contexto comercial resulta fundamental para la personalización y ambientación de espacios físicos. La literatura académica señala que la música de fondo (*background music*) no es un elemento pasivo, sino un factor ambiental estratégico. Investigaciones en el área muestran que componentes estructurales de la música alteran de forma predecible la excitación emocional (*arousal*), la percepción del tiempo y la intención de compra de los consumidores en entornos minoristas y de servicios [3, 4, 5].

Para lograr una personalización ambiental efectiva en cada comercio, es necesario seleccionar pistas musicales que se ajusten a criterios sonoros y emocionales específicos dictados por la identidad de cada marca. La curaduría manual resulta inescalable debido a la gran magnitud de los catálogos musicales; en consecuencia, es importante desarrollar un producto que implemente técnicas MIR para caracterizar automáticamente los archivos de audio de las canciones de grandes repositorios de audio, para el uso de las características en sistemas que llevan música a espacios comerciales, según las necesidades específicas de cada lugar.

1.2. Contexto de aplicación

El trabajo se realiza para dar respuesta a una necesidad tecnológica de Plusyc Live SAS [6], una empresa dedicada a la creación de experiencias musicales personalizadas para locales comerciales. La plataforma de la compañía crea listas de

reproducción basadas en las características musicales de un catálogo de canciones.

Anteriormente, la asignación de estas características dependía del consumo de interfaces de programación de aplicaciones (API) de terceros. Esta metodología generaba restricciones de disponibilidad, incrementos en los costos operativos y limitaba la autonomía de la empresa.

Con la implementación de este trabajo, la empresa cuenta con un sistema de inteligencia artificial que caracteriza automáticamente canciones a partir de su archivo de audio. Esto reduce la dependencia de servicios externos y mejora la escalabilidad y autonomía de la aplicación; de esta manera se fortalece la experiencia musical personalizada que la empresa ofrece a los comercios.

1.3. Objetivos y alcance

Esta sección define las metas. Se presenta el objetivo general y los objetivos específicos, y el conjunto de características musicales consideradas.

1.3.1. Objetivo general

Desarrollar un sistema basado en inteligencia artificial para predecir las características musicales de las canciones del catálogo de Plusyc Live a partir de su archivo de audio y reducir la dependencia de servicios de terceros.

1.3.2. Objetivos específicos

Para alcanzar el objetivo general, se definen los siguientes objetivos específicos:

- Seleccionar y analizar un conjunto de datos musicales pertinente para el entrenamiento de modelos de aprendizaje supervisado.
- Extraer representaciones numéricas y descriptores semánticos a partir de las señales de audio originales.
- Ejecutar el análisis exploratorio de datos (EDA) y el preprocesamiento de las variables.
- Entrenar modelos de aprendizaje supervisado para la predicción de las características objetivo.
- Evaluar el rendimiento de los modelos y seleccionar los de mejor desempeño.
- Desplegar los modelos en un entorno productivo para su integración operativa.

1.3.3. Alcance

El alcance de este trabajo comprende la predicción computacional de trece características musicales, que se agrupan en tres categorías principales:

- Básicas: tonalidad (key), modo (mode), tempo y volumen (loudness).

- Perceptibles: nivel acústico (acousticness), bailabilidad (danceability), energía (energy), instrumentalidad (instrumentalness), presencia de público (liveness), presencia de voz (speechiness) y positividad (valence).
- Clasificables por ánimo y género: estados de ánimo predominantes (primary moods), estados de ánimo secundarios (secondary moods) y géneros sugeridos (suggested genres).

Para cada una de las características mencionadas se busca cumplir con los objetivos específicos definidos.

1.4. Estado del arte

En el campo de la extracción de información musical existen diversas herramientas computacionales para el análisis de audio. Por un lado, se encuentran las bibliotecas de procesamiento digital de señales, que permiten extraer representaciones numéricas a partir de archivos de audio. Además, existen modelos preentrenados capaces de obtener información semántica y servicios comerciales orientados a inferir etiquetas de alto nivel.

1.4.1. Procesamiento digital de señales y extracción a bajo nivel

Existen bibliotecas de software para extraer descriptores numéricos de bajo nivel, como Librosa [7] y Essentia [8].

Las bibliotecas de procesamiento digital de señales proveen funciones para representar la señal digital en arreglos numéricos, como espectrogramas y cromagramas. Este tipo de transformaciones matemáticas son útiles para reducir la dimensionalidad de los archivos de audio y generar variables predictivas para modelos de aprendizaje automático.

1.4.2. Modelos preentrenados y soluciones comerciales

Para la predicción de características semánticas existen modelos de código abierto basados en aprendizaje profundo. Dos ejemplos son la arquitectura musicnn [9] y los modelos entrenados sobre el conjunto de datos AudioSet [10]. Estos sistemas clasifican etiquetas musicales generales. Su limitación principal radica en el uso de taxonomías fijas orientadas a los datos con los que fueron entrenados originalmente. La biblioteca Essentia también incorpora modelos preentrenados para inferir atributos semánticos, y por lo tanto se incluye en esta categoría.

Por su parte, soluciones comerciales como Spotify [11] y Gracenote [12] operan en la modalidad de software como servicio (SaaS) y entregan predicciones mediante su interfaz de programación de aplicaciones (API). La gran desventaja es que introducen costos operativos recurrentes y generan dependencia tecnológica hacia el proveedor.

También existen plataformas web que permiten consultar esta información de manera individual. Un ejemplo es Tunebat [13], que permite visualizar un conjunto de características, pero restringe la consulta a una canción a la vez. En la figura 1.1 se presenta un ejemplo de perfil de características musicales de una canción en la plataforma web Tunebat. En la interfaz se exponen algunas características, como la tonalidad (Si menor o *B Minor*), el *tempo* (153 BPM) y la duración.

Asimismo, la herramienta cuantifica algunas características en una escala porcentual de 0 a 100, mostrando para este caso específico niveles de acusticidad (77 %) e instrumentalidad (76 %), una baja probabilidad de presencia de habla (*speechiness* en 4 %) y público en vivo (*liveness* en 9 %), además de registrar el volumen medio en decibelios (-8 dB).




FIGURA 1.1. Ejemplo de visualización de características musicales en Tunebat¹.

1.4.3. Síntesis comparativa

Las tecnologías existentes ofrecen herramientas útiles para el objetivo del trabajo. Las bibliotecas de procesamiento digital de señales permiten extraer representaciones numéricas de las ondas sonoras, y los modelos preentrenados ofrecen representaciones semánticas. Por otro lado, las soluciones comerciales proveen servicios de etiquetado para canciones.

Sin embargo, persisten limitaciones operativas para su aplicación directa en el entorno de la empresa. Los servicios de terceros generan costos recurrentes, limitan la cantidad de consultas y crean dependencia tecnológica. Las plataformas web de uso manual no son viables para procesar catálogos con miles de canciones. Además, los modelos no coinciden con las características y las clases específicas que usa Plusyc Live.

Por estos motivos, resulta necesario desarrollar una solución propia. El propósito de este trabajo es aprovechar las técnicas actuales de inteligencia artificial para crear un sistema independiente. Esto permite analizar directamente los archivos de audio, etiquetarlos según las necesidades de la empresa y así reducir la dependencia de proveedores externos.

¹Imagen tomada de <https://tunebat.com/Info/Weird-Fishes-Arpeggi-Radiohead/4wajj1o7jWlg62YqpkHC7S>

Capítulo 2

Introducción específica

Este capítulo introduce las herramientas de terceros y las tecnologías necesarias para el desarrollo del sistema. Se describe la fuente de datos principal, las técnicas para extraer representaciones numéricas del audio, los modelos predictivos y las tecnologías utilizadas para el despliegue.

2.1. Fuentes de datos de canciones

Para el entrenamiento de los modelos predictivos se utilizó la colección privada de canciones de la empresa. Esta fuente de datos cuenta con más de 60 000 archivos de audio de canciones completas.

Se seleccionó este conjunto de datos por la disponibilidad en el acceso a la información y por su representatividad en ambientes comerciales reales. Por el contrario, otros conjuntos de datos públicos musicales, como GTZAN [14] y los subconjuntos estándar de FMA [15], ofrecen fragmentos limitados a 10 o 30 segundos de audio. El uso de pistas incompletas restringe la disponibilidad de la información musical. Realizar predicciones sobre el audio total resulta más preciso, ya que evita la pérdida de los eventos musicales que ocurren antes o después de una sola ventana. Además, estas alternativas carecen parcialmente de las variables objetivo requeridas en el alcance del trabajo.

El acceso a los archivos de audio de canciones completas garantiza la preservación de la estructura musical, evita la pérdida de información y flexibiliza la extracción de representaciones matemáticas mediante el uso de bibliotecas y modelos preentrenados.

El análisis comparativo de las fuentes de datos, las representaciones estadísticas de las canciones y los criterios de selección de variables predictivas se detallan en la sección 3.1 del siguiente capítulo.

2.2. Representaciones numéricas de la música

Una canción se traduce a un formato numérico para su procesamiento computacional. El procesamiento digital de señales (DSP) transforma la onda sonora en arreglos matemáticos de una o dos dimensiones [16, 17]. Entre las representaciones bidimensionales más destacadas se encuentran el espectrograma, el cromagrama y el espacio armónico o tonnetz. El espectrograma refleja la variación de las frecuencias a lo largo del tiempo [16]. Por su parte, el cromagrama captura la energía asociada a las doce clases de notas musicales [18]. Finalmente, el tonnetz

modela las relaciones tonales y armónicas de la pista [19]. A modo de ejemplo, en la figura 2.1 se ilustran estas tres transformaciones aplicadas a un fragmento de la canción “Weird Fishes/Arpeggi” de la banda Radiohead. En estos gráficos, el eje horizontal representa el tiempo, mientras que la intensidad del color indica la magnitud de la energía para las distintas frecuencias, notas musicales o relaciones tonales correspondientes a cada eje vertical.




FIGURA 2.1. Representación visual de un espectrograma, un cromagrama y un tonnetz.

Además de las representaciones bidimensionales, las bibliotecas de procesamiento de señales facilitan la extracción de atributos numéricos unidimensionales. En la tabla 2.1 se presenta un listado que introduce algunas de las características de bajo nivel más representativas en el análisis musical. En la elaboración del trabajo se usaron Librosa y Essentia en este proceso.

Estas transformaciones matemáticas reducen la dimensionalidad del archivo de audio. Sin embargo, carecen de significado semántico. Su función principal, en el

contexto de este trabajo, es la de generar las variables predictivas necesarias para entrenar modelos de aprendizaje automático.

El listado completo de las variables de entrada, el análisis de su relevancia y su impacto en el rendimiento de los algoritmos se detalla en la sección 3.2.2.

TABLA 2.1. Listado introductorio de los principales atributos de procesamiento de señales extraídos del audio.

Atributo	Descripción principal
MFCC	Coeficientes cepstrales que modelan la percepción auditiva humana [16].
Centroide espectral	Indica el centro de masa del espectro acústico. Se asocia al brillo del sonido [17].
Ancho de banda	Mide la dispersión de las frecuencias alrededor del centroide espectral [17].
Tasa de cruces por cero	Cuantifica la cantidad de cambios de signo en la señal temporal [17].
Rolloff espectral	Estima la frecuencia por debajo de la que se concentra la mayor parte de la energía [17].

2.3. Información semántica del audio

Las representaciones de bajo nivel descritas en la sección 2.2 no siempre son suficientes para capturar conceptos musicales complejos. Es posible mejorar la cobertura de la información musical con el aprendizaje por transferencia. Esta técnica consiste en utilizar modelos previamente entrenados con grandes volúmenes de datos para extraer características semánticas de alto nivel.

Para este fin existen bibliotecas especializadas, como PANNs Inference [20]. Esta herramienta provee acceso a redes neuronales optimizadas para el análisis de eventos sonoros. Dentro de sus opciones, destaca la arquitectura denominada CNN14, cuyo diseño se inspira en los modelos convolucionales profundos de la familia VGG [21]. Se trata de una red neuronal capaz de abstraer patrones del audio y generar *embeddings* numéricos basados en las clases del conjunto de datos AudioSet.

Un ejemplo de las probabilidades de detección obtenidas para distintas clases de eventos sonoros a lo largo del tiempo se visualiza en la figura 2.2, donde se muestran ventanas consecutivas de 10 segundos de la canción de Radiohead. En este mapa de calor, las áreas más claras indican una mayor probabilidad de activación para cada clase.

El uso de esta arquitectura permite transformar la onda sonora para extraer *embeddings* y obtener probabilidades asociadas a etiquetas predefinidas, como la presencia de aplausos, instrumentos musicales específicos o habla. Estos datos semánticos enriquecen el conjunto de variables de entrada para la inferencia de algunas de las características musicales que se definieron en el alcance del trabajo.




FIGURA 2.2. Mapa de calor de las características semánticas extraídas mediante la red CNN14.

2.4. Modelos de inteligencia artificial utilizados

Una vez obtenidos los descriptores numéricos y semánticos, es necesario aplicar algoritmos de predicción. Para este fin, se utilizaron dos enfoques principales:

- Algoritmos LightGBM: se integró la arquitectura LightGBM, basada en el ensamble de árboles de decisión. Esta herramienta destaca por su alta velocidad computacional y eficiencia en tareas generales de predicción [22]. En este caso también se usó Optuna para la búsqueda de parámetros óptimos [23].
- Redes MLP: los perceptrones multicapa son redes neuronales artificiales con capacidad para modelar relaciones complejas. Permiten, entre otras aplicaciones, predecir múltiples variables continuas de forma simultánea [24].

2.5. Despliegue e integración

La integración del sistema predictivo requirió del despliegue de una interfaz de programación de aplicaciones. Para su construcción se utilizó FastAPI [25] como marco de trabajo. Esta herramienta facilita el desarrollo de servicios web de alto rendimiento basados en Python [26]. El servicio fue contenedorizado con Docker [27]. El alojamiento remoto del producto se apoyó en los servicios de infraestructura de OCI (por su sigla en inglés, *Oracle Cloud Infrastructure*) [28]. Se provisionó una instancia de cómputo virtual en la nube para desplegar la aplicación y ejecutar los modelos predictivos. El uso de esta tecnología garantiza la disponibilidad continua del sistema.

Capítulo 3

Diseño e implementación

Este capítulo detalla el diseño y la implementación del sistema predictivo. Se analizan los conjuntos de datos utilizados, la extracción de atributos del audio y el tratamiento de datos según las distribuciones de las variables objetivo. Asimismo, se describen las técnicas de reducción y selección de variables, el proceso de optimización de los modelos y los resultados de la iteración productiva. Finalmente, se presenta la arquitectura desarrollada para el despliegue y la integración del sistema en un entorno operativo.

3.1. Conjuntos de datos y extracción de atributos

3.1.1. Análisis comparativo de conjuntos de datos públicos

La definición de la estrategia para la extracción de atributos se fundamenta en una revisión de conjuntos de datos públicos estandarizados en el ámbito MIR. El objetivo de este análisis previo fue entender cómo repositorios de referencia, como FMA y Million Song Dataset [29], representan y estructuran los datos musicales, como método para establecer los criterios de diseño del conjunto de datos propio.

En un comienzo se contempló el uso de algunos de estos conjuntos de datos, pero se encontró que presentan varias limitaciones frente a la solución propuesta: algunos restringen el análisis a segmentos cortos de audio, mientras que otros requieren tamaños de almacenamiento excesivamente pesados o estructuras de datos difíciles de replicar durante el proceso de inferencia y dependientes de las versiones de las bibliotecas de extracción.

Por otro lado, el análisis resultó positivo; estas restricciones motivaron que el proceso de extracción se ejecute directamente sobre el catálogo privado para eliminar las limitaciones y su análisis permitió conocer las variables numéricas en la música, cómo se segmentan las canciones, cómo se reduce la dimensionalidad y hacer los primeros experimentos predictivos de las variables objetivo requeridas.

GTZAN

Este conjunto de datos se considera el equivalente al MNIST [30] para el análisis de audio [31], dada su adopción histórica como estándar de evaluación en tareas de clasificación de géneros musicales. Con el análisis de este conjunto de datos se pudo identificar los siguientes puntos:

- Variables predictivas principales: tempo, representaciones chroma [18], amplitud media cuadrática (RMS) [17], descriptores espectrales [32] y coeficientes MFCC.
- Estructura: 1 000 archivos de audio en crudo limitados a 30 segundos, acompañados de metadatos tabulares e imágenes de espectrogramas de Mel en su versión distribuida mediante Kaggle [33]. Todas estas representaciones fueron extraídas con la biblioteca Librosa. Las tablas contienen los atributos calculados sobre la pista completa y también sobre divisiones de 3 segundos para incrementar el volumen de datos de entrenamiento. En ambos escenarios se aplica una reducción de dimensionalidad temporal: las variables se calculan inicialmente sobre micro-ventanas de milisegundos y luego se colapsan a valores estáticos mediante estadísticos de agregación, como la media y la varianza.
- Variables objetivo principales en Plusyc: se podría relacionar con *suggested genres*.
- Desventajas: provee segmentos cortos de audio, lo que limita la representatividad de la información musical a nivel de canción; y solo abarca 10 géneros musicales, mientras que Plusyc trabaja con más de 500.

FMA estándar

Se analiza la versión estándar de FMA, diseñada para superar las limitaciones de tamaño y acceso a las colecciones completa y mediana. Se encuentra:

- Variables predictivas principales: representaciones chroma, Transformada de Q Constante (CQT) [16], tonnetz, MFCC, RMS, descriptores espectrales y tasa de cruces por cero (ZCR).
- Estructura: ofrece recortes de audio de 30 segundos para sus subconjuntos estándar, acompañados de matrices de atributos precomputados distribuidos en formato tabular (CSV). Los atributos fueron extraídos con Librosa y posteriormente colapsados mediante estadísticos de agregación, como la media, desviación estándar, asimetría y curtosis, para obtener valores estáticos por pista.
- Metadatos contextuales: información tabular adicional que incluye álbum, artista, popularidad, fechas de lanzamiento y ubicación geográfica.
- Variables objetivo principales: géneros musicales estructurados en una taxonomía jerárquica de clases y para un subconjunto de aproximadamente 13 000 pistas, proporciona atributos como *danceability*, *energy*, *valence*, *speechiness* y *liveness*.
- Desventajas: el análisis está restringido a segmentos de 30 segundos en la versión estándar. Las versiones media y completa exceden las capacidades de procesamiento de la infraestructura actual de la empresa. Además, la incertidumbre sobre las versiones exactas de Librosa utilizadas originalmente dificulta la replicabilidad técnica sobre canciones nuevas. Finalmente, la información etiquetada de 13 000 pistas es mucho menor que la de más de 60 000 de Plusyc.

Million Song Dataset (MSD)

Desarrollado por la Universidad de Columbia y The Echo Nest, este conjunto escaló la investigación de información musical a nivel industrial. Se describen sus componentes principales:

- Variables predictivas principales: representaciones de tono (chroma y pitch) [18, 16] y descriptores de timbre [32], ambos calculados a nivel de segmento.
- Estructura: colección de metadatos y descriptores precomputados empaquetados en archivos HDF5.
- Método de extracción: a diferencia de la segmentación por ventanas fijas, el MSD utiliza una división adaptativa basada en eventos. Esto fragmenta la canción en segmentos de duración variable. Para cada uno de estos segmentos, se calculan coeficientes de tono y timbre, y se genera una matriz de atributos alineada con la estructura temporal de la pista.
- Variables objetivo principales: proporciona atributos musicales fundamentales como *tempo*, *loudness*, *key* y *mode*.
- Desventajas: los descriptores se generaron con algoritmos propietarios de The Echo Nest, lo que complica procesar la segmentación por eventos en canciones nuevas de forma idéntica para realizar el proceso de inferencia.

AudioSet

Este conjunto masivo establece un estándar para la clasificación de eventos sonoros generales:

- Estructura: conjunto de identificadores de videos de YouTube y marcas de tiempo que referencian segmentos de 10 segundos, anotados bajo una ontología de 527 clases.
- Variables predictivas principales: el corpus original no extrae descriptores tradicionales. Su distribución oficial provee embeddings precomputados mediante el modelo VGGish [34], que sirven como entrada rápida para entrenar clasificadores de terceros sin necesidad de descargar el audio original.
- Variables objetivo principales: etiquetas multiclase que identifican la presencia de instrumentos musicales, como tipos de voces (habla, canto) y ambientes acústicos.
- Desventajas: el enfoque en sonidos generales limita su precisión para los atributos musicales.

Cabe mencionar que, a pesar de que en algunas de las fuentes de datos públicas se incluye información del contexto como la región del artista, el año de lanzamiento, el álbum o las letras, en esta solución se trabaja exclusivamente con información musical que se extrae del audio.

3.1.2. Reducción de dimensionalidad mediante estadísticas

En el ámbito del procesamiento de señales, la información de un archivo de audio se representa como una serie de tiempo multivariada: una secuencia de puntos

de datos [16], en este caso, descriptores numéricos y semánticos, indexados y ordenados cronológicamente.

La estrategia adoptada se inspiró en los conjuntos de datos de referencia, donde la señal se divide en ventanas temporales y la información de cada ventana se colapsa en valores estáticos. Esto permite reducir estas secuencias a un vector por cada canción, para optimizar el uso de la memoria y los tiempos de procesamiento. El diagrama de flujo de este algoritmo se muestra en la figura 3.1, donde se observa como la extracción ocurre en ramas paralelas para la transformación de la señal a un vector de estadísticos.




FIGURA 3.1. Algoritmo de extracción de atributos.

En la rama de la izquierda se observa la extracción de variables (DSP) y a la derecha la extracción de embeddings y probabilidades semánticas con PANNs inference:

- Para la extracción de variables (DSP) se utilizan las bibliotecas Librosa y Essentia sobre la señal continua, el algoritmo extrae las series temporales de las características principales, por ventanas de 64 ms de longitud y solapamiento de 16 ms, que proporciona una alta resolución temporal original de

la señal [16, 17]. También se extrae información global de la canción, descriptores escalares para la pista entera que complementan la información segmentada.

- Para la extracción de embeddings y probabilidades se estableció una ventana de análisis de 10 segundos continuos. Esta decisión se fundamenta en la arquitectura de la red neuronal CNN14, entrenada sobre el conjunto de datos AudioSet, cuyos segmentos originales son de 10 segundos. El algoritmo extrae un vector de embeddings y las probabilidades de activación para 173 clases de eventos musicales provistas por PANNs inference por cada ventana.
- Agrupación estadística: dado que una canción estándar produce una cantidad variable de segmentos, se aplicó una técnica de colapso estadístico a lo largo del eje temporal, según el tipo de variable:
 - Para las variables (DSP), se calcularon siete estadísticos por pista: media, desviación estándar, asimetría, curtosis, y los percentiles 10 (cerca del mínimo), 50 (mediana) y 90 (cerca del máximo para evitar ruido).
 - Para los embeddings y las probabilidades semánticas de las 173 clases seleccionadas de PANNs, se calcularon cuatro medidas: media, valor máximo, desviación estándar y el percentil 90.

Este enfoque matemático permite comprimir el volumen masivo de información de una serie de tiempo en un vector unidimensional por canción. Una representación empírica de este proceso se ilustra en la figura 3.2, donde se observa visualmente cómo las matrices dinámicas de la pista se colapsan en vectores tras el cálculo estadístico. La visualización muestra solo algunos ejemplos, la media en algunos DSP y el percentil 90 en algunas clases del AudioSet.




FIGURA 3.2. Visualización de la reducción de dimensionalidad: las secuencias temporales (izquierda) se transforman en vectores (derecha) mediante la aplicación de medidas de agregación.

Algunos experimentos preliminares sirvieron para validar que esta representación permitía capturar la información esencial de la canción de manera eficiente y compacta. El algoritmo de extracción, es el resultado de pruebas con distintas configuraciones de variables, estadísticos y métodos de segmentación.

3.1.3. Definición del espacio de variables

El procesamiento computacional sobre el catálogo de canciones requirió más de una semana de ejecución para procesar y extraer la información de más de 60 000 canciones completas. El alto costo computacional se justificó por la necesidad de garantizar la disponibilidad de información para los experimentos de modelos predictivos de múltiples características musicales.

La aplicación del algoritmo final generó un conjunto de datos masivo compuesto por 9590 variables, resumido en la tabla 3.1.

TABLA 3.1. Desglose estructural de las 9590 variables extraídas por canción.

Categoría de extracción	Atributos base	Cant.	Estadísticos aplicados	Cant.	Total
Representaciones DSP (Librosa)	MFCC (20), Deltas (40) [17], Centroide, Ancho de banda, Rolloff, Contraste (7) [32], Flatness y Flux [32], Chroma (12), Tonnetz (6), RMS, ZCR.	92	Media, Desv. Estándar, Asimetría, Curtosis, Percentiles (10, 50, 90).	7	644
Atributos globales y ritmo	LUFS [35], Entropía espectral [17], Tempo, Complejidad dinámica [17], Tasa y estadísticos de onset (4) [16], Pitch, Fracción de voz [36], Claridad tonal (2) [16], Factor de cresta [32], Desviación de latidos [16].	14	Cálculo único por pista completa.	1	14
Estimación tonal (Perfiles)	Vectores de correlación Krumhansl (Mayor/Menor) y Temperley (Mayor/Menor) [16].	48	Cálculo único por pista completa (4 perfiles $\times$ 12 semitonos).	1	48
Embeddings semánticos (PANNs)	Vector latente de la capa previa a la clasificación de la red CNN14.	2048	Media, Máximo, Desv. Estándar, Percentil 90.	4	8192
Probabilidades (PANNs)	Clases filtradas (Voz, Instrumentos, Géneros, Público en vivo, Distorsión).	173	Media, Máximo, Desv. Estándar, Percentil 90.	4	692

Total de variables por canción: 9590

3.2. Ejecución de tareas sobre el conjunto de datos

Esta sección presenta las variables objetivo y sus distribuciones en el contexto de Plusyc, el tratamiento aplicado a los datos y las técnicas de selección y reducción de variables predictivas.

3.2.1. Distribución y tratamiento de las variables objetivo


Durante la extracción de variables descrita en el algoritmo de la sección 3.1.2, se aplicaron dos estrategias adicionales para el tratamiento de los datos previos al modelado:

- Recorte de silencios y manejo de valores nulos: tras la primera iteración de extracción de variables (DSP), se detectó la presencia de valores nulos y ceros en algunas variables. El análisis exploratorio reveló que eran generados por las colas de silencio o fade-outs prolongados al final de las pistas. Para corregirlo, se aplicó un algoritmo de recorte de segmentos con amplitud inferior a -60 dB. Esta operación eliminó la gran mayoría de los nulos. El restante se concentró exclusivamente en un 6 % del descriptor `spectral_entropy_global`. Matemáticamente, el cálculo de la entropía espectral requiere normalizar la magnitud del espectro para interpretarlo como una distribución de probabilidad. En ventanas de análisis correspondientes a silencios absolutos, la energía espectral es nula [17].
- Filtrado del etiquetado manual: al analizar las variables objetivo, se identificó un cambio en una fecha específica en la fuente de los datos: hasta mediados de diciembre de 2024, los valores provenían de la integración con una API externa. Los registros generados durante 2025, ingresados manualmente por el equipo de curadores, introdujeron error, caracterizado por la presencia de valores por fuera del rango en variables discretas, valores extremos en cero y uno en variables continuas. Para proteger el entrenamiento de los modelos, el conjunto de datos de análisis fue truncado para conservar únicamente los registros fiables hasta diciembre de 2024. Resulta en el uso de un 92,5 % aproximado de las canciones del catálogo de Plusyc y aplica para todas las variables, excepto para géneros y estados de ánimo donde la información no dependía de la API.

A continuación, se presentan las distribuciones de las variables objetivo después del filtrado y el preprocesamiento adicional aplicado.

Loudness

El *loudness* define el volumen global promedio de la pista acústica en decibeles (dB) (ej. -5,2 dB o -12,4 dB). Los valores más negativos indican menor intensidad [37]. La figura 3.3 muestra la distribución de frecuencia de los valores del *loudness*. Se observa que presenta un sesgo negativo, con una concentración principal cerca de los -7 dB. Esto se explica dada la guerra del *loudness* [38], donde muchos artistas y productores buscan que sus canciones suenen con volumen alto, y plataformas como Spotify normalizan el *loudness* para evitar cambios abruptos en el volumen entre las canciones.

FIGURA 3.3. Distribución de *loudness* en el catálogo de Plusyc.

Se observan dos desafíos principales inherentes a la distribución:


- Existencia de asimetría negativa (sesgo a la izquierda).
- Presencia de valores extremos negativos (hasta -60 dB).

Esto potencialmente podría generar un error matemático que desvíe la atención del algoritmo durante el entrenamiento [24]. Se aplicaron las siguientes transformaciones como parte del preprocesamiento:

- Se aplicó una transformación logarítmica desplazada (Shifted Log-Transformation). Primero, se realizó una traslación de la escala $(y + 60, 1)$ para garantizar que todos los registros fueran estrictamente mayores a cero.
- Posteriormente, se aplicó la función matemática $\log(1 + x)$ ('np.log1p'). Este preprocesamiento comprime la cola izquierda de la distribución, mitiga el sesgo original y estabiliza la varianza para mejorar el rendimiento del modelo de regresión [24].

Key y Mode

Las variables *key* y *mode* representan la tonalidad predominante de la pista mapeada a clases de tono enteras (ej. 0 para Do, 1 para Do#) y su modalidad armónica (1 para Mayor, 0 para Menor) [37]. La figura 3.4 muestra la distribución conjunta de las frecuencias de los valores discretos de las 24 tonalidades de la música occidental. Se observa preferencia por tonalidades como Do mayor, Re mayor y Sol mayor; y menor frecuencia de canciones en Re sostenido mayor y menor.

FIGURA 3.4. Distribución conjunta de *key* y *mode* en el catálogo de Plusyc.

Algunos desafíos inherentes a la distribución:

- Existe un desbalance marcado en las tonalidades, lo que propicia que los modelos de clasificación colapsen hacia las clases mayoritarias [24].
- Los algoritmos de aprendizaje automático requieren que las variables categóricas (como las notas musicales) estén representadas en un formato numérico procesable.

Se siguieron las siguientes estrategias como parte del preprocesamiento:

- Para adaptar las etiquetas alfanuméricas de las tonalidades al entrenamiento, se aplicó codificación de etiquetas (Label Encoding).
- Para mitigar el desbalance sin eliminar información musical intrínseca, el problema se abordó directamente en la fase de modelado mediante la ponderación de clases (`class_weights='balanced'`).

Se decide abordar el problema de clasificación conjunto de *key* y *mode* como una variable categórica con 24 clases (12 tonalidades $\times$ 2 modos). El motivo de la decisión se basa en que el caso de equivocación, o falso *mode*, es más problemático que el de *key* y *mode*, ya que afecta la familia armónica. La predicción de un top-k de *key* y *mode* conjuntos, generalmente muestran relaciones armónicas de la canción, esto tiene sentido en el contexto de la ambientación.

Tempo

El *tempo* indica la velocidad global estimada de la pista en pulsaciones por minuto (ej. 120 BPM u 85 BPM) [37]. La figura 3.5 muestra la distribución de frecuencia de los valores del *tempo*. Se observa una concentración principal en el rango de los 90 a 130 BPM, con un pico destacado alrededor de los 120 BPM, predominante en la música popular contemporánea [16].




FIGURA 3.5. Distribución de *tempo* en el catálogo de Plusyc.

Se encuentra que *tempo* es un caso especial ya que presenta errores de octava métrica:

- Se identificaron inconsistencias en las etiquetas, donde el valor objetivo registrado representaba exactamente la mitad, el doble o proporciones fraccionarias (ej. 1,5x) del tempo real. Este es un problema documentado en la extracción de información musical conocido como error de octava (octave error) [16].

- Este problema puede explicar la presencia de valores atípicos en los extremos de la distribución.
- La presencia de errores de octava complica el uso de algoritmos de regresión lineal ya que se observan múltiples relaciones lineales entre variables rítmicas predictivas y el tempo global (ej. predecir 60 BPM para una pista etiquetada en 120 BPM).

Se contempla la evaluación de los algoritmos DSP de estimación de *tempo* integrados en las bibliotecas de DSP, esta comparación se muestra en la sección de validación.

Acousticness, Danceability, Energy, Instrumentalness y Valence

Este grupo comprende variables perceptibles continuas evaluadas en el rango $[0, 1]$: *acousticness*: confianza acústica, *danceability*: bailabilidad métrica, *energy*: intensidad energética, *instrumentalness*: ausencia vocal y *valence*: positividad musical [37]. La figura 3.6 muestra las distribuciones de frecuencia de los valores de estas características.




FIGURA 3.6. Distribuciones de características perceptibles en el catálogo de Plusyc.

Aunque todas comparten un rango de $[0, 1]$, presentan comportamientos distintos: *danceability* muestra una distribución aproximadamente normal; *energy* presenta sesgo negativo; *valence* tiende a la uniformidad; mientras que *acousticness* y

de forma extrema, *instrumentalness*, exhiben un sesgo positivo con una concentración masiva de valores cercanos a cero.

El modelado conjunto de múltiples características se aborda convencionalmente mediante redes neuronales, como el Perceptrón Multicapa (MLP), dada su capacidad para aprender de forma simultánea las relaciones complejas y dependencias no lineales entre ellas [24]. Bajo esta premisa, el preprocesamiento requiere prestar atención específica en:

- La heterogeneidad en las formas de las distribuciones y sus varianzas. En arquitecturas sensibles a la escala, como los MLP, las variables con mayor varianza empírica pueden dominar el cálculo de los gradientes, ralentizar o sesgar la convergencia de los pesos [24].
- Las MLP son sensibles a los valores nulos y están presentes en un 6 % de `spectral_entropy_global`.

Se implementaron las siguientes medidas:

- A diferencia del *loudness*, las variables objetivo ya se encuentran acotadas matemáticamente en el intervalo $[0, 1]$. Por tanto, no requirieron transformaciones, ya que este rango es compatible con las funciones de activación continuas, como la sigmoid, en la capa de salida de la red neuronal.
- Se garantizó la integridad de la matriz de características al imputar los nulos residuales con el valor cero y así reflejar la falta de información acústica.
- Finalmente, se aplica estandarización estadística (StandardScaler) a todo el conjunto de entrada para garantizar una media de cero y varianza unitaria ($\mu = 0, \sigma^2 = 1$). Este paso es necesario para homogeneizar el espacio de variables predictivas para el entrenamiento de la red neuronal [24].

Speechiness

El *speechiness* detecta la presencia de palabras habladas en la pista y se define en $[0, 1]$, donde valores altos indican contenido exclusivamente hablado y valores bajos indican música (ej. 0,85 para conversación, 0,05 para música y 0,5 es rap) [37]. La figura 3.7 muestra la distribución de frecuencia del *speechiness*.




FIGURA 3.7. Distribución de *speechiness* en el catálogo de Plusyc.

La distribución muestra la presencia de un sesgo positivo extremo, ya que el catálogo musical carece de pistas de palabra hablada pura y concentra los valores

muy cerca de cero. Los valores cerca del uno indican contenido exclusivamente hablado como podcast o streaming conversacional, ausentes en el catálogo de Plusyc.

El mejor resultado experimental en términos de las métricas de evaluación se obtuvo al aplicar técnicas de submuestreo. Se discretizó el dominio de la variable en rangos estratégicos y se aplicó un submuestreo con tope por rangos para limitar la cantidad de registros en la moda, reducir el sesgo y conservar la totalidad de registros de la cola. Los rangos se presentan en la Tabla 3.2.

TABLA 3.2. Distribución porcentual de speechiness antes y después del preprocesamiento

Intervalo	Descripción del Rango	% Original	% Final
[0, 00, 0, 05]	Menor presencia de canto	56,0 %	42,1 %
(0, 05, 0, 33]	Canto	41,9 %	42,1 %
(0, 33, 1, 00]	Rap	2,1 %	15,7 %
Total		100 %	100 %

Cabe mencionar que se aplicó muestreo estratificado a nivel de los rangos durante la división de conjuntos de entrenamiento y pruebas. Finalmente, se mitigó el ruido en las etiquetas al eliminar un porcentaje menor de registros contradictorios: se compararon los valores de la variable objetivo con la evidencia acústica vocal en las probabilidades de clases como *speech* y *rapping* extraídas de PANNs para descartar las pistas que presentaban discrepancias entre su etiqueta manual y su contenido semántico real.

Liveness

El *liveness* representa la confianza de que la pista fue grabada con público en vivo [0, 1], (ej. 0,85 para un concierto, 0,10 para un estudio) [37]. La figura 3.8 muestra la distribución de frecuencia del *liveness*.




FIGURA 3.8. Distribución de *liveness* en el catálogo de Plusyc.

Esta distribución, como en el caso anterior, también muestra la presencia de un sesgo positivo extremo, ya que concentra la inmensa mayoría de los registros por debajo de 0,2. Adicionalmente, se identificó un problema de ruido sistemático en las etiquetas manuales, donde pistas de estudio con una alta percepción de energía o intensidad eran catalogadas erróneamente como "vivo".

Se aplicó una técnica similar a la anterior para balancear el objetivo continuo, se dividió el dominio con base en la definición teórica de la característica y se aplicó un submuestreo con tope por rangos. Se aplicó reducción en la clase mayoritaria y en la zona intermedia para evitar sesgos y se conservan todos los registros minoritarios de la clase de interés: canción en vivo. El resultado de esta reestructuración se detalla en la Tabla 3.3.

TABLA 3.3. Distribución porcentual de liveness antes y después del preprocesamiento

Intervalo	Descripción del Rango	% Original	% Final
[0, 0, 0, 2)	Muy baja probabilidad de vivo	74,4 %	67,4 %
[0, 2, 0, 8)	Baja probabilidad de vivo	24,8 %	22,5 %
[0, 8, 1, 0]	Alta probabilidad de vivo	0,8 %	10,1 %
Total		100 %	100 %

Como en el caso de *speechiness*, también se aplica muestreo estratificado por rangos durante la separación de conjuntos de entrenamiento y pruebas. Y se implementó un filtrado cruzando la variable objetivo con la evidencia de presencia de audiencia extraída por la red PANNs, de las probabilidades de clases asociadas a multitudes, aplausos y aclamaciones. Se descartaron las pistas que presentaban discrepancias severas para eliminar ruido (ej. registros etiquetados como 'en vivo' sin evidencia de sonido de público, o viceversa).

Top-5 primary mood

El *primary mood* define el estado de ánimo o emoción predominante que transmite la pista (ej. *Energizing*, *Lively*, *Empowering*). La figura 3.9 muestra los *primary mood* de Plusyc y sus frecuencias.




FIGURA 3.9. Distribución de *primary mood* en el catálogo de Plusyc.

Se observan los siguientes desafíos en esta variable categórica:

- Alta cardinalidad y un marcado desbalance de clases, donde ciertas emociones predominan debido a la orientación comercial y de ambientación del catálogo. Algunas clases se han dejado de usar en el pasado.

- La predicción se fundamenta exclusivamente en variables numéricas extraídas del audio, ya que se carece de información de lenguaje, como las letras de las canciones.
- Ambigüedad; incluso para un humano, algunos de los estados de ánimo pueden ser confusos.

Se aplicaron las siguientes transformaciones como parte del preprocesamiento:

- Se definió con el negocio prescindir de las clases minoritarias *Urgent*, *Aggressive*, *Upbeat* y *Fiery* que no son usadas para ambientación.
- Submuestreo de clases mayoritarias para equilibrar la distribución con techo de 2 000 muestras por clase.
- Aplicación de Label Encoding para traducir las categorías de texto a un formato numérico procesable.
- Para mitigar el desbalance, se aplicó la técnica de ponderación de clases (`class_weights='balanced'`) directamente durante la fase de modelado.

Top-5 secondary mood

El *secondary mood* identifica los estados de ánimo complementarios (ej. *Euphoric Energy*, *Energetic Anxious*). La figura 3.10 muestra las frecuencias de los *secondary mood* de Plusyc. Las clases más populares del catálogo son *Cheerful / Playful* con 4 322 muestras, *Happy Excitement* con 3 738 y *Sweet / Sincere* con 3 154.




FIGURA 3.10. Distribución de frecuencias de *secondary mood* en el catálogo de Plusyc.

En este caso las dificultades son similares al caso de *primary mood*, en el desbalance de clases, pero con mayor cardinalidad, con 100 clases en total. Además de la delgada frontera en muchos de los estados de ánimo que incluso para el humano resultan confusos.

Medidas aplicadas en el preprocesamiento:

- Se define con el negocio prescindir de las clases minoritarias *Aggressive Power*, *Alienated / Brooding*, *Bittersweet Pop*, *Chaotic / Intense*, *Creepy / Ominous*, *Energetic Dreamy*, *Evocative / Intriguing*, *Focused Sparkling*, *Hard Dark Excitement*, *Heavy Triumphant*, *Hypnotic Rhythm*, *Mysterious / Dreamy*, *Wild / Rowdy* que no son usadas para ambientación en Plusyc.

- Submuestreo de clases mayoritarias para equilibrar la distribución con techo de 1 000 muestras por clase.
- Al igual que con el estado de ánimo principal, se aplicó Label Encoding para la adaptación numérica.
- Se mantuvo la estrategia de balanceo (`class_weights='balanced'`) para evitar sesgos.

Suggested genres

Los *suggested genres* indican las etiquetas de género musical asociadas a la pista (ej. *Chill House*, *EDM*). La figura 3.11 muestra las frecuencias de los *suggested genres*. Las clases más populares del catálogo son *EDM* con 819 muestras, *Pop Vocal* con 764 y *General Latin Pop* con 708.




FIGURA 3.11. Distribución de frecuencias *suggested genres* en el catálogo de Plusyc.

Se observa la extrema diversidad de clases, 585 en total y muchas clases con muy pocas muestras, lo que genera una distribución de cola larga altamente desbalanceada. Por otro lado al revisar algunas clases aparecen géneros que no son géneros sino marcas o artistas como *Shakira*, *Juanes* o *Decathlon*. Otra dificultad radica en que al analizar solo el audio, se puede perder el contexto regional de géneros como *Rock*, *Latin Rock*, que podrían ser confusos en las predicciones.

Se aplicaron las siguientes estrategias:

- Se filtran géneros que no son géneros musicales, sino marcas o artistas.
- Se seleccionan un tope mínimo de 100 muestras por clase para el modelo. De las 585 clases totales, se seleccionan 200 clases que cumplen el criterio y se determinó que las demás quedan pendientes de alcanzar el mínimo de 100 muestras para ser incluidas en el entrenamiento.
- Submuestreo de clases mayoritarias para equilibrar la distribución con techo de 400 muestras por clase.
- Transformación de las categorías mediante Label Encoding.
- Delegación del manejo del desbalance al hiperparámetro de ponderación (`class_weights='balanced'`) durante el entrenamiento del clasificador.

- Estrategia de clasificación por top-k, para mitigar el problema de contexto al seleccionar los más probables.

3.2.2. Selección de variables de entrada

La aplicación del algoritmo de extracción generó un espacio predictivo masivo compuesto por 9590 variables. Modelar directamente sobre esta dimensionalidad introduce riesgo de sobreajuste y alto costo computacional [39, 40]. Por ello, la estrategia de diseño trasladó el esfuerzo hacia el proceso de selección de variables predictivas.

Para todas las variables objetivo, el proceso de selección se ejecutó estrictamente sobre los datos de entrenamiento (X_{train}) para evitar sobreajuste, mediante un flujo secuencial de tres etapas:

1. Filtro por varianza: se implementó `VarianceThreshold` [41] para evaluar cada característica de forma aislada y descartar aquellas constantes o sin varianza (umbral 0,00). Se aplicó un umbral de 0,01 en objetivos de alta cardinalidad para purgar características dispersas que carecen de valor predictivo [42].
2. Selección basada en árboles, con las siguientes características:
 - El cálculo de la importancia se realizó predominantemente mediante un entrenamiento simple, para priorizar la eficiencia computacional. Excepcionalmente, en las variables perceptibles continuas, se implementó validación cruzada (K-Fold con $K = 5$) para mitigar el sobreajuste al ruido en este tipo de etiquetas subjetivas [43].
 - La métrica utilizada fue la ganancia (Gain) para medir el aporte de las variables en las particiones de los árboles [44, 22].
 - Se conservaron únicamente las características con mayor importancia, responsables de explicar el 95 % de la ganancia acumulada del modelo.
3. Filtro por dependencia lineal: se calculó la matriz de correlación de Pearson para analizar las características en conjunto y eliminar aquellas que presentaban redundancia lineal [45, 42].

En la tabla 3.4 se resume la configuración del proceso y el total de variables predictivas resultantes para cada variable objetivo.

TABLA 3.4. Resumen de parámetros usados en la selección de variables.

Variable	Varianza	Validación	Colinealidad	Total
<i>Key y Mode</i>	0,00	Simple	–	173
<i>Loudness</i>	0,00	Simple	–	856
<i>Perceptibles (5)</i>	0,00	K-Fold ($K = 5$)	$> 0,95$	2140
<i>Speechiness</i>	0,00	Simple	$> 0,95$	92
<i>Liveness</i>	0,00	K-Fold ($K = 5$)	$> 0,95$	67
<i>Primary Mood</i>	0,01	Simple	$> 0,95$	1423
<i>Secondary Mood</i>	0,01	Simple	$> 0,95$	1397
<i>Suggested Genres</i>	0,01	Simple	$> 0,95$	1309

La columna 'Varianza', indica el umbral del filtro por varianza, 'Validación', indica el tipo de validación utilizada (Simple o K-Fold), y 'Colinealidad', indica el umbral de correlación para el filtro por dependencia lineal.

3.3. Modelado y optimización

Modelado mediante perceptrón multicapa (MLP)

Para la predicción de las cinco variables perceptibles (*acousticness, danceability, energy, instrumentalness, valence*), se implementó una red neuronal de tipo perceptrón multicapa. La arquitectura diseñada consta de tres capas ocultas con una reducción progresiva de neuronas (512, 256 y 128 neuronas, respectivamente). La capa de salida cuenta con cinco neuronas y emplea una función de activación sigmoid, para garantizar que las predicciones se acoten dentro del rango físico $[0, 1]$.

Para la optimización de pesos se empleó el algoritmo AdamW [46]. Este método incorpora un desacoplamiento de la penalización de peso (weight decay) para favorecer la generalización. Como función de pérdida se seleccionó Huber Loss debido a su robustez frente a valores atípicos en las etiquetas subjetivas [47, 39]. Su ventaja radica en combinar el comportamiento del error absoluto medio (MAE) para penalizar los errores grandes y el del error cuadrático medio (MSE) para los errores pequeños y así asegurar una convergencia suave al acercarse a la solución óptima. Por último, el entrenamiento se ejecutó en lotes de 512 muestras.

Para el ajuste de los hiperparámetros de aprendizaje, la tasa inicial se fijó en 10^{-4} y fue gestionada dinámicamente mediante `ReduceLROnPlateau`. Este mecanismo redujo la tasa de aprendizaje a la mitad automáticamente al detectar estancamientos.

Dado el amplio espacio de variables (2 140 variables de entrada) y la alta capacidad del modelo, se implementó la siguiente estrategia de regularización para mitigar el sobreajuste [24]:

- Capas de normalización por lotes (Batch Normalization) después de cada transformación lineal ($Wx + b$) en `nn.Linear`, para evitar que los valores numéricos se disparen entre las capas y facilitar la convergencia [48].
- Inactivación aleatoria de neuronas (Dropout) con tasas de 0,30 en la primera capa oculta y 0,20 en las subsiguientes, como filtro más agresivo de ruido en las variables iniciales y proteger las representaciones más abstractas en las capas profundas [49].
- Penalización L2 (regularización de Tikhonov) integrada en el optimizador con un factor de 10^{-5} .
- Parada anticipada (Early Stopping) basada en el conjunto de validación que interrumpió el entrenamiento tras 15 iteraciones sin mejoras.

Modelado mediante Gradient Boosting (LightGBM)

Para la predicción del resto de las variables, se implementaron modelos basados en árboles de decisión potenciados por gradiente, LightGBM [22]. Esta arquitectura se seleccionó por su eficiencia computacional al procesar espacios dimensionales complejos y su capacidad para modelar relaciones no lineales sin requerir transformaciones y tratamiento de valores atípicos en las variables de entrada.

El diseño de los modelos se adaptó a la naturaleza de cada variable objetivo, con base en el preprocesamiento detallado en etapas anteriores:

- *Key / Mode, Primary, Secondary Moods y Suggested Genres*: mayor peso a las clases minoritarias mediante el parámetro `class_weight='balanced'` y se evaluó el desempeño con la métrica F1-Score macro.
- *Liveness, Speechiness*: la separación de los conjuntos de entrenamiento y validación se ejecutó de forma estratificada tras discretizar las variables en rangos probabilísticos.
- *Loudness*: la optimización evaluó el error absoluto medio (MAE), y el modelado definitivo se configuró mediante regresión estándar (L2) para minimizar el error cuadrático medio (RMSE). Esto demostró una mejora en la predicción en volúmenes extremos.

Optimización de hiperparámetros y regularización

Se implementó una búsqueda automatizada de hiperparámetros para cada objetivo mediante la librería Optuna [23]. A continuación un resumen de los parámetros y algunas decisiones relacionadas:

- Profundidad máxima de los árboles (`max_depth`) y restricción en el número máximo de hojas (`num_leaves`) para evitar el crecimiento asimétrico descontrolado. Además, se exigió un volumen mínimo de muestras por hoja (`min_child_samples` o `min_data_in_leaf`) para evitar que los modelos crearan reglas exclusivas para registros aislados [22].
- Submuestreo de filas y columnas para mejorar la generalización. En la mayoría de los modelos se utilizó el algoritmo (GBDT) combinado con un submuestreo de filas aleatorio (`subsample`). Excepto para *Loudness*, donde se implementó el algoritmo de muestreo basado en gradientes (GOSS) [22], para retener ejemplos con mayor error predictivo y descartar una fracción de las que el modelo ya aprendió.
- Penalizaciones (L1 y L2) para frenar el peso excesivo de las ramas [39]. Adicionalmente, en la mayoría de los objetivos, se exigió una mejora mínima (`min_split_gain`) antes de permitir que el árbol se dividiera.
- Early stopping, configurado entre 30 y 50 iteraciones, para interrumpir el entrenamiento cuando el modelo dejara de mejorar.

El resumen de los hiperparámetros resultantes se detalla en la tabla 3.5. Para el entrenamiento de los modelos finales, se configuró una alta cantidad de árboles (hasta 10 000 en algunos casos) y se delegó el control total al mecanismo de early stopping. Esto, combinado con tasas de aprendizaje muy bajas, mejora el desempeño [39].

TABLA 3.5. Resumen de hiperparámetros óptimos por objetivo.

Objetivo	Prof. Máx.	Hojas	Tasa de Apren.	Muestras/Hoja	L1 (α)	L2 (λ)
<i>Key/Mode</i>	5	140	0,0259	34	3,1690	6,9757
<i>Loudness</i>	10	21	0,0868	25	0,0104	0,0390
<i>Liveness</i>	4	15	0,0194	17	0,0107	0,3887
<i>Speechiness</i>	8	34	0,0102	32	0,4942	0,2947
<i>Primary Mood</i>	10	32	0,0208	79	0,1084	5,0239
<i>Secondary Mood</i>	11	35	0,0125	69	0,1443	2,6547
<i>Genres</i>	6	28	0,0606	21	0,9334	4,8052

3.4. Arquitectura de despliegue e integración

El sistema de inferencia fue diseñado para operar como un servicio integrable con la infraestructura existente de Plusyc. El despliegue se realizó en una instancia de cómputo sobre Oracle Cloud Infrastructure.

3.4.1. Diseño del servicio predictivo

El núcleo de procesamiento se expuso a través de una API RESTful desarrollada con FastAPI. Esta interfaz expone el ciclo de inferencia: carga del audio, extracción de variables predictivas de entrada a los modelos MLP y LightGBM, que retornan los valores de las predicciones de las características musicales.

Para garantizar la reproducibilidad y estabilidad del entorno, la aplicación fue contenedorizada utilizando Docker. Dada la alta exigencia computacional y de memoria del modelo preentrenado PANNs inference, se aplicaron configuraciones a nivel de contenedor para asegurar la viabilidad en producción:

- Se limitó a una instancia. Esto previene la duplicación masiva de los modelos y pesos preentrenados en la memoria RAM, para optimizar el consumo de los recursos de la máquina virtual y evitar nuevos costos [50].
- Restricción de hilos: las operaciones matemáticas requeridas para la extracción de variables se restringieron a un solo hilo (`OMP_NUM_THREADS=1`). Esto evita cuellos de botella por saturación de la CPU y bloqueos cruzados (deadlocks) durante la extracción paralela de variables [51].
- Gestión de memoria y tiempo de respuesta: se asignó un bloque de memoria compartida (`shm_size: '5gb'`) y se establecieron timeouts holgados (120 segundos) para prevenir interrupciones provocadas por el análisis de pistas de audio de larga duración, restringidas a 15 máximo máximo por canción.

3.4.2. Flujo de integración

La interacción del motor predictivo con el ecosistema web se realiza a través de un flujo de procesamiento asíncrono. La comunicación entre componentes es orquestada por una herramienta de Plusyc denominada Beethoven.

El ciclo de vida de la integración, ilustrado en la figura 3.12, sigue esta secuencia lógica:

1. Una tarea programada (cron job) en el sistema ejecuta el CLI Beethoven a intervalos regulares de tiempo.
2. El proceso detecta nuevos archivos de audio que aún no han sido caracterizados.
3. Por cada nueva pista detectada, Beethoven envía el archivo al servicio de inferencia (API) mediante una petición HTTP POST.
4. **Inferencia:** La API ejecuta el pipeline predictivo, que recibe la señal cruda y retorna un diccionario estructurado (JSON) que contiene todas las etiquetas estimadas (*Key, Moods, Liveness, etc.*).
5. El script captura la respuesta de la API, extrae las características musicales y las persiste en la base de datos de información musical de Plusyc.
6. Una vez en la base de datos, los metadatos quedan disponibles para revisión de curadores en un portal web.




FIGURA 3.12. Diagrama de despliegue e integración.

Capítulo 4

Ensayos y resultados

Este capítulo presenta los resultados de los modelos seleccionados para cada variable objetivo, su comparación con un experimento previo, los resultados de su evaluación con métricas de inteligencia artificial y su desempeño en un entorno de producción.

4.1. Resultados predictivos

4.1.1. Acousticness, Danceability, Energy, Instrumentalness y Valence

En un ensayo preliminar, se entrenó un modelo multisalida únicamente con variables DSP para predecir siete variables en total, con *Liveness* y *Speechiness*, que comparten el rango continuo de valores entre 0 y 1. Con este enfoque se obtuvo un rendimiento insuficiente, incapaz de predecir valores altos de *Liveness* y *Speechiness*, pero con métricas aceptables para las 5 variables restantes. Así se identificó la necesidad de separar las dos variables en preprocesamiento y la extracción de variables semánticas específicas de voz y presencia de público. De aquí se llegó a PANNs inference.

El modelo definitivo se reestructuró para las 5 variables restantes y se incorporaron los embeddings y probabilidades de PANNs. En el entrenamiento se observa que la tasa de aprendizaje se disminuyó dinámicamente desde el $1,00 \times 10^{-4}$ inicial hasta $1,00 \times 10^{-6}$, al responder a los estancamientos en la función de pérdida, tal como se esperaba en el diseño descrito en la sección de diseño de la red neuronal 3.3. Finalmente, el mecanismo de early stopping detuvo el proceso en la iteración 74, después de 15 épocas sin reducir el error de validación mínimo de 0,0058, alcanzado en la iteración 59. La figura 4.1 ilustra las curvas de aprendizaje del modelo durante el entrenamiento.



FIGURA 4.1. Curvas de aprendizaje del modelo MLP

La evolución de la pérdida de Huber a la izquierda y el MAE a la derecha, demuestran una convergencia rápida y estable. En ambos casos, las curvas de validación y entrenamiento se cruzan y estabilizan alrededor de las iteraciones 12 y 20, respectivamente. A partir de este punto, la validación se mantiene constante mientras el error de entrenamiento presenta un descenso marginal y evidencian aprendizaje sin sobreajuste.

La tabla 4.1 muestra cómo la inclusión de embeddings y probabilidades de PANNs inference y la separación de *speechiness* y *liveness* mejoró consistentemente todas las métricas, con mejor R^2 global de 0,8152.

TABLA 4.1. Comparativa de métricas de los dos experimentos de la red neuronal MLP.

Variable	R^2 ($\uparrow$)		MAE ($\downarrow$)		MSE ($\downarrow$)	
	Inicial	Definitivo	Inicial	Definitivo	Inicial	Definitivo
<i>Acousticness</i>	0,8178	0,8903	0,0950	0,0681	0,0171	0,0106
<i>Danceability</i>	0,6042	0,7381	0,0780	0,0594	0,0108	0,0063
<i>Energy</i>	0,7584	0,8626	0,0809	0,0581	0,0110	0,0062
<i>Instrumentalness</i>	0,6733	0,8308	0,1231	0,0671	0,0355	0,0188
<i>Valence</i>	0,6523	0,7539	0,1172	0,0964	0,0221	0,0162
<i>Liveness</i>	0,1570	–	–	–	–	–
<i>Speechiness</i>	0,2778	–	–	–	–	–

La figura 4.2 muestra los resultados de los valores reales de las etiquetas y las estimaciones del modelo multisalida definitivo. En estos gráficos de dispersión, la línea diagonal de referencia representa el escenario de predicción perfecta. La proximidad y densidad de los puntos respecto a esta recta ilustran visualmente el nivel de precisión, el control de la varianza en los extremos y la capacidad de generalización frente a datos no vistos.




FIGURA 4.2. Dispersión de valores reales vs. estimados para las cinco variables perceptibles con el modelo definitivo.

Un análisis de importancia de variables predictivas muestra predominio de atributos globales y ritmo de la tabla 3.1. La figura 4.3 presenta las 15 variables más relevantes del modelo MLP. En la figura, el grado de importancia equivale a la caída en el coeficiente de determinación (R^2) que sufre el modelo al eliminar la información de dicha variable. Se destaca el impacto principal del Factor de cresta, representaciones chroma y estadísticos de onset. También es interesante la ausencia de embeddings y probabilidades de PANNs en el top 15, pero muchas están presentes entre las variables seleccionadas (2 140 en total), lo que muestra que operan en conjunto





FIGURA 4.3. Top-15 variables predictivas del modelo MLP.

4.1.2. Loudness

Para la estimación de la variable continua *Loudness*, se implementó un modelo de regresión potenciado por gradiente mediante LightGBM. La optimización inicial utilizó muestreo unilateral basado en gradientes (GOSS) y una función objetivo basada en la penalización L1 (*regression_l1*). La figura 4.4 expone las curvas de aprendizaje para esta configuración, donde se observa un descenso suave y continuo de los errores de entrenamiento y validación a medida que se suman árboles al modelo. La trayectoria estrictamente paralela de ambas curvas y su estabilización conjunta evidencian un aprendizaje estable.

FIGURA 4.4. Curvas de aprendizaje del modelo LightGBM para *Loudness*.

Esta primera configuración alcanzó un coeficiente de determinación (R^2) de 0,8300,

un RMSE de 1,8534 y un MAE de 1,1469. Para evaluar posibles mejoras en la predicción de valores atípicos, se entrenó una segunda configuración equivalente empleando regresión con penalización L2 (`regression_l2`). Las métricas globales obtenidas fueron competitivas y ligeramente superiores en varianza explicada, logrando un R^2 de 0,8367, un RMSE de 1,8167 y un MAE de 1,1889.

A pesar de la similitud en el desempeño cuantitativo general, el modelo con penalización L2 se seleccionó como el definitivo debido a su superioridad para estimar valores en el extremo de la distribución, es decir audios con muy bajo volumen. La figura 4.5 compara gráficamente el comportamiento de ambas configuraciones. A la izquierda, el modelo L1 presenta mayor dispersión en los valores inferiores, mientras que a la derecha, las estimaciones del modelo L2 se concentran con mayor precisión sobre la diagonal de predicción perfecta.




FIGURA 4.5. Dispersión de valores actuales vs. estimados para *Loudness*.

El análisis de importancia de variables, evaluado mediante la métrica de ganancia (*gain*) en las divisiones de los árboles, confirma el impacto directo de los atributos globales. La figura 4.6 detalla las 15 características predictivas principales. El modelo prioriza fuertemente el Factor de cresta y los LUFs, seguidos de estadísticos de las representaciones DSP tradicionales como el RMS y el Centroide espectral. A diferencia de las variables perceptibles analizadas en la sección anterior, en este modelo sí destaca la presencia de un embedding de PANNs dentro del conjunto de mayor relevancia.




FIGURA 4.6. Top-15 variables predictivas del modelo LightGBM para *Loudness*.

4.1.3. Key y Mode

Para la predicción conjunta de la tonalidad y el modo (*Key* y *Mode*), el problema se abordó como una clasificación multiclase de 24 categorías (12 tonalidades mayores y 12 menores). Se implementó un modelo LightGBM optimizado para la métrica de pérdida logarítmica multiclase (`multi_logloss`). Durante el entrenamiento, la función de parada anticipada (*early stopping*) detuvo el proceso en la iteración 736 al estabilizarse la pérdida de validación en 1,1926.

La evaluación global del modelo alcanzó una exactitud (*accuracy*) de 0,6106 y un F1-Score ponderado de 0,6115. Destaca un AUC-ROC promedio de 0,9589, lo que indica una alta capacidad de discriminación entre las 24 clases. Adicionalmente, la exactitud Top-3 alcanzó un notable 0,8671, demostrando que la tonalidad correcta se encuentra casi siempre entre las tres primeras predicciones del sistema.

La figura 4.7 presenta la matriz de confusión absoluta. El análisis de los errores revela una fuerte coherencia armónica: cuando el modelo se equivoca en la predicción principal con datos no vistos, las confusiones más frecuentes ocurren con la tonalidad relativa (mayor o menor correspondientes) o con las tonalidades dominante y subdominante.

Para contextualizar el desempeño, se compararon estos resultados con el extractor de tonalidad de la librería de estado del arte Essentia. La tabla 4.2 demuestra que el modelo LightGBM entrenado supera holgadamente a la herramienta de referencia en todas las métricas globales, con una mejora cercana a los 18 puntos porcentuales en exactitud y 20 puntos en F1-Score ponderado.

La evaluación global del modelo alcanzó métricas muy superiores a los estándares tradicionales. Destaca un AUC-ROC ponderado de 0,9579, lo que indica una alta capacidad de discriminación entre las 24 clases.

Para contextualizar este desempeño, la tabla 4.2 contrasta los resultados del extractor de tonalidad de la librería Essentia con las predicciones exactas (*Top-1*) y flexibles (*Top-3*) del modelo LightGBM. El algoritmo entrenado supera holgadamente a la herramienta de referencia en todas las métricas. Adicionalmente, al evaluar el *Top-3*, la exactitud y el F1-Score escalan por encima del 86 %, demostrando que la tonalidad correcta se encuentra casi siempre entre las tres primeras opciones sugeridas por el sistema.

TABLA 4.2. Comparativa de métricas globales entre el extractor de Essentia y las predicciones *Top-1* y *Top-3* del modelo LightGBM.

Métrica	Essentia	Modelo LightGBM	
		<i>Top-1</i>	<i>Top-3</i>
Exactitud (<i>Accuracy</i>)	0,4291	0,6106	0,8671
F1-Score (Macro)	0,3780	0,5971	0,8589
F1-Score (Ponderado)	0,4076	0,6115	0,8672
AUC-ROC (Ponderado)	–	0,9579	0,9579

Finalmente, el análisis de importancia de variables predictivas confirma la relevancia lógica de los atributos armónicos detallados previamente en el diseño de

Matriz de confusión Key / Mode

Valores actuales	C Minor	168	8	1	11	8	10	0	0	1	3	0	21	1	0	35	4	0	0	34	3	0	28	1	1
	C Major	13	626	1	14	7	5	6	3	33	12	0	0	29	1	12	53	0	3	24	35	0	4	80	3
	C# Minor	1	0	192	12	2	2	4	25	0	3	1	0	3	25	1	3	31	2	1	3	18	1	0	5
	C# Major	1	9	9	362	55	1	3	7	0	6	16	0	0	0	55	4	8	30	0	9	10	36	0	1
	A# Minor	5	4	1	57	245	4	3	1	1	3	13	0	0	0	34	4	2	15	3	3	2	31	3	2
	A# Major	11	4	0	1	13	231	0	1	11	2	0	7	0	1	12	12	0	2	27	4	0	1	1	2
	B Minor	0	3	4	2	6	1	337	12	0	54	0	0	44	4	1	0	43	2	2	20	2	1	2	18
	B Major	0	0	11	7	7	0	6	192	1	0	6	2	4	7	1	0	8	13	0	2	26	1	1	2
	D Minor	2	22	0	3	1	5	1	1	218	10	0	1	1	1	0	29	1	0	20	5	0	1	21	0
	D Major	2	2	5	6	1	2	63	2	16	478	0	1	15	1	0	0	18	2	15	43	1	3	15	27
	D# Minor	0	0	0	3	17	2	0	12	1	2	65	2	0	0	2	1	0	19	0	0	13	1	0	0
	D# Major	11	0	0	1	5	6	0	0	1	2	0	121	1	2	5	1	0	2	6	2	1	16	1	0
	E Minor	0	11	2	1	0	2	50	1	1	23	0	0	301	5	0	0	10	4	0	52	0	1	40	13
	E Major	0	1	34	1	2	1	4	10	1	2	0	0	11	193	0	2	7	1	1	1	7	0	2	14
	F Minor	32	6	0	27	38	16	0	0	5	1	1	14	1	1	272	9	2	5	23	3	0	52	4	1
	F Major	2	32	1	6	4	19	3	0	45	5	0	1	5	2	11	324	0	2	20	7	0	1	21	3
	F# Minor	2	3	39	11	1	0	25	4	1	6	1	0	4	17	2	1	220	6	0	4	10	0	2	27
	F# Major	0	3	6	27	27	1	5	11	0	1	14	0	1	0	4	2	13	187	1	3	18	1	0	2
	G Minor	14	14	1	3	3	34	0	0	25	7	0	8	0	1	7	15	1	1	255	12	0	7	13	2
	G Major	0	51	1	7	4	0	36	1	12	54	0	1	75	0	10	5	3	7	16	562	1	10	51	0
	G# Minor	0	0	15	18	4	0	3	29	0	1	12	2	2	2	0	2	4	12	2	3	101	2	1	3
	G# Major	40	2	5	19	23	4	3	3	0	6	0	18	0	1	33	2	5	0	14	6	2	280	0	0
	A Minor	2	47	0	3	3	2	5	0	23	14	1	0	36	4	0	10	1	1	3	27	0	1	389	10
	A Major	0	3	20	4	0	3	24	3	1	22	0	0	11	12	0	5	33	0	0	6	2	3	23	394
	C Minor																								
	C Major																								
	C# Minor																								
	C# Major																								
	A# Minor																								
	A# Major																								
	B Minor																								
	B Major																								
	D Minor																								
	D Major																								
	D# Minor																								
	D# Major																								
	E Minor																								
	E Major																								
	F Minor																								
	F Major																								
	F# Minor																								
	F# Major																								
	G Minor																								
	G Major																								
	G# Minor																								
	G# Major																								
	A Minor																								
	A Major																								
		Predicciones																							

FIGURA 4.7. Matriz de confusión para la clasificación de 24 clases de Key y Mode.

la solución. La figura 4.8 detalla que las decisiones del algoritmo dependen principalmente del *Pitch*, las redes tonales (*Tonnetz*), representaciones *Chroma* y los perfiles de estimación tonal (como la fuerza tonal de *Temperley*).




FIGURA 4.8. Top-15 variables predictivas del modelo LightGBM para *Key* y *Mode*.

A nivel general, el análisis transversal de los tres modelos desarrollados (*Perceptibles*, *Loudness* y *Key/Mode*) evidencia que las características DSP tradicionales y sus diversos estadísticos mantienen el dominio como las variables de mayor impacto predictivo, complementadas transversalmente por los *embeddings* semánticos (PANNs) que operan en conjunto para refinar la generalización.

4.1.4. Suggested Genres

4.1.5. Tempo

A diferencia del caso de *Key* y *Mode*, la estimación del *Tempo* representó una excepción en el flujo de trabajo, siendo un escenario donde los extractores directos de librerías DSP (como *Essentia*) superaron significativamente el rendimiento del modelado predictivo estándar.

Un ensayo inicial utilizando un modelo de regresión con LightGBM —manteniendo el mismo diseño de variables predictivas que los modelos anteriores— demostró ser insuficiente. La evaluación de este modelo arrojó un Error Absoluto Medio (MAE) de 14,8394, un RMSE de 26,7187 y un coeficiente de determinación (R^2) prácticamente nulo de 0,0543. Como se evidencia en la figura 4.9, el modelo de regresión solo presenta capacidad predictiva alrededor de la moda (aproximadamente 120 BPM). Fuera de ese rango central, el algoritmo sobrestima los valores inferiores y subestima los superiores, fallando en capturar la relación con la variable objetivo.

Este bajo rendimiento no obedece a un déficit en la extracción de características, sino al fenómeno de multiplicidad descrito durante el preprocesamiento de los datos. La figura 4.10 ilustra que la relación entre las etiquetas reales y los valores extraídos algorítmicamente no conforma una única línea recta continua, sino




FIGURA 4.9. Dispersión de valores reales vs. estimados para *Tempo* utilizando regresión con LightGBM. Se evidencia la incapacidad del modelo para generalizar fuera de la moda.

múltiples relaciones lineales superpuestas, generadas por la ambigüedad en la percepción de los compases y la confusión de octavas rítmicas (medios tiempos, dobles tiempos, etc.).




FIGURA 4.10. Múltiples relaciones lineales y de proporción entre el tempo real (etiqueta) y el extraído por DSP.

Ante la imposibilidad de que una regresión lineal mapee correctamente este ruido estructural en las etiquetas, se optó por analizar las predicciones directas de la librería de estado del arte Essentia. La figura 4.11 superpone la distribución del tempo real con el extraído (*tempo_bpm*), evidenciando una similitud estadística sumamente alta entre ambas curvas.

Para validar esta elección, se analizó el comportamiento del error segmentado por las distintas proporciones métricas detectadas en el conjunto de datos. La tabla 4.3




FIGURA 4.11. Superposición de distribuciones: Tempo real vs. estimación directa de Essentia (`tempo_bpm`).

desglosa esta información, donde se aprecia que el 85,3 % de las pistas presentan una relación directa ($y \approx x$) con un error medio casi nulo de 0,0091 BPM.

TABLA 4.3. Estadísticas de la estimación directa de Essentia según la relación proporcional con el tempo real.

Relación (y vs. x)	Proporción (%)	Cantidad	Media de error	Desv. Est. (σ)
$y \approx x$	85,3	45.002	0,0091	2,1743
$y \approx 0,5x$	5,7	3.003	-0,0734	3,3490
$y \approx 2x$	3,2	1.682	-0,1027	2,5812
$y \approx 0,67x$	3,0	1.604	7,3190	6,9215
$y \approx 1,5x$	2,8	1.472	-3,8125	8,2052

Las métricas finales de Essentia terminan de ratificar su fiabilidad. En una comparación directa estricta ($x = y$), se obtiene un MAE de 12,81 BPM y una exactitud del 80,3 % (dentro de un margen de tolerancia de ± 5 BPM). Sin embargo, al flexibilizar la evaluación para incorporar las relaciones armónicas rítmicas válidas (mitad, doble, etc.), el error absoluto medio se reduce a **1,45 ($\pm 4,02$) BPM**, con un **92,4 %** de las pistas clasificadas correctamente dentro de la tolerancia.

Estos resultados evidencian que el atributo DSP `tempo_bpm` de Essentia captura la estructura rítmica real de manera mucho más precisa que cualquier intento de forzar una regresión sobre datos inherentemente ambiguos. Por tanto, se estableció prescindir de modelos predictivos adicionales y emplear directamente esta variable extraída como el resultado final para *Tempo*.

4.1.6. Speechiness y Liveness

Tal como se evidenció en la evaluación del modelo multisalida preliminar, las variables *Speechiness* y *Liveness* presentaron un rendimiento deficiente cuando se intentaron predecir exclusivamente con representaciones DSP. El modelo inicial fue incapaz de generalizar los valores altos de estas distribuciones, obteniendo coeficientes de determinación (R^2) sumamente bajos (0,2796 y 0,1640, respectivamente). Este comportamiento motivó su separación analítica y la incorporación de los *embeddings* y probabilidades de la red preentrenada PANNs para capturar el contexto semántico necesario.

Tras el preprocesamiento independiente y la optimización de hiperparámetros, se entrenaron modelos específicos para cada variable. La tabla 4.4 contrasta las métricas del experimento preliminar frente a los modelos definitivos, evidenciando un salto de rendimiento sustancial. En *Speechiness*, el R^2 escaló a 0,6748, reduciendo el MAE a 0,0405. Por su parte, el modelo definitivo de *Liveness* alcanzó un R^2 de 0,6318.

TABLA 4.4. Comparativa de métricas entre el modelo preliminar DSP y los modelos definitivos con PANNs para *Speechiness* y *Liveness*.

Variable	R ² (↑)		MAE (↓)		RMSE (↓)	
	Inicial	Definitivo	Inicial	Definitivo	Inicial	Definitivo
<i>Speechiness</i>	0,2796	0,6748	0,0570	0,0405	0,1024	0,0675
<i>Liveness</i>	0,1640	0,6318	0,0978	0,0811	0,1392	0,1301

La mejora predictiva se observa gráficamente en la figura ?? . A diferencia del modelo inicial que colapsaba hacia la media, las estimaciones definitivas logran identificar correctamente los valores atípicos. En *Speechiness* (izquierda), el modelo demuestra capacidad para detectar audios con alto contenido de voz hablada, como pistas de rap o intermedios vocales. En *Liveness* (derecha), el algoritmo penaliza con valores bajos a las grabaciones de estudio puras y logra extender sus predicciones para reconocer las pistas capturadas en vivo.

El análisis de la importancia de características confirma el impacto absoluto del contexto semántico introducido por PANNs, operando en sinergia con el procesamiento de señales.

Para *Speechiness* (ver figura 4.13), las variables de mayor peso son directamente las probabilidades de las clases 0000 (*Speech*) y 0156 (*Song*), demostrando que el modelo aprendió a discriminar eficientemente entre la voz hablada y el canto melódico. Asimismo, es notable la presencia de características dinámicas como los deltas de los coeficientes MFCC y el flujo espectral (*Spectral flux*). Estas representaciones DSP son fundamentales porque capturan las transiciones rápidas, el ruido silábico y la naturaleza percusiva típica del fraseo en el rap o el habla, los cuales carecen de las vocales sostenidas del canto.

Por otro lado, la predicción de *Liveness* (ver figura 4.14) está monopolizada casi en su totalidad por la arquitectura PANNs. El modelo extrae su poder predictivo de los *embeddings* latentes y, de manera explícita, de las desviaciones estándar y medias probabilísticas de las clases 0022 (*Applause*), 0021 (*Cheering*) y 0024 (*Crowd*). Esto evidencia que la percepción de "música en vivo" para la máquina, al igual que para el oyente humano, no depende tanto de la acústica de la sala o de los instrumentos, sino de la detección algorítmica de la respuesta del público.

4.1.7. Suggested Genre

El problema de clasificar el género musical representó el desafío computacional y semántico más complejo del proyecto debido a la alta granularidad de las etiquetas. Se implementó un clasificador LightGBM (*gbdt*) para distinguir entre 197 géneros y subgéneros. Al tratarse de una cantidad masiva de clases (muchas de ellas con una base rítmica o tímbrica similar), la evaluación priorizó la capacidad




FIGURA 4.12. Comparativa de dispersión entre los modelos preliminares (izquierda) y definitivos (derecha) para *Speechiness* y *Liveness*. Se observa la transición del colapso hacia la media a una capacidad real de discriminación de valores altos.




FIGURA 4.13. Top-15 variables predictivas para el modelo definitivo de *Speechiness*.




FIGURA 4.14. Top-15 variables predictivas para el modelo definitivo de *Liveness*.

del modelo para generar un abanico de sugerencias coherentes de cara al usuario final.

Las métricas globales sobre el conjunto de prueba alcanzaron una exactitud (*accuracy*) y un F1-Score (Macro y Ponderado) cercanos a 0,47. Si bien predecir el género exacto (*Top-1*) arroja un 46,74 % de aciertos, el rendimiento del algoritmo escala drásticamente al analizar las estimaciones flexibles. La exactitud *Top-3* alcanza un 68,32 %, mientras que la exactitud *Top-5* asciende al 77,31 %. Esto significa que, en casi 8 de cada 10 casos, el modelo ubica el género correcto del audio entre sus primeras cinco sugerencias.

La figura 4.15 presenta la matriz de confusión normalizada. Debido a la densidad de las 197 clases, la diagonal principal resalta la concentración de aciertos, pero también expone un alto nivel de dispersión fuera de la diagonal.




FIGURA 4.15. Matriz de confusión normalizada para la clasificación de 197 géneros musicales.

Un análisis cualitativo de las predicciones erróneas del modelo (*Top-1*) demuestra que el algoritmo no fracasa de forma aleatoria, sino que sus confusiones poseen una fuerte coherencia acústica y de contexto. Al observar las estimaciones del *Top-5*, se evidencia lo siguiente:

- **Agrupación por familia rítmica:** Un audio etiquetado como *Minimal House* fue clasificado erróneamente como *Funk House*, pero el *Top-5* estuvo compuesto exclusivamente por subgéneros de la música electrónica bailable (*Contemporary House*, *Tech House*, *Chicago House*).
- **Cruce de estéticas vocales y armónicas:** Una pista de *Trap Soul* se confundió con *Neo-Soul* y *Contemporary R&B*. De igual manera, un audio de *Alternative Based R&B/Soul* fue asignado a *Downtempo* y *Neo-Soul*. El modelo detecta correctamente los *grooves* lentos, los bajos profundos y los arreglos vocales sofisticados, confundiendo etiquetas que los propios críticos y curadores humanos suelen debatir.
- **Similitud de instrumentación:** Una pista de *Latin Traditional* fue catalogada como *Jazz Vocals*. Es altamente probable que la presencia de ensambles acústicos, metales e improvisación vocal haya inducido al modelo a priorizar la textura general del ensamble por encima del ritmo folclórico específico.

Finalmente, la importancia de las características predictivas, expuesta en la figura 4.16, revela que el modelo no se apoya en características semánticas de alto nivel (como los *embeddings*), sino en el análisis físico fundamental del sonido.

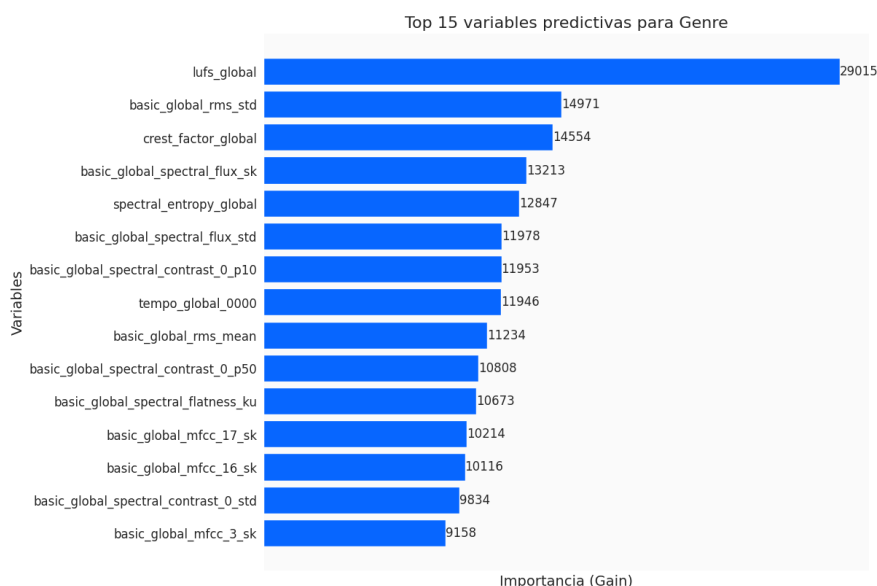


FIGURA 4.16. Top-15 variables predictivas del modelo LightGBM para la sugerencia de género (*Suggested Genre*).

Para discriminar entre 197 géneros, el algoritmo prioriza fuertemente la intensidad (LUFS y RMS) y las características macro del espectro: la presencia de transientes rítmicos (*Crest factor* y *Spectral flux*), el brillo (*Spectral entropy*) y el contraste espectral, el cual resulta vital para diferenciar arreglos instrumentales densos (como una orquesta de salsa) de géneros minimalistas (como el *Lo-Fi* o el *Minimal House*).

4.2. Validación productiva

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [4] Franck V Garlin y Keri Owen. «Setting the tone with the tune: A meta-analytic review of the effects of background music in retail settings». En: *Journal of Business Research* (2006).
- [5] Holger Roschk, Sandra Maria Correia Loureiro y Jan Breitsohl. «Calibrating 30 years of experimental research: a meta-analysis of the atmospheric effects of music, scent, and color». En: *Journal of Retailing* (2017).
- [6] Plusyc Live SAS. *Perfil oficial en Instagram*. 2026. URL: <https://www.instagram.com/plusyc/>.
- [7] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20. 2015. URL: <https://librosa.org/>.
- [8] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- [9] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [10] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [11] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [12] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [13] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- [14] George Tzanetakis y Perry Cook. «Musical genre classification of audio signals». En: *IEEE Transactions on Speech and Audio Processing* (2002).
- [15] Michaël Defferrard et al. «FMA: A Dataset for Music Analysis». En: *18th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.
- [16] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Springer, 2015.

- [17] Alexander Lerch. *An introduction to audio content analysis: Applications in signal processing and music informatics*. John Wiley & Sons, 2012.
- [18] Emilia Gómez. «Tonal description of polyphonic audio for music content processing». En: *INFORMS Journal on Computing* (2006).
- [19] Christopher Harte, Mark Sandler y Martin Gasser. «Detecting harmonic change in musical audio». En: *Proceedings of the 1st ACM workshop on Audio and music computing multimedia*. 2006.
- [20] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).
- [21] Karen Simonyan y Andrew Zisserman. «Very deep convolutional networks for large-scale image recognition». En: *International Conference on Learning Representations*. 2015.
- [22] Guolin Ke et al. «Lightgbm: A highly efficient gradient boosting decision tree». En: *Advances in neural information processing systems*. Vol. 30. 2017.
- [23] Takuya Akiba et al. «Optuna: A next-generation hyperparameter optimization framework». En: *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*. 2019.
- [24] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep learning*. MIT press, 2016.
- [25] Sebastián Ramírez. *FastAPI*. 2018. URL: <https://github.com/fastapi/fastapi>.
- [26] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://www.python.org>.
- [27] Dirk Merkel. «Docker: lightweight linux containers for consistent development and deployment». En: *Linux journal* ().
- [28] Oracle Corporation. *Oracle Cloud Infrastructure*. 2026. URL: <https://www.oracle.com/cloud/>.
- [29] Thierry Bertin-Mahieux et al. «The million song dataset». En: *Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR 2011)*. 2011.
- [30] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* (1998).
- [31] Bob L. Sturm. «The state of the art ten years after a state of the art: Future research in music information retrieval». En: *Journal of New Music Research* (2014).
- [32] Geoffroy Peeters. *A large set of audio features for sound description (similarity and classification) in the CUIDADO project*. Inf. téc. IRCAM (Institut de Recherche et Coordination Acoustique/Musique), 2004.
- [33] Andrada Olteanu. *GTZAN Dataset - Music Genre Classification*. 2020. URL: <https://www.kaggle.com/datasets/andradolteanu/gtzan-dataset-music-genre-classification>.
- [34] Shawn Hershey et al. «CNN architectures for large-scale audio classification». En: *IEEE*. 2017.
- [35] ITU-R. «Algorithms to measure audio programme loudness and true-peak audio level». En: *Recommendation ITU-R BS.1770-4* (2015).
- [36] Alain De Cheveigné e Hideki Kawahara. «YIN, a fundamental frequency estimator for speech and music». En: *The Journal of the Acoustical Society of America* (2002).

- [37] Spotify AB. *Spotify Web API Reference: Get Track Audio Features*. Accedido en el transcurso de la investigación. 2024. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [38] Earl Vickers. «The loudness war: Background, speculation and recommendations». En: Audio Engineering Society. 2010.
- [39] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Science & Business Media, 2009.
- [40] Christopher M Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [41] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* (2011).
- [42] Max Kuhn y Kjell Johnson. *Applied Predictive Modeling*. Springer, 2013.
- [43] Ron Kohavi. «A study of cross-validation and bootstrap for accuracy estimation and model selection». En: *Proceedings of the 14th International Joint Conference on Artificial Intelligence - Volume 2*. Morgan Kaufmann Publishers Inc. 1995.
- [44] Leo Breiman et al. *Classification and Regression Trees*. CRC press, 1984.
- [45] Isabelle Guyon y André Elisseeff. «An introduction to variable and feature selection». En: *Journal of Machine Learning Research* (2003).
- [46] Ilya Loshchilov y Frank Hutter. «Decoupled Weight Decay Regularization». En: *International Conference on Learning Representations*. 2019.
- [47] Peter J Huber. «Robust estimation of a location parameter». En: *The Annals of Mathematical Statistics* ().
- [48] Sergey Ioffe y Christian Szegedy. «Batch normalization: Accelerating deep network training by reducing internal covariate shift». En: *International Conference on Machine Learning*. PMLR.
- [49] Nitish Srivastava et al. «Dropout: a simple way to prevent neural networks from overfitting». En: *The Journal of Machine Learning Research* (2014).
- [50] Mark Treveil et al. *Introducing MLOps: How to scale machine learning in the enterprise*. O'Reilly Media, 2020.
- [51] Micha Gorelick y Ian Ozsvald. *High Performance Python: Practical Performant Programming for Humans*. O'Reilly Media, 2020.