

Asignación de características musicales para ambientación comercial

Ing. Carlos Alberto Rivas Araque

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Martín Moreyra (GatekeeperX)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Buenos Aires, junio de 2026

Resumen

En la presente memoria se describe el diseño e implementación de un sistema que extrae información de las canciones y las etiqueta automáticamente a partir de su audio. Este trabajo fue desarrollado para la empresa Plusyc Live con el fin de optimizar el armado de catálogos musicales destinados a la ambientación de distintos espacios comerciales.

Para la elaboración de este trabajo fueron fundamentales los conocimientos adquiridos durante la carrera sobre tratamiento de datos estadísticos, modelos de árboles de clasificación y regresión, perceptrones multicapa, aprendizaje por transferencia, y puesta en producción.

Índice general

Resumen	I
1. Introducción general	1
1.1. Extracción de información musical	1
1.2. Contexto de aplicación	1
1.3. Objetivos y alcance	1
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.3.3. Alcance	2
1.4. Estado del arte	3
1.4.1. Procesamiento digital de señales y extracción a bajo nivel . .	3
1.4.2. Modelos preentrenados y soluciones comerciales	3
1.4.3. Síntesis comparativa	3
1.5. Estructura del documento	4
2. Introducción específica	5
2.1. Fuentes de datos de canciones	5
2.2. Representaciones numéricas de la música	5
2.3. Información semántica del audio	7
2.4. Modelos de inteligencia artificial utilizados	7
2.5. Despliegue e integración	8
3. Diseño e implementación	9
3.1. Análisis del software	9
4. Ensayos y resultados	11
4.1. Pruebas funcionales del hardware	11
5. Conclusiones	13
5.1. Conclusiones generales	13
5.2. Próximos pasos	13
Bibliografía	15

Índice de figuras

1.1. Interfaz de consulta en Tunebat	4
--	---

Índice de tablas

2.1. Conjuntos de datos evaluados	5
2.2. Conjuntos de datos evaluados	6
2.3. Atributos DSP extraídos	7

Capítulo 1

Introducción general

En este capítulo se introduce la definición de la extracción de información musical, se expone la problemática que motivó la búsqueda de una solución automatizada para la asignación de características musicales a partir del audio de canciones, y se detalla el alcance de la solución propuesta. Finalmente, se realiza una revisión general de las soluciones existentes.

1.1. Extracción de información musical

La extracción de información musical, comúnmente conocida como MIR (por sus siglas en inglés *Music Information Retrieval*), procesa, analiza y organiza datos musicales [1]. Los sistemas MIR abarcan el procesamiento digital de señales y el aprendizaje automático, y permiten automatizar tareas como el etiquetado de canciones, la clasificación de géneros o el reconocimiento de estados de ánimo a partir del audio digital [2].

1.2. Contexto de aplicación

El trabajo se realiza para dar respuesta a una necesidad tecnológica de Plusyc Live SAS, una empresa dedicada a la creación de experiencias musicales personalizadas para locales comerciales. La plataforma de la compañía crea listas de reproducción basadas en las características musicales de un catálogo de canciones.

Anteriormente, la asignación de estas características dependía del consumo de interfaces de programación de aplicaciones (API) de terceros. Esta metodología generaba restricciones de disponibilidad, incrementos en los costos operativos y limitaba la autonomía de la empresa.

Con la implementación de este trabajo, la empresa cuenta con un sistema de inteligencia artificial que caracteriza automáticamente canciones a partir de su archivo de audio. Esto reduce la dependencia de servicios externos y mejora la escalabilidad y autonomía de la aplicación; de esta manera se fortalece la experiencia musical personalizada que la empresa ofrece a los comercios.

1.3. Objetivos y alcance

Esta sección define las metas del proyecto. Se presentan los objetivos generales y específicos, los pasos metodológicos necesarios para su cumplimiento y el conjunto de características musicales consideradas.

1.3.1. Objetivo general

Desarrollar un sistema predictivo basado en inteligencia artificial para la caracterización automática de canciones a partir de su archivo de audio, destinado a dotar de autonomía a la aplicación de la empresa y a reducir la dependencia de servicios de terceros.

1.3.2. Objetivos específicos

Para alcanzar el objetivo general, se definen los siguientes pasos metodológicos:

- Seleccionar y analizar un conjunto de datos musicales pertinente para el entrenamiento de modelos de aprendizaje supervisado.
- Extraer representaciones numéricas y descriptores semánticos a partir de las señales de audio originales.
- Ejecutar el análisis exploratorio de datos (EDA) y el preprocesamiento de las variables.
- Entrenar modelos de aprendizaje supervisado para la predicción de las características objetivo.
- Evaluar el rendimiento de los modelos y seleccionar los de mejor desempeño.
- Desplegar los modelos en un entorno productivo para su integración operativa.

1.3.3. Alcance

El alcance de este trabajo comprende la predicción computacional de trece características musicales, que se agrupan en tres categorías principales:

- Básicas: tonalidad (key), modo (mode), tempo y volumen (loudness).
- Perceptibles: nivel acústico (acousticness), bailabilidad (danceability), energía (energy), instrumentalidad (instrumentalness), presencia de público (liveness), presencia de voz (speechiness) y positividad (valence).
- Clasificables por ánimo y género: estados de ánimo predominantes (primary moods), estados de ánimo secundarios (secondary moods) y géneros sugeridos (suggested genres).

Para cada una de las características mencionadas se aplican los pasos mencionados en los objetivos específicos. El detalle técnico, las definiciones formales y el modelado de cada característica como problema de clasificación o regresión se abordan en el capítulo de desarrollo.

1.4. Estado del arte

En el campo de la extracción de información musical existen diversas herramientas computacionales para el análisis de audio. Por un lado, se encuentran las bibliotecas de procesamiento digital de señales, que permiten extraer representaciones numéricas a partir de archivos de audio. Además, existen modelos preentrenados capaces de obtener información semántica y servicios comerciales orientados a inferir etiquetas de alto nivel.

1.4.1. Procesamiento digital de señales y extracción a bajo nivel

Existen bibliotecas de software para extraer descriptores numéricos de bajo nivel, como Librosa [3] y Essentia [4]. Estas herramientas representan la señal digital en arreglos numéricos, como espectrogramas.

1.4.2. Modelos preentrenados y soluciones comerciales

Para la predicción de características de alto nivel existen modelos de código abierto basados en aprendizaje profundo. Dos ejemplos son la arquitectura musicnn [5] y los modelos entrenados sobre el conjunto de datos AudioSet [6]. Estos sistemas clasifican etiquetas musicales generales. Su limitación principal radica en el uso de taxonomías fijas orientadas a los datos con los que fueron entrenados originalmente.

La biblioteca Essentia también incorpora modelos preentrenados para inferir atributos semánticos, y por lo tanto se incluye en esta categoría.

Por su parte, soluciones comerciales como Spotify [7] y Gracenote [8] operan en la modalidad de software como servicio (SaaS) y entregan predicciones mediante su interfaz de programación de aplicaciones (API). La gran desventaja es que introducen costos operativos recurrentes y generan dependencia tecnológica hacia el proveedor. También existen plataformas web que permiten consultar esta información de manera individual. Un ejemplo es Tunebat [9], que permite visualizar un conjunto de características, pero restringe la consulta a una canción a la vez. Se presenta un ejemplo en la figura 1.1.

1.4.3. Síntesis comparativa

Las tecnologías actuales para la extracción de información musical ofrecen diversas soluciones útiles. Las bibliotecas de procesamiento digital de señales permiten extraer representaciones numéricas de las ondas sonoras, y los modelos preentrenados ofrecen representaciones semánticas. Por otro lado, los servicios comerciales proveen servicios de etiquetado para canciones.

Sin embargo, persisten limitaciones operativas para su aplicación directa en el entorno de la empresa. Los servicios de terceros generan costos recurrentes, limitan la cantidad de consultas y crean dependencia tecnológica. Las plataformas web de uso manual no son viables para procesar catálogos con miles de canciones. Además, los modelos no coinciden con las características y las clases específicas que usa la empresa.

Por estos motivos, resulta necesario desarrollar una solución propia. El propósito de este trabajo es aprovechar las técnicas actuales de inteligencia artificial para

crear un sistema independiente. Esto permite analizar directamente los archivos de audio y etiquetarlos según las necesidades de la empresa, lo cual elimina de forma definitiva la dependencia de proveedores externos.




FIGURA 1.1. Ejemplo de visualización de características musicales en Tunebat ¹.

1.5. Estructura del documento

Para exponer de manera ordenada el desarrollo y los resultados del sistema, la presente memoria se estructura en los siguientes capítulos:

En el **Capítulo 2** se introduce el marco teórico. Se definen los conceptos matemáticos y computacionales sobre los que se sustenta el trabajo, incluyendo el procesamiento de señales de audio y los fundamentos del aprendizaje automático.

En el **Capítulo 3** se detalla el desarrollo metodológico. Se documenta la selección del conjunto de datos, el análisis exploratorio y el proceso de extracción de características, así como las arquitecturas de los modelos predictivos utilizados.

En el **Capítulo 4** se presentan los resultados obtenidos. Se evalúa el desempeño de los distintos modelos entrenados y se justifica la selección final de los algoritmos para su paso a producción.

Finalmente, en el **Capítulo 5** se exponen las conclusiones generales del proyecto, el cumplimiento de los objetivos propuestos y las posibles líneas de trabajo futuro para escalar el sistema implementado.

¹Imagen tomada de <https://tunebat.com/Info/Weird-Fishes-Arpeggi-Radiohead/4wajj1o7jWlg62YqpkHC7S>

Capítulo 2

Introducción específica

Este capítulo introduce las herramientas de terceros, los fundamentos teóricos y las tecnologías necesarias para el desarrollo del sistema. Se describen los conjuntos de datos analizados, las técnicas de extracción de representaciones numéricas, los modelos de aprendizaje automático y las herramientas utilizadas para el despliegue del producto.

2.1. Fuentes de datos de canciones

Para entrenar los modelos predictivos se evaluaron diferentes fuentes de datos musicales. En una etapa inicial se analizaron repositorios públicos orientados a tareas de recuperación de información musical. El objetivo fue identificar las ventajas y desventajas de cada alternativa antes de tomar una decisión definitiva. En la tabla 2.1 se resumen los conjuntos de datos estudiados.

TABLA 2.1. Comparativa de los conjuntos de datos musicales evaluados para el entrenamiento de los modelos.

Nombre	Descripción	Ventajas	Desventajas
GTZAN	Archivo histórico con audios de 30 segundos clasificados por género.	Ampliamente documentado.	Tamaño reducido.
FMA	Repositorio libre con metadatos y extracción de características precalculadas.	Gran volumen de datos.	Etiquetas ruidosas.
Plusyc	Colección privada provista por la empresa comercial asociada al proyecto.	Etiquetas manuales precisas.	Acceso restringido.

Tras esta evaluación, se determinó que los conjuntos públicos presentaban limitaciones para los objetivos específicos de la empresa. Por este motivo, se seleccionó el conjunto de datos privado de Plusyc. Esta fuente cuenta con más de 60.000 canciones completas. Además, cada pista posee etiquetas manuales para todos los objetivos predictivos requeridos.

2.2. Representaciones numéricas de la música

El procesamiento computacional del audio requiere extraer descriptores acústicos de la señal. Para esta tarea se emplearon bibliotecas de procesamiento digital de

TABLA 2.2. Comparativa de los conjuntos de datos musicales evaluados para el entrenamiento de los modelos.

Nombre	Descripción	Ventajas	Desventajas
GTZAN	Archivo histórico con características precalculadas sobre ventanas de 3 y 30 segundos.	Ampliamente documentado.	Audios cortos. Complejidad para replicar el preprocesamiento en datos nuevos.
FMA	Repositorio libre con metadatos y extracción de atributos acústicos.	Gran volumen de datos.	Audios limitados a fragmentos de 30 segundos. Etiquetas ruidosas.
MSD y Last.fm	Base de datos masiva con etiquetas sociales y características precalculadas.	Gran escala. Contiene etiquetas semánticas útiles.	No incluye los archivos de audio crudo. Demanda altos recursos computacionales.
Kaggle (Spotify Tracks)	Conjuntos de datos tabulares con métricas extraídas de plataformas comerciales.	Gran volumen de metadatos y etiquetas de alto nivel.	No incluye los archivos de audio crudo. Imposibilita el entrenamiento desde la señal acústica.
Magnatune	Conjunto de datos con acceso a metadatos estructurados.	Información detallada de las pistas.	Estructura de archivos XML compleja de procesar.
Plusyc	Colección privada provista por la empresa asociada al proyecto.	Audios completos. Etiquetas manuales precisas para todos los objetivos.	Acceso restringido al público general.

señales (DSP, por sus siglas en inglés). Estas herramientas transforman la onda sonora en arreglos matemáticos de una o dos dimensiones.

Entre las representaciones más útiles se encuentran el espectrograma y el cromagrama. El espectrograma refleja la variación de las frecuencias a lo largo del tiempo. Por su parte, el cromagrama captura la energía asociada a las doce clases de notas musicales. Un ejemplo de ambas transformaciones se ilustra en la figura ??.

Figura aquí

Además de estas representaciones visuales, el sistema requiere la extracción de atributos numéricos unidimensionales. En la tabla 2.3 se listan las características principales que se extrajeron para alimentar los algoritmos de predicción.

TABLA 2.3. Listado de los principales atributos de procesamiento de señales extraídos del audio.

Atributo	Descripción principal
MFCC	Coeficientes cepstrales que modelan la percepción auditiva humana.
Centroide espectral	Indica el centro de masa del espectro y se asocia al brillo del sonido.
Ancho de banda	Mide la amplitud de las frecuencias alrededor del centroide espectral.
Tasa de cruce por cero	Cuantifica los cambios de signo en la señal temporal.
Flujo espectral	Evalúa la tasa de cambio local en el espectro entre tramas sucesivas.

2.3. Información semántica del audio

Las representaciones numéricas de bajo nivel no siempre son suficientes para capturar conceptos musicales complejos. Por ello, se implementó una estrategia de aprendizaje por transferencia. Esta técnica consiste en utilizar modelos previamente entrenados con grandes volúmenes de datos para extraer características de alto nivel.

Para este fin se utilizó la biblioteca *PANNs Inference*. Esta herramienta provee acceso a redes neuronales optimizadas para el análisis de sonido. De las opciones disponibles, se seleccionó la arquitectura denominada CNN14. Se trata de una red neuronal convolucional robusta, capaz de abstraer patrones semánticos profundos de la música. La estructura interna de esta arquitectura se detalla en la figura ??.

Figura aquí.

2.4. Modelos de inteligencia artificial utilizados

Una vez obtenidas las características acústicas y semánticas, fue necesario aplicar algoritmos de predicción. El alcance del trabajo abarca problemas de clasificación y de regresión. Para resolverlos, se implementaron dos enfoques principales:

- Redes MLP: Se diseñaron perceptrones multicapa para abordar los problemas de regresión multisalida. Estas redes neuronales artificiales demostraron eficacia para predecir variables continuas correlacionadas.
- Algoritmos LightGBM: Se integró el marco de trabajo *LightGBM* para las tareas generales de clasificación multiclase y regresión simple. Esta herramienta se basa en el ensamble de árboles de decisión y destaca por su velocidad computacional.

2.5. Despliegue e integración

Para que las predicciones musicales sean consumidas por servicios externos, se desarrolló una interfaz de programación de aplicaciones. Se eligió el marco de trabajo *FastAPI* por su alto rendimiento y su facilidad para construir servicios web con lenguaje *Python*.

Finalmente, el sistema completo se configuró para operar de forma remota. Se provisionó una instancia de cómputo en la nube, la cual garantiza la disponibilidad y los recursos de procesamiento necesarios. El esquema general de integración entre el cliente, la interfaz y el servidor se muestra en la figura ??.

Figura aquí.

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno `lstlisting` con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
  las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código [3.1](#):

```
1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ACTUATOR_NUMBER 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER]; //ON or OFF
8 state_t actuatorState[MAX_ACTUATOR_NUMBER]; //ON or OFF
9
10 void vControl() {
11
12     initGlobalVariables();
13
14     period = 500 ms;
15
16     while(1) {
17
18         ticks = xTaskGetTickCount();
19
20         updateSensors();
21
22         updateAlarms();
23
24         controlActuators();
25
26         vTaskDelayUntil(&ticks, period);
27     }
```

28 }

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20. 2015. URL: <https://librosa.org/>.
- [4] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- [5] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [6] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [7] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [8] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [9] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.