

Asignación de características musicales para ambientación comercial

Carrera de Especialización en Inteligencia Artificial
Trabajo Final

Ing. Carlos Rivas

Director:

Esp. Ing. Martín Moreyra

Jurados:

Esp. Ing. Natanael Emir Ferrán

Mg. Lic. Pablo Carlos Zizzutti

Esp. Ing. Ana Laura Diedrichs


Ciudad de Buenos Aires, junio de 2026



Ambientación musical

Plataforma SaaS de **Plusyc** para espacios comerciales:
hoteles, restaurantes, retail.

- Catálogo privado de **60000+** canciones completas
- Listas curadas por **características musicales**
- Elecciones basadas en **valores**



CONTEXTO

La necesidad y el objetivo

FUENTES EXTERNAS

Spotify API
Gracenote

Etiquetado manual



- ✗ Costos y límites de requests
- ✗ Dependencia de terceros
- ✗ Carga manual
- ✗ Clases diferentes en Plusyc



SOLUCIÓN

Sistema propio

Inferencia automática

CONTEXTO

El objetivo

Sistema propio



Audio crudo
Catálogo Plusyc



Inferencia IA



13 CARACTERÍSTICAS

key · mode · tempo · loudness

acousticness · danceability · energy ·

instrumentalness

liveness · speechiness · valence

primary mood · secondary mood · suggested
genres

Estado del arte

MIR (Music Information Retrieval): Procesamiento de señales y Machine Learning para extraer información del audio.

DSP tradicional

Librosa / Essentia

- Extraen descriptores físicos de la señal
- Carecen de comprensión semántica (mood, género, habla)

Deep Learning

PANNs / musicnn

- Extraen contexto acústico profundo
- Clasificadores genéricos, no adaptados al catálogo

APIs comerciales

Spotify / Gracenote

- Solución directa y ya empaquetada
- Inviabile a escala por costos y dependencia

Los datos

+60000 canciones · catálogo de Plusyc

Audio completo — no previews de 30s

Valores revisados manualmente

DATASETS PÚBLICOS - NINGUNO TIENE LAS 13 CARACTERÍSTICAS

GTZAN

1000 clips · 30s · 10 géneros

- ✓ DSP: MFCC, chroma, RMS, descriptores espectrales
- ✓ Ventanas y estadísticos (media, varianza)
- ✗ Previews de 30s · 10 géneros vs 500+ de Plusyc

FMA estándar

clips 30s · taxonomía jerárquica

- ✓ Más DSP: CQT, tonnetz, ZCR
- ✓ Estadísticos: media, std, asimetría, curtosis
- ✗ Clips cortos · versión completa excede infraestructura

Million Song Dataset

1M canciones · HDF5

- ✓ Gran cantidad de muestras
- ✗ Sin audio crudo · difícil replicar la extracción

AudioSet

2M clips · 10s · 527 clases

- ✓ Embeddings semánticos con CNN14 (PANNs)
- ✓ Ventanas de 10s para captura semántica
- ✓ Usado para limpiar etiquetas ruidosas
- ✗ Clases diferentes

Representaciones DSP

Variables por frame (~64 ms)


- MFCC · centroide · ancho de banda · rolloff
- Zero Crossing Rate · RMS
- Cromagrama · Tonnetz

92 atributos × 7 estadísticos = **644 features**
media · std · asimetría · curtosis · P10 · P50 · P90

Atributos globales (pista entera)

- Tempo · LUFS · Pitch global
- Perfiles tonales (Krumhansl / Temperley)

62 features — sin ventaneo




espectrograma · cromagrama · tonnetz — "Weird Fishes" (Radiohead)

Semántica: PANNs / CNN14

- Red neuronal **preentrenada en AudioSet**
2M clips de YouTube · 527 clases de audio
- Produce **embeddings** de 2048 dims
representación latente de la canción
- Produce **probabilidades** de 527 eventos
Voz / habla · **Público en vivo** · Instrumentos · Géneros
· Distorsión

Ventanas de **10s** → **4 estadísticos**
media · máximo · std · P90

Clave para capturar semántica que el DSP clásico no puede.



probabilidades de eventos sonoros por canción

El dataset



Preprocesamiento — I

✓ Corte del histórico


cambio de distribución detectado en fecha → solo datos anteriores

✓ Recorte de colas de silencio

evita valores nulos en los estadísticos de ventanas vacías

✓ Transformaciones estadísticas

ej. *Shifted Log Transformation* en Loudness para normalizar la distribución sesgada



distribución de Loudness - transformación

Preprocesamiento — II

✓ Limpieza con AudioSet


modelo preentrenado detecta y elimina falsas etiquetas

✓ Muestreo balanceado

mood y genres tienen clases muy desbalanceadas

✓ Selección de variables — 3 etapas

① Filtro de varianza · ② Importancia basada en ganancia (árboles) · ③ Exclusión por colinealidad (Pearson)




liveness antes de limpieza — distribución con ruido

Modelo MLP

Multi-output — 5 salidas:

acousticness danceability energy instrumentalness valence

- Salidas en $[0, 1]$ — Sigmoid final (escala de las variables objetivo)
- **Huber loss** — robusto a outliers en variables continuas
- **AdamW** — regularización L2 (Weight Decay) para evitar el sobreajuste
- Early stopping en iteración 74



Modelos LightGBM

7 modelos individuales

loudness key y mode liveness speechiness primary mood
secondary mood genres


- Ensamble de árboles de decisión (gradient boosting)
- Eficiencia computacional
- Hiperparámetros optimizados con **Optuna**




Desafío: liveness & speechiness

Primera versión: $R^2 \approx 0.15$ (liveness) y $R^2 \approx 0.28$ (speechiness) — etiquetas ruidosas en el catálogo histórico

ANTES




DESPUÉS — LIMPIEZA CON AUDIOSET



Modelo preentrenado detecta canciones mal etiquetadas → se excluyen del entrenamiento

RESULTADOS

Resultados MLP




Huber loss + MAE en entrenamiento y validación

Variable	R ²
acousticness	0.89
energy	0.86
instrumentalness	0.83
valence	0.75
danceability	0.74
Global (MLP)	0.8152

Early stopping en iter. 74
(mínimo de validación en iter. 59)

Resultados — moods y géneros



- Clasificación multiclase con LightGBM
- Diagonal clara → el modelo aprende las clases
- Confusión entre clases adyacentes refleja **ambigüedad inherente al etiquetado humano**

Géneros → multi-etiqueta

una canción puede pertenecer a múltiples géneros simultáneamente

Resumen de métricas

MLP — REGRESIÓN (R²)

Variable	R²
acousticness	0.89
energy	0.86
instrumentalness	0.83
valence	0.75
danceability	0.74


R² global MLP: 0.8152

LIGHTGBM — CLASIFICACIÓN

Variable	Tipo
tempo	regresión
loudness	regresión
key / mode	multiclase
liveness / speechiness	binaria
primary mood	multiclase
secondary mood	multiclase
suggested genres	multi-etiqueta

Hiperparámetros optimizados individualmente con Optuna

Arquitectura en producción



- ✓ **FastAPI** — API REST de inferencia
- ✓ **Docker** — contenedores reproducibles
- ✓ **OCI** — Oracle Cloud Infrastructure
- ✓ **Beethoven** — integración asíncrona
herramienta interna de Plusyc


Flujo de una canción nueva:

ingresa al catálogo → Beethoven dispara inferencia → 13 características asignadas automáticamente


PRODUCCIÓN

Plusyc hoy

El sistema está en producción — clasifica canciones entrantes en tiempo real



características asignadas automáticamente



moods y géneros

A CONTINUACIÓN

Demo

Sistema en producción — Plusyc Live

Conclusiones

- ✓ **PANNs fue la clave**

embeddings preentrenados capturan semántica que DSP clásico no puede

- ✓ **ML clásico funciona**

LightGBM + Optuna supera arquitecturas más complejas en este dominio y escala

- ✓ **Pipeline propio sobre canciones completas**

clases adaptadas al catálogo de Plusyc, no a datasets genéricos

- ✓ **Sistema en producción**

clasifica canciones entrantes, costo de inferencia cero, sin dependencia de terceros

Próximos pasos

→ Reentrenamiento periódico

Airflow + MLflow para orquestar y versionar modelos

→ Clasificación jerárquica de moods

estructura más fina y coherente para ambientación de precisión

→ Arquitecturas transformer

cuando el volumen de datos etiquetados lo justifique

→ SaaS posible

sistema extensible a otros catálogos y empresas

¡Gracias!

Ing. Carlos Alberto Rivas Araque

Director: Esp. Ing. Martín Moreyra

CEIA · FIUBA · junio 2026