

Asignación de características musicales para ambientación comercial

Carrera de Especialización en Inteligencia Artificial
Trabajo Final

Ing. Carlos Rivas

Director:

Esp. Ing. Martín Moreyra

Jurados:

Esp. Ing. Natanael Emir Ferrán

Mg. Lic. Pablo Carlos Zizzutti

Esp. Ing. Ana Laura Diedrichs


Ciudad de Buenos Aires, junio de 2026



Ambientación musical

Plataforma SaaS de **Plusyc** para espacios comerciales:
hoteles, restaurantes, retail.

- Catálogo privado de **60000+** canciones completas
- Listas curadas por **características musicales**
- Elecciones basadas en **valores**



CONTEXTO

La necesidad y el objetivo

FUENTES EXTERNAS

Spotify API
Gracenote

Etiquetado manual



- ✗ Costos y límites de requests
- ✗ Dependencia de terceros
- ✗ Carga manual
- ✗ Clases diferentes en Plusyc



SOLUCIÓN

Sistema propio

Inferencia automática

CONTEXTO

El objetivo

Sistema propio



Audio crudo
Catálogo Plusyc



Inferencia IA



14 CARACTERÍSTICAS

key · mode · tempo · loudness

acousticness · danceability · energy ·

instrumentalness

liveness · speechiness · valence

primary mood · secondary mood · suggested
genres

Estado del arte

MIR (Music Information Retrieval): Procesamiento de señales y Machine Learning para extraer información del audio.

DSP tradicional

Librosa / Essentia

- Extraen descriptores físicos de la señal
- Carecen de comprensión semántica (mood, género, habla)

Deep Learning

PANNs / musicnn

- Filtros convolucionales detectan bordes y texturas en el espectrograma
- Clasificadores genéricos, no adaptados al catálogo

APIs comerciales

Spotify / Gracenote

- Solución directa y ya empaquetada
- Inviabile a escala por costos y dependencia

DATOS

Los datos

+60000 canciones · catálogo de Plusyc

Audio completo — no previews de 30s

Valores revisados manualmente

DATASETS PÚBLICOS - NINGUNO TIENE TODAS LAS 14 CARACTERÍSTICAS

GTZAN

1000 clips · 30s · 10 géneros

✓ DSP: MFCC, croma, RMS, descriptores espectrales

✓ Ventanas y estadísticos (media, varianza)

✗ Previews de 30s · 10 géneros vs 500+ de Plusyc

FMA estándar

clips 30s · taxonomía jerárquica

✓ Más DSP: CQT, tonnetz, ZCR

✓ Estadísticos: media, std, asimetría, curtosis

✗ Clips cortos · versión completa excede infraestructura

Million Song Dataset

1M canciones · HDF5

✓ Features por segmento: timbre (MFCC) · pitches (croma) · loudness

✗ Sin audio crudo · difícil replicar la extracción

AudioSet

2M clips · 10s · 527 clases

✓ Embeddings semánticos con CNN14 (PANNs)

✓ Ventanas de 10s para captura semántica

✗ Clases diferentes

Representaciones DSP

Variables por frame (~64 ms)


- MFCC · centroide · ancho de banda · rolloff
- Zero Crossing Rate · RMS
- Cromagrama · Tonnetz

92 atributos × 7 estadísticos = **644 features**
media · std · asimetría · curtosis · P10 · P50 · P90

Atributos globales (pista entera)

- Tempo · LUFS · Pitch global
- Perfiles tonales (Krumhansl / Temperley)

62 features — sin ventaneo




espectrograma · cromagrama · tonnetz — "Weird Fishes" (Radiohead)

Semántica: PANNs / CNN14

- Red neuronal **preentrenada en AudioSet**
2M clips de YouTube · 527 clases de audio
- Produce **embeddings** de 2048 dims
representación latente de la canción
- Produce **probabilidades** de 527 eventos
Voz / habla · **Público en vivo** · Instrumentos · Géneros
· Distorsión

Ventanas de **10s** → **4 estadísticos**
media · máximo · std · P90

Clave para capturar semántica que el DSP clásico no puede.



probabilidades de eventos sonoros por canción

El dataset



Preprocesamiento — I

✓ Corte del histórico


cambio de distribución detectado en fecha → solo datos anteriores

✓ Recorte de colas de silencio

evita valores nulos en los estadísticos de ventanas vacías

✓ Transformaciones estadísticas

ej. Shifted Log Transformation en loudness para normalizar la distribución sesgada



distribución de Loudness - transformación

Preprocesamiento — II

✓ Limpieza con AudioSet


modelo preentrenado detecta falsas etiquetas

✓ Selección de variables — 3 etapas

① Filtro de varianza · ② Importancia por ganancia en árboles (95% acumulado) · ③ Exclusión por colinealidad (Pearson > 0,95)

✓ Muestreo balanceado

mood y genres: techo por clase mayoritaria y mínimo representativo por clase minoritaria



Modelo MLP

Multi-output — 5 salidas:

acousticness


danceability

energy

instrumentalness

valence

- Salidas en $[0, 1]$ — Sigmoid final (escala de las variables objetivo)
- **Huber loss** — robusto a outliers en variables continuas
- **AdamW** — regularización L2 (Weight Decay) para evitar el sobreajuste
- Early stopping en iteración 74



Modelos LightGBM


7 modelos individuales

loudness key y mode liveness speechiness primary mood
secondary mood genres

- Ensamble de árboles de decisión (gradient boosting)
- Eficiencia computacional
- Hiperparámetros optimizados con **Optuna**



Optimización de hiperparámetros — Optuna



✓ Búsqueda bayesiana

no grid search — usa resultados anteriores para sugerir la próxima combinación

✓ Early stopping integrado

30–50 iteraciones sin mejora cortan el trial actual

✓ Modelo final

lr muy baja + hasta 10.000 árboles — el early stopping determina el número real

Tempo — extracción directa


- **Octave error** en el etiquetado
proporciones métricas: $\frac{1}{2} \cdot \frac{2}{3} \cdot 1 \cdot 1\frac{1}{2} \cdot 2\times$ del tempo real
- Árboles sin señal de aprendizaje —
 $R^2 \approx 0$
- **Solución: Essentia** — estimación DSP directa del tempo global

MAE exacto ($y \approx x$)


MAE admitiendo proporciones métricas

12,81 BPM

1,45 BPM




relaciones métricas en el etiquetado — octave error




distribución estimación Essentia vs etiquetas del catálogo


Resultados MLP



Huber loss + MAE — entrenamiento y validación



acoustiness




danceability

Variable	R ² (↑)	MAE (↓)
Acoustiness	0,8903	0,0681
Energy	0,8626	0,0581
Instrumentalness	0,8308	0,0671
Valence	0,7539	0,0964
Danceability	0,7381	0,0594


Resultados loudness

Config.	R ² (↑)	RMSE (↓)	MAE (↓)
L1 (regression_l1)	0,8300	1,8534	1,1469
L2 (regression_l2)	0,8367	1,8167	1,1889


L2 aplana predicciones hacia valores extremos.
Métricas globales similares, mejor distribución.
Configuración elegida: L2.




L1 — real vs predicho



L2 — real vs predicho



curva de aprendizaje



feature importance top 15

Resultados key / mode

Valores actuales	C Minor	168	8	1	11	8	10	0	0	1	3	0	21	1	0	35	4	0	0	34	3	0	28	1	1
	C Major	13	626	1	14	7	5	6	3	33	12	0	0	29	1	12	53	0	3	24	35	0	4	80	3
	C# Minor	1	0	192	12	2	2	4	25	0	3	1	0	3	25	1	3	31	2	1	3	18	1	0	5
	C# Major	1	9	9	362	55	1	3	7	0	6	16	0	0	0	55	4	8	30	0	9	10	36	0	1
	A# Minor	5	4	1	57	245	4	3	1	1	3	13	0	0	0	34	4	2	15	3	3	2	31	3	2
	A# Major	11	4	0	1	13	231	0	1	11	2	0	7	0	1	12	12	0	2	27	4	0	1	1	2
	B Minor	0	3	4	2	6	1	337	12	0	54	0	0	44	4	1	0	43	2	2	20	2	1	2	18
	B Major	0	0	11	7	7	0	6	192	1	0	6	2	4	7	1	0	8	13	0	2	26	1	1	2
	D Minor	2	22	0	3	1	5	1	1	218	10	0	1	1	1	0	29	1	0	20	5	0	1	21	0
	D Major	2	2	5	6	1	2	63	2	16	478	0	1	15	1	0	0	18	2	15	43	1	3	15	27
	D# Minor	0	0	0	3	17	2	0	12	1	2	65	2	0	0	2	1	0	19	0	0	13	1	0	0
	D# Major	11	0	0	1	5	6	0	0	1	2	0	121	1	2	5	1	0	2	6	2	1	16	1	0
	E Minor	0	11	2	1	0	2	50	1	1	23	0	0	301	5	0	0	10	4	0	52	0	1	40	13
	E Major	0	1	34	1	2	1	4	10	1	2	0	0	11	193	0	2	7	1	1	1	7	0	2	14
	F Minor	32	6	0	27	38	16	0	0	5	1	1	14	1	1	272	9	2	5	23	3	0	52	4	1
	F Major	2	32	1	6	4	19	3	0	45	5	0	1	5	2	11	324	0	2	20	7	0	1	21	3
	F# Minor	2	3	39	11	1	0	25	4	1	6	1	0	4	17	2	1	220	6	0	4	10	0	2	27
	F# Major	0	3	6	27	27	1	5	11	0	1	14	0	1	0	4	2	13	187	1	3	18	1	0	2
	G Minor	14	14	1	3	3	34	0	0	25	7	0	8	0	1	7	15	1	1	255	12	0	7	13	2
	G Major	0	51	1	7	4	0	36	1	12	54	0	1	75	0	10	5	3	7	16	562	1	10	51	0
	G# Minor	0	0	15	18	4	0	3	29	0	1	12	2	2	2	0	2	4	12	2	3	101	2	1	3
	G# Major	40	2	5	19	23	4	3	3	0	6	0	18	0	1	33	2	5	0	14	6	2	280	0	0
	A Minor	2	47	0	3	3	2	5	0	23	14	1	0	36	4	0	10	1	1	3	27	0	1	389	10
	A Major	0	3	20	4	0	3	24	3	1	22	0	0	11	12	0	5	33	0	0	6	2	3	23	394
		C Minor																							
	C Major																								
	C# Minor																								
	C# Major																								
	A# Minor																								
	A# Major																								
	B Minor																								
	B Major																								
	D Minor																								
	D Major																								
	D# Minor																								
	D# Major																								
	E Minor																								
	E Major																								
	F Minor																								
	F Major																								
	F# Minor																								
	F# Major																								
	G Minor																								
	G Major																								
	G# Minor																								
	G# Major																								
	A Minor																								
	A Major																								
	Predicciones																								

matriz de confusión — 24 clases (key × mode)

Métrica	Valor
Accuracy	0,6106
F1-Score ponderado	0,6115
AUC-ROC promedio	0,9589
Accuracy top-3	0,8671

Top-3 suele incluir la tónica, dominante, subdominante o relativa — relaciones armónicas principales


Liveness & speechiness

Variable	R ² (↑)		MAE (↓)		RMSE (↓)	
	ini.	act.	ini.	act.	ini.	act.
Speechiness	0,28	0,67	0,06	0,04	0,10	0,07
Liveness	0,16	0,63	0,10	0,08	0,14	0,13


Inicial → actual, tras limpieza
con modelo preentrenado en AudioSet.

Etiquetas ruidosas en el catálogo histórico → limpieza con AudioSet

ANTES




DESPUÉS



speechiness — distribución antes y después de la limpieza

Resultados — moods y genres



matriz de confusión normalizada — géneros (197 clases)

Modelo	Acc.	F1	Top-3	Top-5
Genre 197 cl.	0,47	0,47	68,32%	77,31%
Primary mood 20 cl.	0,25	0,24	55,81%	73,64%
Secondary mood 102 cl.	0,19	0,15	—	46,57%

Alta cardinalidad y fronteras subjetivas
Predicciones coherentes

Primary mood — ej: *melancholy* vs *sentimental*
Secondary mood — ej: *cool melancholy* vs *light melancholy*

RESULTADOS

Resumen de métricas

MLP — REGRESIÓN (R²)

Variable	R²
acousticness	0.89
energy	0.86
instrumentalness	0.83
valence	0.75
danceability	0.74

R² global MLP: 0.8152

LIGHTGBM — CLASIFICACIÓN

Variable	Tipo
tempo	regresión
loudness	regresión
key / mode	multiclase
liveness / speechiness	binaria
primary mood	multiclase
secondary mood	multiclase
suggested genres	multi-etiqueta


Hiperparámetros optimizados individualmente con Optuna

Despliegue e integración

- ✓ **FastAPI** — API REST de inferencia
- ✓ **Docker** — contenedor reproducible
- ✓ **Compute instance** — Oracle Cloud Infrastructure
- ✓ **Beethoven** — integración asíncrona
herramienta interna de Plusyc

Flujo de una canción nueva:

ingresa al catálogo → Beethoven dispara inferencia → secuencia de modelos JSON → 14 características asignadas automáticamente



A CONTINUACIÓN

Demo

Sistema — Plusyc Live

Conclusiones

- ✓ **Dataset MIR propio de Plusyc**

DSP, PANNs, clases del catálogo

- ✓ **MLP y ML clásico funcionan**

MLP y LightGBM + Optuna alcanzan rendimiento aceptable en producción en el dominio y escala del negocio, con posibilidad de iterar

- ✓ **PANNs fue clave**

el modelo preentrenado captura semántica que DSP clásico no

- ✓ **Baseline de inferencia en producción**

el sistema etiqueta canciones entrantes, sin costo por consulta, sin dependencia de terceros

Próximos pasos

→ Reentrenamiento periódico

Airflow + MLflow para orquestar y versionar modelos

→ Clasificación jerárquica de moods

estructura más fina y coherente para ambientación de precisión

→ Mejorar limpieza y data augmentation

más limpieza en lugar de submuestreo y uso de transformadores y redes de difusión para aumentar muestras en clases escasas

→ Posible SaaS

el pipeline es generalizable — con mejoras en datos, reentrenamiento e infraestructura escalable

¡Gracias!

Ing. Carlos Alberto Rivas Araque

Director: Esp. Ing. Martín Moreyra

CEIA · FIUBA · junio 2026

