

Asignación de características musicales para ambientación comercial

Ing. Carlos Alberto Rivas Araque

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Martín Moreyra (GatekeeperX)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Buenos Aires, junio de 2026

Resumen

En la presente memoria se describe el diseño e implementación de un sistema que extrae información de las canciones y las etiqueta automáticamente a partir de su audio. Este trabajo fue desarrollado para la empresa Plusyc Live con el fin de optimizar el armado de catálogos musicales destinados a la ambientación de distintos espacios comerciales.

Para la elaboración de este trabajo fueron fundamentales los conocimientos adquiridos durante la carrera sobre tratamiento de datos estadísticos, modelos de árboles de clasificación y regresión, perceptrones multicapa, aprendizaje por transferencia, y puesta en producción.

Índice general

Resumen	I
1. Introducción general	1
1.1. Extracción de información musical	1
1.2. Contexto de aplicación	1
1.3. Objetivos y alcance	2
1.3.1. Objetivo general	2
1.3.2. Objetivos específicos	2
1.3.3. Alcance	2
1.4. Estado del arte	3
1.4.1. Procesamiento digital de señales y extracción a bajo nivel . .	3
1.4.2. Modelos preentrenados y soluciones comerciales	3
1.4.3. Síntesis comparativa	4
2. Introducción específica	5
2.1. Fuentes de datos de canciones	5
2.2. Representaciones numéricas de la música	5
2.3. Información semántica del audio	7
2.4. Modelos de inteligencia artificial utilizados	8
2.5. Despliegue e integración	8
3. Diseño e implementación	11
3.1. Conjuntos de datos	11
3.1.1. Análisis de conjuntos de datos públicos	11
GTZAN	11
FMA estándar	12
Million Song Dataset (MSD)	12
AudioSet	13
3.1.2. Reducción de dimensionalidad mediante estadísticas	13
3.1.3. Conformación del espacio de variables	16
3.2. Ejecución de tareas sobre el conjunto de datos	16
3.2.1. Distribuciones de las variables objetivo	18
Características básicas	18
3.2.2. Selección de variables de entrada	18
3.3. Modelado y optimización	18
3.4. Arquitectura de despliegue e integración	18
4. Ensayos y resultados	19
4.1. Pruebas funcionales del hardware	19
5. Conclusiones	21
5.1. Conclusiones generales	21
5.2. Próximos pasos	21

Índice de figuras

1.1. Interfaz de consulta en Tunebat	4
2.1. Representaciones visuales del audio	6
2.2. Probabilidades de detección semántica	8
3.1. Algoritmo de extracción de atributos	14
3.2. Proceso de reducción de dimensionalidad	15
3.3. Distribución de Loudness	18

Índice de tablas

2.1. Atributos representativos	7
3.1. Desglose detallado del espacio de variables	16
3.2. Características predictivas	17

Capítulo 1

Introducción general

En este capítulo se introduce la definición de la extracción de información musical, se expone la problemática que motivó la búsqueda de una solución automatizada para la asignación de características musicales a partir del audio de canciones, y se detalla el alcance de la solución propuesta. Finalmente, se realiza una revisión general de las soluciones existentes.

1.1. Extracción de información musical

La extracción de información musical, comúnmente conocida como MIR (por su sigla en inglés, *Music Information Retrieval*), procesa, analiza y organiza datos musicales [1].

Los sistemas MIR abarcan el procesamiento digital de señales (DSP) y el aprendizaje automático, y permiten automatizar tareas como el etiquetado de canciones, la clasificación de géneros o el reconocimiento de estados de ánimo a partir del audio digital [2].

La aplicación de estas tecnologías en el contexto comercial resulta fundamental para la personalización y ambientación de espacios físicos. La literatura académica señala que la música de fondo (*background music*) no es un elemento pasivo, sino un factor ambiental estratégico. Investigaciones en el área muestran que componentes estructurales de la música alteran de forma predecible la excitación emocional (*arousal*), la percepción del tiempo y la intención de compra de los consumidores en entornos minoristas y de servicios [3, 4, 5].

Para lograr una personalización ambiental efectiva en cada comercio, es necesario seleccionar pistas musicales que se ajusten a criterios sonoros y emocionales específicos dictados por la identidad de cada marca. La curaduría manual resulta inescalable debido a la gran magnitud de los catálogos musicales; en consecuencia, es importante desarrollar un producto que implemente técnicas MIR para caracterizar automáticamente los archivos de audio de las canciones de grandes repositorios de audio, para el uso de las características en sistemas que llevan música a espacios comerciales, según las necesidades específicas de cada lugar.

1.2. Contexto de aplicación

El trabajo se realiza para dar respuesta a una necesidad tecnológica de Plusyc Live SAS [6], una empresa dedicada a la creación de experiencias musicales personalizadas para locales comerciales. La plataforma de la compañía crea listas de

reproducción basadas en las características musicales de un catálogo de canciones.

Anteriormente, la asignación de estas características dependía del consumo de interfaces de programación de aplicaciones (API) de terceros. Esta metodología generaba restricciones de disponibilidad, incrementos en los costos operativos y limitaba la autonomía de la empresa.

Con la implementación de este trabajo, la empresa cuenta con un sistema de inteligencia artificial que caracteriza automáticamente canciones a partir de su archivo de audio. Esto reduce la dependencia de servicios externos y mejora la escalabilidad y autonomía de la aplicación; de esta manera se fortalece la experiencia musical personalizada que la empresa ofrece a los comercios.

1.3. Objetivos y alcance

Esta sección define las metas. Se presenta el objetivo general y los objetivos específicos, y el conjunto de características musicales consideradas.

1.3.1. Objetivo general

Desarrollar un sistema basado en inteligencia artificial para predecir las características musicales de las canciones del catálogo de Plusyc Live a partir de su archivo de audio y reducir la dependencia de servicios de terceros.

1.3.2. Objetivos específicos

Para alcanzar el objetivo general, se definen los siguientes objetivos específicos:

- Seleccionar y analizar un conjunto de datos musicales pertinente para el entrenamiento de modelos de aprendizaje supervisado.
- Extraer representaciones numéricas y descriptores semánticos a partir de las señales de audio originales.
- Ejecutar el análisis exploratorio de datos (EDA) y el preprocesamiento de las variables.
- Entrenar modelos de aprendizaje supervisado para la predicción de las características objetivo.
- Evaluar el rendimiento de los modelos y seleccionar los de mejor desempeño.
- Desplegar los modelos en un entorno productivo para su integración operativa.

1.3.3. Alcance

El alcance de este trabajo comprende la predicción computacional de trece características musicales, que se agrupan en tres categorías principales:

- Básicas: tonalidad (key), modo (mode), tempo y volumen (loudness).

- Perceptibles: nivel acústico (acousticness), bailabilidad (danceability), energía (energy), instrumentalidad (instrumentalness), presencia de público (liveness), presencia de voz (speechiness) y positividad (valence).
- Clasificables por ánimo y género: estados de ánimo predominantes (primary moods), estados de ánimo secundarios (secondary moods) y géneros sugeridos (suggested genres).

Para cada una de las características mencionadas se busca cumplir con los objetivos específicos definidos.

1.4. Estado del arte

En el campo de la extracción de información musical existen diversas herramientas computacionales para el análisis de audio. Por un lado, se encuentran las bibliotecas de procesamiento digital de señales, que permiten extraer representaciones numéricas a partir de archivos de audio. Además, existen modelos preentrenados capaces de obtener información semántica y servicios comerciales orientados a inferir etiquetas de alto nivel.

1.4.1. Procesamiento digital de señales y extracción a bajo nivel

Existen bibliotecas de software para extraer descriptores numéricos de bajo nivel, como Librosa [7] y Essentia [8].

Las bibliotecas de procesamiento digital de señales proveen funciones para representar la señal digital en arreglos numéricos, como espectrogramas y cromagramas. Este tipo de transformaciones matemáticas son útiles para reducir la dimensionalidad de los archivos de audio y generar variables predictivas para modelos de aprendizaje automático.

1.4.2. Modelos preentrenados y soluciones comerciales

Para la predicción de características semánticas existen modelos de código abierto basados en aprendizaje profundo. Dos ejemplos son la arquitectura musicnn [9] y los modelos entrenados sobre el conjunto de datos AudioSet [10]. Estos sistemas clasifican etiquetas musicales generales. Su limitación principal radica en el uso de taxonomías fijas orientadas a los datos con los que fueron entrenados originalmente. La biblioteca Essentia también incorpora modelos preentrenados para inferir atributos semánticos, y por lo tanto se incluye en esta categoría.

Por su parte, soluciones comerciales como Spotify [11] y Gracenote [12] operan en la modalidad de software como servicio (SaaS) y entregan predicciones mediante su interfaz de programación de aplicaciones (API). La gran desventaja es que introducen costos operativos recurrentes y generan dependencia tecnológica hacia el proveedor.

También existen plataformas web que permiten consultar esta información de manera individual. Un ejemplo es Tunebat [13], que permite visualizar un conjunto de características, pero restringe la consulta a una canción a la vez. En la figura 1.1 se presenta un ejemplo de perfil de características musicales de una canción en la plataforma web Tunebat. En la interfaz se exponen algunas características, como la tonalidad (Si menor o *B Minor*), el *tempo* (153 BPM) y la duración.

Asimismo, la herramienta cuantifica algunas características en una escala porcentual de 0 a 100, mostrando para este caso específico niveles de acusticidad (77 %) e instrumentalidad (76 %), una baja probabilidad de presencia de habla (*speechiness* en 4 %) y público en vivo (*liveness* en 9 %), además de registrar el volumen medio en decibelios (-8 dB).




FIGURA 1.1. Ejemplo de visualización de características musicales en Tunebat¹.

1.4.3. Síntesis comparativa

Las tecnologías existentes ofrecen herramientas útiles para el objetivo del trabajo. Las bibliotecas de procesamiento digital de señales permiten extraer representaciones numéricas de las ondas sonoras, y los modelos preentrenados ofrecen representaciones semánticas. Por otro lado, las soluciones comerciales proveen servicios de etiquetado para canciones.

Sin embargo, persisten limitaciones operativas para su aplicación directa en el entorno de la empresa. Los servicios de terceros generan costos recurrentes, limitan la cantidad de consultas y crean dependencia tecnológica. Las plataformas web de uso manual no son viables para procesar catálogos con miles de canciones. Además, los modelos no coinciden con las características y las clases específicas que usa Plusyc Live.

Por estos motivos, resulta necesario desarrollar una solución propia. El propósito de este trabajo es aprovechar las técnicas actuales de inteligencia artificial para crear un sistema independiente. Esto permite analizar directamente los archivos de audio, etiquetarlos según las necesidades de la empresa y así reducir la dependencia de proveedores externos.

¹Imagen tomada de <https://tunebat.com/Info/Weird-Fishes-Arpeggi-Radiohead/4wajj1o7jWlg62YqpkHC7S>

Capítulo 2

Introducción específica

Este capítulo introduce las herramientas de terceros y las tecnologías necesarias para el desarrollo del sistema. Se describe la fuente de datos principal, las técnicas para extraer representaciones numéricas del audio, los modelos predictivos y las tecnologías utilizadas para el despliegue.

2.1. Fuentes de datos de canciones

Para el entrenamiento de los modelos predictivos se utilizó la colección privada de canciones de la empresa. Esta fuente de datos cuenta con más de 60 000 archivos de audio de canciones completas.

Se seleccionó este conjunto de datos por la disponibilidad en el acceso a la información y por su representatividad en ambientes comerciales reales. Por el contrario, otros conjuntos de datos públicos musicales, como GTZAN [14] y los subconjuntos estándar de FMA [15], ofrecen fragmentos limitados a 10 o 30 segundos de audio. El uso de pistas incompletas restringe la disponibilidad de la información musical. Realizar predicciones sobre el audio total resulta más preciso, ya que evita la pérdida de los eventos musicales que ocurren antes o después de una sola ventana. Además, estas alternativas carecen parcialmente de las variables objetivo requeridas en el alcance del trabajo.

El acceso a los archivos de audio de canciones completas garantiza la preservación de la estructura musical, evita la pérdida de información y flexibiliza la extracción de representaciones matemáticas mediante el uso de bibliotecas y modelos preentrenados.

El análisis comparativo de las fuentes de datos, las representaciones estadísticas de las canciones y los criterios de selección de variables predictivas se detallan en la sección 3.1 del siguiente capítulo.

2.2. Representaciones numéricas de la música

Una canción se traduce a un formato numérico para su procesamiento computacional. El procesamiento digital de señales (DSP) transforma la onda sonora en arreglos matemáticos de una o dos dimensiones [16, 17]. Entre las representaciones bidimensionales más destacadas se encuentran el espectrograma, el cromagrama y el espacio armónico o tonnetz. El espectrograma refleja la variación de las frecuencias a lo largo del tiempo [16]. Por su parte, el cromagrama captura la energía asociada a las doce clases de notas musicales [18]. Finalmente, el tonnetz

modela las relaciones tonales y armónicas de la pista [19]. A modo de ejemplo, en la figura 2.1 se ilustran estas tres transformaciones aplicadas a un fragmento de la canción “Weird Fishes/Arpeggi” de la banda Radiohead. En estos gráficos, el eje horizontal representa el tiempo, mientras que la intensidad del color indica la magnitud de la energía para las distintas frecuencias, notas musicales o relaciones tonales correspondientes a cada eje vertical.




FIGURA 2.1. Representación visual de un espectrograma, un cromagrama y un tonnetz.

Además de las representaciones bidimensionales, las bibliotecas de procesamiento de señales facilitan la extracción de atributos numéricos unidimensionales. En la tabla 2.1 se presenta un listado que introduce algunas de las características de bajo nivel más representativas en el análisis musical. En la elaboración del trabajo se usaron Librosa y Essentia en este proceso.

Estas transformaciones matemáticas reducen la dimensionalidad del archivo de audio. Sin embargo, carecen de significado semántico. Su función principal, en el

contexto de este trabajo, es la de generar las variables predictivas necesarias para entrenar modelos de aprendizaje automático.

El listado completo de las variables de entrada, el análisis de su relevancia y su impacto en el rendimiento de los algoritmos se detalla en la sección 3.2.2.

TABLA 2.1. Listado introductorio de los principales atributos de procesamiento de señales extraídos del audio.

Atributo	Descripción principal
MFCC	Coefficientes cepstrales que modelan la percepción auditiva humana [16].
Centroide espectral	Indica el centro de masa del espectro acústico. Se asocia al brillo del sonido [17].
Ancho de banda	Mide la dispersión de las frecuencias alrededor del centroide espectral [17].
Tasa de cruces por cero	Cuantifica la cantidad de cambios de signo en la señal temporal [17].
Rolloff espectral	Estima la frecuencia por debajo de la que se concentra la mayor parte de la energía [17].

2.3. Información semántica del audio

Las representaciones de bajo nivel descritas en la sección 2.2 no siempre son suficientes para capturar conceptos musicales complejos. Es posible mejorar la cobertura de la información musical con el aprendizaje por transferencia. Esta técnica consiste en utilizar modelos previamente entrenados con grandes volúmenes de datos para extraer características semánticas de alto nivel.

Para este fin existen bibliotecas especializadas, como PANNs Inference [20]. Esta herramienta provee acceso a redes neuronales optimizadas para el análisis de eventos sonoros. Dentro de sus opciones, destaca la arquitectura denominada CNN14, cuyo diseño se inspira en los modelos convolucionales profundos de la familia VGG [21]. Se trata de una red neuronal capaz de abstraer patrones del audio y generar *embeddings* numéricos basados en las clases del conjunto de datos AudioSet.

Un ejemplo de las probabilidades de detección obtenidas para distintas clases de eventos sonoros a lo largo del tiempo se visualiza en la figura 2.2, donde se muestran ventanas consecutivas de 10 segundos de la canción de Radiohead. En este mapa de calor, las áreas más claras indican una mayor probabilidad de activación para cada clase.

El uso de esta arquitectura permite transformar la onda sonora para extraer *embeddings* y obtener probabilidades asociadas a etiquetas predefinidas, como la presencia de aplausos, instrumentos musicales específicos o habla. Estos datos semánticos enriquecen el conjunto de variables de entrada para la inferencia de algunas de las características musicales que se definieron en el alcance del trabajo.




FIGURA 2.2. Mapa de calor de las características semánticas extraídas mediante la red CNN14.

2.4. Modelos de inteligencia artificial utilizados

Una vez obtenidos los descriptores numéricos y semánticos, es necesario aplicar algoritmos de predicción. Para este fin, se utilizaron dos enfoques principales:

- Algoritmos LightGBM: se integró la arquitectura LightGBM, basada en el ensamble de árboles de decisión. Esta herramienta destaca por su alta velocidad computacional y eficiencia en tareas generales de predicción [22].
- Redes MLP: los perceptrones multicapa son redes neuronales artificiales con capacidad para modelar relaciones complejas. Permiten, entre otras aplicaciones, predecir múltiples variables continuas de forma simultánea [23].

2.5. Despliegue e integración

La integración del sistema predictivo requirió del despliegue de una interfaz de programación de aplicaciones. Para su construcción se utilizó FastAPI [24] como

marco de trabajo. Esta herramienta facilita el desarrollo de servicios web de alto rendimiento basados en Python [25].

El alojamiento remoto del producto se apoyó en los servicios de infraestructura de OCI (por su sigla en inglés, *Oracle Cloud Infrastructure*) [26]. Se provisionó una instancia de cómputo virtual en la nube para desplegar la aplicación y ejecutar los modelos predictivos. El uso de esta tecnología garantiza la disponibilidad continua del sistema.

Capítulo 3

Diseño e implementación

Este capítulo detalla el diseño y la implementación del sistema predictivo. Se analizan los conjuntos de datos utilizados, la extracción de atributos del audio y el tratamiento de datos según las distribuciones de las variables objetivo. Asimismo, se describen las técnicas de reducción y selección de variables, el proceso de optimización de los modelos y los resultados de la iteración productiva. Finalmente, se presenta la arquitectura desarrollada para el despliegue y la integración del sistema en un entorno operativo.

3.1. Conjuntos de datos

3.1.1. Análisis de conjuntos de datos públicos

La definición de la estrategia para la extracción de atributos se fundamenta en una revisión de conjuntos de datos públicos estandarizados en el ámbito MIR. El objetivo de este análisis previo fue entender cómo repositorios de referencia, como FMA y Million Song Dataset [27], representan y estructuran los datos musicales, como método para establecer los criterios de diseño del conjunto de datos propio.

En un comienzo se contempló el uso de algunos de estos conjuntos de datos, pero se encontró que presentan varias limitaciones frente a la solución propuesta: algunos restringen el análisis a segmentos cortos de audio, mientras que otros requieren tamaños de almacenamiento excesivamente pesados o estructuras de datos difíciles de replicar durante el proceso de inferencia y dependientes de las versiones de las bibliotecas de extracción.

Por otro lado, el análisis resultó positivo; estas restricciones motivaron que el proceso de extracción se ejecute directamente sobre el catálogo privado para eliminar las limitaciones, y su análisis permitió conocer las variables numéricas en la música, cómo se segmentan las canciones, cómo se reduce la dimensionalidad y hacer los primeros experimentos predictivos de las variables objetivo requeridas.

GTZAN

Este conjunto de datos se considera el equivalente al MNIST [28] para el análisis de audio [29], dada su adopción histórica como estándar de evaluación en tareas de clasificación de géneros musicales. Con el análisis de este conjunto de datos se pudo identificar los siguientes puntos:

- Variables predictivas principales: tempo, representaciones chroma, amplitud media cuadrática (RMS), descriptores espectrales y coeficientes MFCC.

- Estructura: 1 000 archivos de audio en crudo limitados a 30 segundos, acompañados de metadatos tabulares e imágenes de espectrogramas de Mel en su versión distribuida mediante Kaggle [30]. Todas estas representaciones fueron extraídas con la biblioteca Librosa. Las tablas contienen los atributos calculados sobre la pista completa y también sobre divisiones de 3 segundos para incrementar el volumen de datos de entrenamiento. En ambos escenarios se aplica una reducción de dimensionalidad temporal: las variables se calculan inicialmente sobre micro-ventanas de milisegundos y luego se colapsan a valores estáticos mediante estadísticos de agregación, como la media y la varianza.
- Variables objetivo principales en Plusyc: se podría relacionar con *suggested genres*.
- Desventajas: provee segmentos cortos de audio, lo que limita la representatividad de la información musical a nivel de canción; y solo abarca 10 géneros musicales, mientras que Plusyc trabaja con más de 500.

FMA estándar

Se analiza la versión estándar de FMA, diseñada para superar las limitaciones de tamaño y acceso a las colecciones completa y mediana. Se encuentra:

- Variables predictivas principales: representaciones chroma, Transformada de Q Constante (CQT), tonnetz, MFCC, RMS, descriptores espectrales y tasa de cruces por cero (ZCR).
- Estructura: ofrece recortes de audio de 30 segundos para sus subconjuntos estándar, acompañados de matrices de atributos precomputados distribuidos en formato tabular (CSV). Los atributos fueron extraídos con Librosa y posteriormente colapsados mediante estadísticos de agregación, como la media, desviación estándar, asimetría y curtosis, para obtener valores estáticos por pista.
- Metadatos contextuales: información tabular adicional que incluye álbum, artista, popularidad, fechas de lanzamiento y ubicación geográfica.
- Variables objetivo principales: géneros musicales estructurados en una taxonomía jerárquica de clases y para un subconjunto de aproximadamente 13 000 pistas, proporciona atributos como *danceability*, *energy*, *valence*, *speechiness* y *liveness*.
- Desventajas: el análisis está restringido a segmentos de 30 segundos en la versión estándar. Las versiones media y completa exceden las capacidades de procesamiento de la infraestructura actual de la empresa. Además, la incertidumbre sobre las versiones exactas de Librosa utilizadas originalmente dificulta la replicabilidad técnica sobre canciones nuevas. Finalmente, la información etiquetada de 13 000 pistas es mucho menor que la de más de 60 000 de Plusyc.

Million Song Dataset (MSD)

Desarrollado por la Universidad de Columbia y The Echo Nest, este conjunto escaló la investigación de información musical a nivel industrial. Se describen sus componentes principales:

- Variables predictivas principales: representaciones de tono (chroma y pitch) y descriptores de timbre, ambos calculados a nivel de segmento.
- Estructura: colección de metadatos y descriptores precomputados empaquetados en archivos HDF5.
- Método de extracción: a diferencia de la segmentación por ventanas fijas, el MSD utiliza una división adaptativa basada en eventos. Esto fragmenta la canción en segmentos de duración variable. Para cada uno de estos segmentos, se calculan coeficientes de tono y timbre, y se genera una matriz de atributos alineada con la estructura temporal de la pista.
- Variables objetivo principales: proporciona atributos musicales fundamentales como *tempo*, *loudness*, *key* y *mode*.
- Desventajas: los descriptores se generaron con algoritmos propietarios de The Echo Nest, lo que complica procesar la segmentación por eventos en canciones nuevas de forma idéntica para realizar el proceso de inferencia.

AudioSet

Este conjunto masivo establece un estándar para la clasificación de eventos sonoros generales:

- Estructura: conjunto de identificadores de videos de YouTube y marcas de tiempo que referencian segmentos de 10 segundos, anotados bajo una ontología de 527 clases.
- Variables predictivas principales: el corpus original no extrae descriptores tradicionales. Su distribución oficial provee embeddings precomputados mediante el modelo VGGish [31], que sirven como entrada rápida para entrenar clasificadores de terceros sin necesidad de descargar el audio original.
- Variables objetivo principales: etiquetas multiclase que identifican la presencia de instrumentos musicales, como tipos de voces (habla, canto) y ambientes acústicos.
- Desventajas: el enfoque en sonidos generales limita su precisión para los atributos musicales.

Cabe mencionar que, a pesar de que en algunas de las fuentes de datos públicas se incluye información del contexto como la región del artista, el año de lanzamiento, el álbum o las letras, en esta solución se trabaja exclusivamente con información musical que se extrae del audio.

3.1.2. Reducción de dimensionalidad mediante estadísticas

En el ámbito del procesamiento de señales, la información de un archivo de audio se representa como una serie de tiempo multivariada: una secuencia de puntos de datos [16], en este caso, descriptores numéricos y semánticos, indexados y ordenados cronológicamente.

La estrategia adoptada se inspiró en los conjuntos de datos de referencia, donde la señal se divide en ventanas temporales y la información de cada ventana se colapsa en valores estáticos. Esto permite reducir estas secuencias a un vector por

cada canción, para optimizar el uso de la memoria y los tiempos de procesamiento. El diagrama de flujo de este algoritmo se muestra en la figura 3.1, donde se observa como la extracción ocurre en ramas paralelas para la transformación de la señal a un vector de estadísticos.




FIGURA 3.1. Algoritmo de extracción de atributos.

En la rama de la izquierda se observa la extracción de variables (DSP) y a la derecha la extracción de embeddings y probabilidades semánticas con PANNs inference:

- Para la extracción de variables (DSP) se utilizan las bibliotecas Librosa y Essentia sobre la señal continua, el algoritmo extrae las series temporales de las características principales, por ventanas de 64 ms de longitud y solapamiento de 16 ms, que proporciona una alta resolución temporal original de la señal [16, 17]. También se extrae información global de la canción, descriptores escalares para la pista entera que complementan la información segmentada.
- Para la extracción de embeddings y probabilidades se estableció una ventana de análisis de 10 segundos continuos. Esta decisión se fundamenta en la arquitectura de la red neuronal CNN14, entrenada sobre el conjunto de

datos AudioSet, cuyos segmentos originales son de 10 segundos. El algoritmo extrae un vector de embeddings y las probabilidades de activación para 173 clases de eventos musicales provistas por PANNs inference por cada ventana.

- Agrupación estadística: dado que una canción estándar produce una cantidad variable de segmentos, se aplicó una técnica de colapso estadístico a lo largo del eje temporal, según el tipo de variable:
 - Para las variables (DSP), se calcularon siete estadísticos por pista: media, desviación estándar, asimetría, curtosis, y los percentiles 10 (cerca del mínimo), 50 (mediana) y 90 (cerca del máximo para evitar ruido).
 - Para los embeddings y las probabilidades semánticas de las 173 clases seleccionadas de PANNs, se calcularon cuatro medidas: media, valor máximo, desviación estándar y el percentil 90.

Este enfoque matemático permite comprimir el volumen masivo de información de una serie de tiempo en un vector unidimensional por canción. Una representación empírica de este proceso se ilustra en la figura 3.2, donde se observa visualmente cómo las matrices dinámicas de la pista se colapsan en vectores tras el cálculo estadístico. La visualización muestra solo algunos ejemplos, la media en algunos DSP y el percentil 90 en algunas clases del AudioSet.




FIGURA 3.2. Visualización de la reducción de dimensionalidad: las secuencias temporales (izquierda) se transforman en vectores (derecha) mediante la aplicación de medidas de agregación.

Algunos experimentos preliminares sirvieron para validar que esta representación permitía capturar la información esencial de la canción de manera eficiente y compacta. El algoritmo de extracción, es el resultado de pruebas con distintas configuraciones de variables, estadísticos y métodos de segmentación.

3.1.3. Conformación del espacio de variables

El procesamiento computacional sobre el catálogo de canciones requirió más de una semana de ejecución para procesar y extraer la información de más de 60 000 canciones completas. El alto costo computacional se justificó por la necesidad de garantizar la disponibilidad de información para los experimentos de modelos predictivos de múltiples características musicales.

La aplicación del algoritmo final generó un conjunto de datos masivo compuesto por 9591 variables, resumido en la tabla 3.1.

TABLA 3.1. Desglose estructural de las 9591 variables extraídas por canción.

Categoría de extracción	Atributos base	Cant.	Estadísticos aplicados	Cant.	Total
Representaciones DSP (Librosa)	MFCC (20), Deltas (40), Centroide, Ancho de banda, Rolloff, Contraste (7), Flatness, Flux, Chroma (12), Tonnetz (6), RMS, ZCR.	92	Media, Desv. Estándar, Asimetría, Curtosis, Percentiles (10, 50, 90).	7	644
Atributos globales y ritmo	LUFs, Entropía espectral, Tempo Librosa/Essentia (2), Complejidad dinámica, Tasa de onsets, Estadísticos de onset (3), Pitch, Fracción de voz, Claridad tonal (2), Factor de cresta.	15	Cálculo único por pista completa.	1	15
Estimación tonal (Perfiles)	Vectores de correlación Krumhansl (Mayor/Menor) y Temperley (Mayor/Menor).	48	Cálculo único por pista completa (4 perfiles $\times$ 12 semitonos).	1	48
Embeddings semánticos (PANNs)	Vector latente de la capa previa a la clasificación de la red CNN14.	2048	Media, Máximo, Desv. Estándar, Percentil 90.	4	8192
Probabilidades (PANNs)	Clases filtradas (Voz, Instrumentos, Géneros, Público en vivo, Distorsión).	173	Media, Máximo, Desv. Estándar, Percentil 90.	4	692
Total de variables por canción:					9591

3.2. Ejecución de tareas sobre el conjunto de datos

Esta sección presenta las variables objetivo y sus distribuciones, el tratamiento aplicado a los datos y las técnicas de selección y reducción de variables predictivas.

Las variables objetivo se dividen en tres grupos: básicas, perceptibles y géneros/estados de ánimo sugeridos. Y se definen en la tabla 3.2.

TABLA 3.2. Definición, ejemplos y tipo de problema de aprendizaje supervisado por característica.

Característica	Definición	Ejemplos	Tipo de problema
Básicas			
<i>Loudness</i>	Volumen global promedio en decibeles, más negativa, más silenciosa (dB)	-5.2 dB, -12.4 dB	Regresión
<i>Key</i>	Tonalidad estimada de la pista mapeada a números enteros (<i>Pitch Class</i>).	0 (Do), 1 (Do#), 2 (Re)	Clasificación
<i>Mode</i>	Modalidad (mayor o menor) del contenido melódico.	1 (Mayor), 0 (Menor)	Clasificación
<i>Tempo</i>	Tempo global estimado en pulsaciones por minuto (BPM).	120 BPM, 85 BPM	Regresión
Perceptibles			
<i>Acousticness</i>	Confianza de que la pista es acústica (0.0 a 1.0).	0.95, 0.10	Regresión
<i>Danceability</i>	Capacidad de ser bailable según tempo y ritmo (0.0 a 1.0).	0.85, 0.20	Regresión
<i>Energy</i>	Medida de intensidad y actividad (0.0 a 1.0).	0.90	Regresión
<i>Instrumentalness</i>	Probabilidad de ausencia de contenido vocal (0.0 a 1.0).	0.90 (sin voz), 0.05 (cantada)	Regresión
<i>Liveness</i>	Confianza de grabación con público en vivo (0.0 a 1.0).	0.85 (concierto), 0.10 (estudio)	Regresión
<i>Speechiness</i>	Presencia de palabras habladas (0.0 a 1.0).	0.85 (conversación), 0.5 (rap), 0.05 (música)	Regresión
<i>Valence</i>	Positividad musical transmitida (0.0 a 1.0).	0.90, 0.15	Regresión
ánimo y género sugeridos			
<i>Primary Mood</i>	Estado de ánimo o emoción predominante.	<i>Energizing, Lively, Empowering</i>	Clasificación
<i>Secondary Mood</i>	Estados de ánimo complementarios.	<i>Euphoric Energy, Energetic Anxious</i>	Clasificación
<i>Suggested Genres</i>	Género musical.	<i>Chill House, EDM</i>	Clasificación

3.2.1. Distribuciones de las variables objetivo

Características básicas

Este grupo incluye el *loudness*, *key*, *mode* y *tempo*:

Loudness La figura 3.3 muestra el valor del *loudness* en el eje x y la frecuencia en las canciones del catálogo en el eje y. Se observa que presenta un sesgo negativo, con una concentración principal cerca de los -7 dB. Esto es predecible dada la guerra del *loudness* [32], donde muchos artistas y productores quieren que sus canciones suenen fuertes, y plataformas como Spotify normalizan el *loudness* para evitar cambios abruptos en el volumen entre las canciones.




FIGURA 3.3. Distribución de *loudness* en el catálogo.

Desafíos y tratamiento:

- Desafío 1:
- Desafío n:

3.2.2. Selección de variables de entrada

3.3. Modelado y optimización

3.4. Arquitectura de despliegue e integración

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] J. Stephen Downie. «Music Information Retrieval». En: *Annual Review of Information Science and Technology* (2003).
- [2] Michael A. Casey et al. «Content-Based Music Information Retrieval: Current Directions and Future Challenges». En: *Proceedings of the IEEE* (2008).
- [3] Gordon C Bruner II. «Music, mood, and marketing». En: *Journal of marketing* (1990).
- [4] Franck V Garlin y Keri Owen. «Setting the tone with the tune: A meta-analytic review of the effects of background music in retail settings». En: *Journal of Business Research* (2006).
- [5] Holger Roschk, Sandra Maria Correia Loureiro y Jan Breitsohl. «Calibrating 30 years of experimental research: a meta-analysis of the atmospheric effects of music, scent, and color». En: *Journal of Retailing* (2017).
- [6] Plusyc Live SAS. *Perfil oficial en Instagram*. 2026. URL: <https://www.instagram.com/plusyc/>.
- [7] Brian McFee et al. «librosa: Audio and Music Signal Analysis in Python». En: *Proceedings of the 14th Python in Science Conference*. Visitado el 2026-03-20. 2015. URL: <https://librosa.org/>.
- [8] Dmitry Bogdanov et al. «Essentia: An Audio Analysis Library for Music Information Retrieval». En: *Proceedings of the 14th International Society for Music Information Retrieval Conference (ISMIR)*. 2013. URL: <http://essentia.upf.edu/>.
- [9] Jordi Pons y Xavier Serra. «musicnn: Pre-trained Convolutional Neural Networks for Music Audio Tagging». En: *Late-Breaking/Demo Session of the 20th International Society for Music Information Retrieval Conference (ISMIR)*. 2019. URL: <https://github.com/jordipons/musicnn>.
- [10] Jort F. Gemmeke et al. «Audio Set: An ontology and human-labeled dataset for audio events». En: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017. URL: <https://research.google.com/audioset/>.
- [11] Spotify AB. *Spotify Web API Reference: Get Audio Features*. 2026. URL: <https://developer.spotify.com/documentation/web-api/reference/get-audio-features>.
- [12] Gracenote Inc. *Gracenote Music Data: Sonic Attributes and Mood*. 2026. URL: <https://gracenote.com/products/audio-data/>.
- [13] Tunebat. *Tunebat: Song Key, BPM and Audio Features Database*. 2026. URL: <https://tunebat.com/>.
- [14] George Tzanetakis y Perry Cook. «Musical genre classification of audio signals». En: *IEEE Transactions on Speech and Audio Processing* (2002).
- [15] Michaël Defferrard et al. «FMA: A Dataset for Music Analysis». En: *18th International Society for Music Information Retrieval Conference (ISMIR)*. 2017.
- [16] Meinard Müller. *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Springer, 2015.

- [17] Alexander Lerch. *An introduction to audio content analysis: Applications in signal processing and music informatics*. John Wiley & Sons, 2012.
- [18] Emilia Gómez. «Tonal description of polyphonic audio for music content processing». En: *INFORMS Journal on Computing* (2006).
- [19] Christopher Harte, Mark Sandler y Martin Gasser. «Detecting harmonic change in musical audio». En: *Proceedings of the 1st ACM workshop on Audio and music computing multimedia*. 2006.
- [20] Qiuqiang Kong et al. «PANNs: Large-scale pretrained audio neural networks for audio pattern recognition». En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* (2020).
- [21] Karen Simonyan y Andrew Zisserman. «Very deep convolutional networks for large-scale image recognition». En: *International Conference on Learning Representations*. 2015.
- [22] Guolin Ke et al. «Lightgbm: A highly efficient gradient boosting decision tree». En: *Advances in neural information processing systems*. Vol. 30. 2017.
- [23] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep learning*. MIT press, 2016.
- [24] Sebastián Ramírez. *FastAPI*. 2018. URL: <https://github.com/fastapi/fastapi>.
- [25] Python Software Foundation. *Python Language Reference*. 2026. URL: <https://www.python.org>.
- [26] Oracle Corporation. *Oracle Cloud Infrastructure*. 2026. URL: <https://www.oracle.com/cloud/>.
- [27] Thierry Bertin-Mahieux et al. «The million song dataset». En: *Proceedings of the 12th International Society for Music Information Retrieval Conference (ISMIR 2011)*. 2011.
- [28] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* (1998).
- [29] Bob L. Sturm. «The state of the art ten years after a state of the art: Future research in music information retrieval». En: *Journal of New Music Research* (2014).
- [30] Andrada Olteanu. *GTZAN Dataset - Music Genre Classification*. 2020. URL: <https://www.kaggle.com/datasets/andradolteanu/gtzan-dataset-music-genre-classification>.
- [31] Shawn Hershey et al. «CNN architectures for large-scale audio classification». En: *IEEE*. 2017.
- [32] Earl Vickers. «The loudness war: Background, speculation and recommendations». En: *Audio Engineering Society*. 2010.